

Modelos Lineares Generalizados

Por que precisamos de MLGs?

ESTAT0092 – Modelos Lineares Generalizados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/mlg>

Introdução

- A **Estatística** desenvolve e utiliza teorias, métodos matemáticos e probabilísticos e procedimentos computacionais para compreender o comportamento de fenômenos, objetos, indivíduos ou sistemas a partir de observações.
- Aquilo que se deseja compreender é denominado **entidade** (ex.: uma pessoa, uma empresa, uma cidade ou uma população)
- A entidade não é incorporada diretamente à análise estatística. Ela é representada por características que podem ser observadas ou mensuradas (**variáveis**).
- Cada observação da entidade produz diferentes valores para suas variáveis e formam a **variabilidade**.

Introdução


- A Estatística procura compreender essa variabilidade a partir da identificação de **padrões** no comportamento conjunto das observações.
- Os métodos estatísticos assumem que esses padrões possuem algum componente aleatório que pode ser estudado e representado probabilisticamente.
- Assim, embora não seja possível prever perfeitamente cada observação individual, é possível identificar regularidades e investigar **associações entre variáveis**.
- Por exemplo, podemos investigar como características de uma transação se relacionam com a probabilidade de fraude ou como características socioeconômicas de uma população se relacionam com seus indicadores de saúde.

Introdução

- Uma vez identificada uma associação entre variáveis, podemos utilizá-la para diferentes finalidades. Entre as mais importantes estão:
 - **Predizer** o valor de uma variável a partir de outras;
 - **Explicar** como uma variável varia em associação com outras.


Predição

- Quando existe uma associação entre variáveis, os valores conhecidos de algumas delas podem ser utilizados para *estimar o valor desconhecido de outra*.
- Essa utilização da associação é denominada **predição**.
- A predição é particularmente útil quando a variável de interesse:
 - é difícil, cara ou demorada de ser observada; ou
 - representa um resultado que ainda será observado no futuro.
- **Exemplo:** uma empresa pode utilizar informações como *preço, período do ano, investimentos em publicidade e vendas anteriores* para *predizer a demanda de um produto no próximo mês*.



Explicação

- A associação entre variáveis também pode ser utilizada para *descrever e quantificar como uma variável tende a variar em relação a outras*.
- Nesse caso, o objetivo não é necessariamente prever o valor de uma nova observação, mas compreender e quantificar a relação observada entre as variáveis.
- **Exemplo:** podemos investigar como o *investimento em publicidade* está associado às *vendas* e estimar *quanto as vendas tendem a variar, em média, para diferentes níveis de investimento*.
- É importante destacar que **descrever uma associação não significa, necessariamente, demonstrar uma relação causal**.



Modelagem de regressão

- A **modelagem de regressão** utiliza métodos estatísticos para estudar a associação entre duas ou mais variáveis e **representar matematicamente essa relação**.
- Uma variável é definida como a principal variável de interesse, denominada **variável resposta**, enquanto as demais são denominadas **variáveis preditoras** e são utilizadas para representar seu comportamento.
- Um **modelo de regressão** descreve como o comportamento da variável resposta está associado aos valores das variáveis preditoras, considerando a variabilidade presente nas observações.
- Esses modelos podem ser utilizados para **investigar associações, quantificar relações, descrever o comportamento** de uma variável ou **predizer valores desconhecidos**.

Modelo de regressão normal linear

- Seja Y a variável resposta e sejam $x_1, \dots, x_p$ as variáveis preditoras.
- Para valores observados de Y e das $x_1, \dots, x_p$ das variáveis preditoras, o modelo de regressão normal linear assume que

$$Y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon$$

- $\beta_0, \beta_1, \dots, \beta_p$ são parâmetros reais;
- ε é uma variável aleatória tal que $\varepsilon \sim N(0, \sigma^2)$.
- Os coeficientes $\beta_0, \beta_1, \dots, \beta_p$ e a variância σ^2 são os **parâmetros** do modelo.
- Em geral, os parâmetros são **desconhecidos** e devem ser estimados com base em uma amostra de observações da variável resposta e das variáveis preditoras.
- A variável aleatória ε é denominada **erro aleatório**.

Modelo de regressão normal linear

- O modelo de regressão normal linear possui as seguintes propriedades:
 1. $E[Y \mid x_1, \dots, x_p] = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$;
 2. $Var[Y \mid x_1, \dots, x_p] = \sigma^2$;
 3. $Y \mid x_1, \dots, x_p$ segue uma distribuição normal.
- A primeira propriedade estabelece que a média da variável resposta varia linearmente em função das variáveis preditoras.
- A segunda estabelece que a variância da variável resposta permanece constante para diferentes valores das variáveis preditoras.

Modelo de regressão normal linear

- Quando a variância condicional da variável resposta é constante, dizemos que há **homoscedasticidade**.
- O oposto de homoscedasticidade é a **heteroscedasticidade**, que ocorre quando a variância da variável resposta varia de acordo com os valores das variáveis preditoras.
- Essas propriedades permitem concluir que:

$$Y \mid x_1, \dots, x_p \sim N(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p, \sigma^2).$$

- Ou seja, para determinados valores das variáveis preditoras, o modelo assume que a variável resposta segue uma distribuição Normal cuja **média é uma função linear das variáveis preditoras** e cuja **variância é constante**.

Modelo de regressão normal linear

- O objetivo da modelagem de regressão é obter um modelo capaz de **descrever satisfatoriamente o comportamento da variável resposta** em função das variáveis preditoras.
- De forma geral, o processo envolve quatro etapas:
 1. **Especificação** do modelo;
 2. **Estimação** dos parâmetros;
 3. **Avaliação** da adequação do modelo;
 4. **Aplicação** do modelo.
- Inicialmente, definimos as variáveis, a estrutura do modelo e suas suposições.
- Em seguida, estimamos seus parâmetros a partir de uma amostra.

Modelo de regressão normal linear

- Após estimar os parâmetros, avaliamos se o modelo descreve adequadamente os dados e se suas **suposições são plausíveis**.
- Também investigamos a existência de observações que não são adequadamente explicadas pelo modelo (análise de resíduos, identificação de pontos discrepantes, pontos de alavancagem e observações influentes).
- Uma vez considerado adequado, o modelo pode ser utilizado para:
 - **investigar associações;**
 - **descrever e quantificar relações;**
 - **predizer valores desconhecidos.**
- Espera-se, ao final do processo, obter um modelo capaz de reproduzir satisfatoriamente o comportamento observado da variável resposta.

Modelo de regressão normal linear

- Na avaliação do modelo, investigamos se suas principais suposições são adequadas aos dados.
- No modelo de regressão normal linear, verificamos se:
 1. a média da resposta varia **linearmente** com as variáveis preditoras;
 2. a variância da resposta é **constante**;
 3. a resposta segue uma **distribuição Normal**, fixados os valores das variáveis preditoras.
- A violação de alguma dessas suposições pode indicar que o modelo normal linear não é adequado aos dados.
- Uma possibilidade para lidar com essas situações é transformar a variável resposta e/ou as variáveis preditoras (ex.: transformação de Box-Cox).
- Outra é **repensar a própria estrutura do modelo**.

Uma nova forma de representar o modelo

- Temos que o modelo de regressão normal linear é geralmente escrito como:

$$Y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon,$$

em que $\varepsilon \sim N(0, \sigma^2)$ é o erro aleatório.

- Para valores fixados das variáveis preditoras, a expressão $\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$ é constante.
- Assim, a variabilidade de Y decorre exclusivamente do erro aleatório. Portanto,

$$Y \mid x_1, \dots, x_p \sim N \left(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p, \sigma^2 \right).$$

Uma nova forma de representar o modelo

A representação anterior permite identificar três componentes:

1. **Componente sistemático.** Um preditor linear formado pela combinação das variáveis preditoras:

$$\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

2. **Relação com a média.** No modelo normal linear,

$$\mu = \eta$$

3. **Componente aleatório.** A distribuição da resposta em torno da média:

$$Y \mid x_1, \dots, x_p \sim N(\mu, \sigma^2)$$

Uma nova forma de representar o modelo

- Dessa forma, o modelo de regressão normal linear pode ser compreendido a partir de três componentes:
 - Uma **distribuição de probabilidade** para a variável resposta Y ;
 - Uma combinação linear das variáveis preditoras, chamada **preditor linear** (η);
 - Uma **relação funcional** entre a média de Y (μ) e η (função identidade, isto é, $\mu = \eta$).
- Os **Modelos Lineares Generalizados** (MLGs) surgem ao ampliar as possibilidades para especificar esses componentes.

Forma Geral de um MLG

Um Modelo Linear Generalizado é definido por três componentes:

1. **Componente aleatório.** A variável resposta Y segue uma distribuição de probabilidade adequada à natureza dos dados.
2. **Componente sistemático.** As variáveis preditoras são combinadas em um preditor linear:

$$\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

3. **Função de ligação.** A média da variável resposta $\mu = E[Y]$ é relacionada ao preditor linear por meio de uma função g :

$$g(\mu) = \eta.$$

Exemplo: Regressão de Poisson

- Suponha que desejamos estudar o *número de sinistros registrados por uma seguradora* em determinado período.
- Y é uma variável quantitativa discreta que representa uma **contagem**, com $Y \in \{0, 1, 2, 3, \dots\}$.
- Podemos estar interessados em investigar como o número esperado de sinistros está associado a características como:
 - perfil dos segurados;
 - região;
 - tipo de veículo;
 - período de exposição ao risco.
- Uma distribuição frequentemente utilizada para representar variáveis de contagem é a **distribuição de Poisson**.

Exemplo: Regressão de Poisson

- Se $Y \sim \text{Poisson}(\mu)$: $P(Y = y) = \frac{e^{-\mu} \mu^y}{y!}$, $y \in \{0, 1, 2, \dots\}$
 - Além disso, $E[Y] = \text{Var}[Y] = \mu$.
- Assim, uma primeira especificação para os três componentes do modelo seria:
 1. **Componente aleatório:** $Y \sim \text{Poisson}(\mu)$
 2. **Componente sistemático:** $\eta = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$
 3. **Relação com a média:** $\mu = \eta$
- Entretanto, essa especificação apresenta um problema: η pode assumir valores negativos, mas a média $\mu = E[Y]$ é sempre positiva na Poisson.

Exemplo: Regressão de Poisson

- Uma solução é usar a função de ligação logarítmica $g(\mu) = \ln(\mu)$, pois ela transforma valores positivos de μ em qualquer valor real.
- Assim, o modelo pode ser definido por:
 1. **Componente aleatório:** $Y \sim \text{Poisson}(\mu)$
 2. **Componente sistemático:** $\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$
 3. **Função de ligação:** $\ln(\mu) = \eta$
- Esse modelo é conhecido como **modelo de regressão de Poisson**.
- Nesse caso, $\mu = e^\eta = e^{\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p}$, garantindo que $\mu > 0$.
- Como $\text{Var}[Y] = \mu$, $\text{Var}[Y] = e^\eta = e^{\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p}$.
- Portanto, quando a média varia com as variáveis preditoras, a variância da resposta também varia, permitindo a heteroscedasticidade.

Exemplo: Regressão Logística

- Suponha que uma instituição financeira deseje estudar a **probabilidade de um cliente se tornar inadimplente** em determinado período.
- Y é uma variável binária:
$$Y = \begin{cases} 1, & \text{cliente se torna inadimplente;} \\ 0, & \text{cliente não se torna inadimplente.} \end{cases}$$
- Podemos estar interessados em investigar como essa probabilidade está associada a características como:
 - renda;
 - idade;
 - histórico de pagamentos;
 - número de empréstimos.
- Como Y assume apenas dois valores, a **distribuição de Bernoulli** é adequada.

Exemplo: Regressão Logística

- Se $Y \sim \text{Bernoulli}(\mu)$: $P(Y = y) = \mu^y (1 - \mu)^{1-y}$, $y \in \{0, 1\}$.
- Além disso, $E[Y] = \mu$ e $\text{Var}[Y] = \mu(1 - \mu)$.
- Assim, uma primeira especificação para os três componentes seria:
 1. **Componente aleatório:** $Y \sim \text{Bernoulli}(\mu)$
 2. **Componente sistemático:** $\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$
 3. **Relação com a média:** $\mu = \eta$
- Entretanto, essa especificação apresenta um problema: η pode assumir qualquer valor real, enquanto $\mu = E[Y]$ é uma probabilidade e, portanto,

$$0 \leq \mu \leq 1.$$

Exemplo: Regressão logística

- Uma solução é utilizar a **função de ligação logit**:

$$g(\mu) = \text{logit}(\mu) = \ln \left(\frac{\mu}{1 - \mu} \right).$$

- Assim, o modelo pode ser definido por:

1. **Componente aleatório:** $Y \sim \text{Bernoulli}(\mu)$

2. **Componente sistemático:** $\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$

3. **Função de ligação:** $\text{logit}(\mu) = \eta$

- Esse modelo é conhecido como **modelo de regressão logística**.

- A probabilidade de inadimplência é $\mu = \frac{e^\eta}{1+e^\eta} = \frac{e^{\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p}}{1+e^{\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p}}$, garantindo que $0 < \mu < 1$.

Exemplo: Regressão logística

- Além disso, como $Var[Y] = \mu(1 - \mu)$, temos que

$$Var[Y] = \frac{e^{\eta}}{(1 + e^{\eta})^2} = \frac{e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p}}{(1 + e^{\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p})^2}.$$

- Ou seja, a variância da resposta depende da média e pode variar entre diferentes valores das variáveis preditoras (o modelo incorpora a heteroscedasticidade).

MLGs e Família Exponencial

- Os modelos **normal linear**, **Poisson** e **logístico** possuem a mesma estrutura:
 - uma distribuição de probabilidade para a variável resposta Y ;
 - um preditor linear $\eta = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$;
 - uma relação entre a média $\mu = E[Y]$ e η .
- Além dessa estrutura, há outra característica em comum:

as distribuições de Y pertencem à família exponencial.

MLGs e Família Exponencial

- A distribuição de uma v.a. Y pertence à família exponencial se sua função de probabilidade, ou função de densidade de probabilidade, pode ser escrita na forma

$$f(y; \theta, \phi) = \exp\{ \phi^{-1} [\theta y - b(\theta)] + c(y, \phi) \},$$

em que θ e ϕ são parâmetros e $b(\cdot)$ e $c(\cdot, \cdot)$ são funções conhecidas.

- Além das distribuições **Normal**, **Poisson** e **Bernoulli**, várias outras distribuições pertencem à família exponencial, tais como **Normal inversa**, **Gama**, **Binomial** e **Binomial negativa**.
- A família exponencial reúne então distribuições de probabilidade que podem ser adequadas para representar respostas contínuas, contagens, binárias, entre outras.

Modelos Lineares Generalizados

- Para uma variável resposta Y e um conjunto de preditores $x_1, \dots, x_p$, um MLG é definido da seguinte forma:
 1. A distribuição de Y pertence à família exponencial;
 2. $\eta = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$
 3. $g(\mu) = \eta$ em que μ é a média de Y e g é uma função monótona diferenciável.
- A família exponencial fornece uma estrutura comum que permite tratar, **de forma unificada**, propriedades importantes da distribuição da resposta, especialmente a média, a variância e relações entre os parâmetros da distribuição.
- Isto é, diferentes distribuições podem assumir formas distintas, mas podem ser representadas por meio de uma mesma estrutura matemática.

Identificando uma distribuição na família exponencial

- Para verificar se uma distribuição pertence à família exponencial, procuramos escrever sua função de probabilidade ou densidade na forma

$$f(y; \theta, \phi) = \exp\{\phi^{-1}[\theta y - b(\theta)] + c(y, \phi)\}.$$

- O procedimento consiste em reorganizar a função de probabilidade ou densidade até identificar
 - θ
 - ϕ
 - $b(\theta)$
 - $c(y, \phi)$

Exemplo 1.1

Considere $Y \sim \text{Poisson}(\mu)$, cuja função de probabilidade é

$$f(y; \mu) = \frac{\mu^y e^{-\mu}}{y!}, \quad y \in \{0, 1, 2, \dots\}.$$

Escreva a função de probabilidade na forma da família exponencial e identifique θ , ϕ , $b(\theta)$ e $c(y, \phi)$.

Exemplo 1.2

Considere $Y \sim \text{Bernoulli}(\mu)$, cuja função de probabilidade é

$$f(y; \mu) = \mu^y (1 - \mu)^{1-y}, \quad y \in \{0, 1\}.$$

Escreva a função de probabilidade na forma da família exponencial e identifique θ , ϕ , $b(\theta)$ e $c(y, \phi)$.

Exemplo 1.3

Considere $Y \sim N(\mu, \sigma^2)$, cuja função de densidade é

$$f(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(y - \mu)^2}{2\sigma^2}\right\}, \quad y \in \mathbb{R}.$$

Escreva a função de densidade na forma da família exponencial e identifique θ , ϕ , $b(\theta)$ e $c(y, \phi)$.

Representação das distribuições na família exponencial

Distribuição	θ	ϕ	$b(\theta)$	$c(y, \phi)$
Poisson	$\ln(\mu)$	1	e^θ	$-\ln(y!)$
Bernoulli	$\ln\left(\frac{\mu}{1-\mu}\right)$	1	$\ln(1 + e^\theta)$	0
Normal	μ	σ^2	$\frac{\theta^2}{2}$	$-\frac{y^2}{2\phi} - \frac{1}{2}\ln(2\pi\phi)$

Parâmetro canônico e parâmetro de dispersão

- Na representação

$$f(y; \theta, \phi) = \exp\{\phi^{-1}[\theta y - b(\theta)] + c(y, \phi)\},$$

- θ é chamado **parâmetro canônico**, pois é o parâmetro que aparece associado diretamente à resposta y .
- ϕ é chamado **parâmetro de dispersão**, pois controla a variabilidade da distribuição.

Fim