

Estimação por Máxima Verossimilhança

Como usamos os dados para estimar β e ϕ ?

ESTAT0092 – Modelos Lineares Generalizados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/mlg>

Definição de um MLG

Seja Y_i a variável resposta e $x_{i1}, x_{i2}, \dots, x_{ip}$ as variáveis preditoras, $i = 1, \dots, n$. Um MLG é definido por três componentes:

1. Componente aleatório. A distribuição da variável resposta Y_i pertence à família exponencial, na forma

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right\}.$$

- A média é $\mu_i = E(Y_i) = b'(\theta_i)$.
 - Ou seja, a média μ_i e o parâmetro canônico θ_i estão relacionados.
 - Note que $\theta_i = (b')^{-1}(\mu_i)$.
- A variância é $Var(Y_i) = \phi b''(\theta_i) = \phi V(\mu_i)$.

Definição de um MLG

2. Componente sistemático. As variáveis preditoras são combinadas linearmente por meio do preditor linear:

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

- $\mathbf{x}_i = (1, x_{i1}, \dots, x_{ip})^\top$ é o vetor contendo o intercepto e as variáveis preditoras;
- $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ é o vetor de coeficientes de regressão.

3. Função de ligação. A média μ_i é relacionada ao preditor linear por uma função de ligação:

$$g(\mu_i) = \eta_i.$$

- Consequentemente, $\mu_i = g^{-1}(\eta_i)$.

A cadeia de relações

- Portanto, os parâmetros β determinam a distribuição de Y_i por meio da sequência

$$\beta \longrightarrow \eta_i \longrightarrow \mu_i \longrightarrow \theta_i$$

pois

$$\eta_i = \mathbf{x}_i^\top \beta, \quad \mu_i = g^{-1}(\eta_i), \quad \theta_i = (b')^{-1}(\mu_i).$$

- Essa cadeia será fundamental para obter a **função escore**, que será utilizada para obter as estimativas dos parâmetros pelo **método da máxima verossimilhança**.
- No método da máxima verossimilhança, **derivamos a log-verossimilhança em relação aos parâmetros** para obter a função escore. Como a log-verossimilhança depende de β indiretamente, por meio de η_i , μ_i e θ_i , sua derivada em relação a β será obtida utilizando a **regra da cadeia**.

Função de verossimilhança

- Nos MLGs, buscamos os valores de β e ϕ que maximizam a função de verossimilhança.
- Como as observações são independentes, a função de verossimilhança é

$$\begin{aligned} L(\beta, \phi) &= \prod_{i=1}^n f(y_i; \theta_i, \phi) \\ &= \exp \left\{ \phi^{-1} \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^n c(y_i, \phi) \right\} \\ &= \exp \left\{ \phi^{-1} \left(\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n c(y_i, \phi) \right\} \end{aligned}$$

Função de log-verossimilhança

$$\begin{aligned}\ell(\boldsymbol{\beta}, \phi) &= \ln[L(\boldsymbol{\beta}, \phi)] \\ &= \phi^{-1} \left(\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n c(y_i, \phi)\end{aligned}$$

- Embora ℓ seja escrita em termos de θ_i e ϕ , os parâmetros do modelo são $\boldsymbol{\beta}$ e ϕ .

Máxima Verossimilhança

- Os parâmetros $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ e ϕ são estimados maximizando a função de log-verossimilhança, isto é,

$$(\hat{\boldsymbol{\beta}}, \hat{\phi}) = \arg \max_{\boldsymbol{\beta}, \phi} \ell(\boldsymbol{\beta}, \phi).$$

- Para encontrar os estimadores, procuramos os valores de $\boldsymbol{\beta}$ e ϕ que satisfazem as equações

$$\frac{\partial \ell}{\partial \beta_j} = 0, \quad j = 0, 1, \dots, p, \quad \text{e} \quad \frac{\partial \ell}{\partial \phi} = 0$$

- O conjunto dessas derivadas forma a **função escore**.

Função escore

- A função escore é o gradiente (vetor que aponta na direção em que o valor da função cresce mais rápido) da log-verossimilhança. Ela é dada por

$$\mathbf{U}(\boldsymbol{\beta}, \phi) = \left(\frac{\partial \ell}{\partial \beta_0}, \frac{\partial \ell}{\partial \beta_1}, \dots, \frac{\partial \ell}{\partial \beta_p}, \frac{\partial \ell}{\partial \phi} \right)^\top$$

- Ela pode ser particionada como $\mathbf{U}(\boldsymbol{\beta}, \phi) = \left(\mathbf{U}_\beta^\top, U_\phi \right)^\top$, onde

$$\mathbf{U}_\beta = \left(\frac{\partial \ell}{\partial \beta_0}, \frac{\partial \ell}{\partial \beta_1}, \dots, \frac{\partial \ell}{\partial \beta_p} \right)^\top \quad \text{e} \quad U_\phi = \frac{\partial \ell}{\partial \phi}$$

- Assim, para obter $\mathbf{U}(\boldsymbol{\beta}, \phi)$, obtemos separadamente $\mathbf{U}_\beta$ e U_ϕ .

Função escore

- As derivadas em $\mathbf{U}_\beta$ são

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n \phi^{-1} \sqrt{\frac{w_i}{V_i}} (y_i - \mu_i) x_{ij}, \quad \text{com} \quad w_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V_i} \quad \text{e} \quad V_i = V(\mu_i)$$

- A derivada em U_ϕ é

$$U_\phi = \frac{\partial \ell}{\partial \phi} = -\phi^{-2} \left[\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right] + \sum_{i=1}^n \frac{\partial c(y_i, \phi)}{\partial \phi}$$

Função escore

Se definirmos $\mathbf{Y} = (y_1, \dots, y_n)^\top$ o vetor de valores de Y a serem observados e $\mathbf{X}$ a matriz $n \times (p + 1)$ definida como

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix},$$

$\mathbf{U}_\beta$ pode ser escrito, em notação matricial, como

$$\mathbf{U}_\beta = \phi^{-1} \mathbf{X}^\top \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}),$$

onde $\mathbf{W} = \text{diag}\{w_1, \dots, w_n\}$ e $\mathbf{V} = \text{diag}\{V_1, \dots, V_n\}$.

Função escore

- Se a ligação é canônica, então $g(\mu_i) = \eta_i = \theta_i$.
 - Nesse caso, $\frac{\partial \mu_i}{\partial \eta_i} = \frac{\partial \mu_i}{\partial \theta_i} = V(\mu_i) = V_i$.
 - Daí, $w_i = (\partial \mu_i / \partial \eta_i)^2 / V_i = V_i^2 / V_i = V_i$ e

$$\mathbf{W} = \text{diag}\{w_1, \dots, w_n\} = \text{diag}\{V_1, \dots, V_n\} = \mathbf{V}$$

- Ou seja, quando a função de ligação é canônica, a derivada da log-verossimilhança com relação a β_j é

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n \phi^{-1}(y_i - \mu_i) x_{ij}$$

$$\text{e } \mathbf{U}_\beta = \phi^{-1} \mathbf{X}^\top (\mathbf{Y} - \boldsymbol{\mu})$$

Informação de Fisher

- A matriz de informação de Fisher observada, denotada por $\mathbf{J}(\boldsymbol{\beta}, \phi)$, é o negativo da matriz hessiana da log-verossimilhança. Ou seja,

$$\mathbf{J}(\boldsymbol{\beta}, \phi) = - \begin{pmatrix} \frac{\partial^2 \ell}{\partial \beta_0^2} & \frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_1} & \cdots & \frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_p} & \frac{\partial^2 \ell}{\partial \beta_0 \partial \phi} \\ \frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_0} & \frac{\partial^2 \ell}{\partial \beta_1^2} & \cdots & \frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_p} & \frac{\partial^2 \ell}{\partial \beta_1 \partial \phi} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \frac{\partial^2 \ell}{\partial \beta_p \partial \beta_0} & \frac{\partial^2 \ell}{\partial \beta_p \partial \beta_1} & \cdots & \frac{\partial^2 \ell}{\partial \beta_p^2} & \frac{\partial^2 \ell}{\partial \beta_p \partial \phi} \\ \frac{\partial^2 \ell}{\partial \phi \partial \beta_0} & \frac{\partial^2 \ell}{\partial \phi \partial \beta_1} & \cdots & \frac{\partial^2 \ell}{\partial \phi \partial \beta_p} & \frac{\partial^2 \ell}{\partial \phi^2} \end{pmatrix}$$

Informação de Fisher

- As derivadas parciais de $\mathbf{J}(\boldsymbol{\beta}, \phi)$ são

$$\begin{aligned} \frac{\partial^2 \ell}{\partial \beta_j \partial \beta_l} = & \phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) \frac{\partial^2 \theta_i}{\partial \mu_i^2} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 x_{ij} x_{il} + \phi^{-1} \sum_{i=1}^n (Y_i - \mu_i) \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial^2 \mu_i}{\partial \eta_i^2} x_{ij} x_{il} \\ & - \phi^{-1} \sum_{i=1}^n \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \theta_i}{\partial \mu_i} x_{ij} x_{il} \end{aligned}$$

$$\frac{\partial^2 \ell}{\partial \beta_j \partial \phi} = -\phi^{-2} \sum_{i=1}^n \sqrt{\frac{w_i}{V_i}} (y_i - \mu_i) x_{ij}$$

$$\frac{\partial^2 \ell}{\partial \phi^2} = 2\phi^{-3} \left(\sum_{i=1}^n Y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2}$$

Informação de Fisher

- Podemos escrever $\mathbf{J}(\boldsymbol{\beta}, \phi) = \begin{pmatrix} \mathbf{J}_{\beta\beta} & \mathbf{J}_{\beta\phi} \\ \mathbf{J}_{\beta\phi}^\top & \mathbf{J}_{\phi\phi} \end{pmatrix}$ em que

$$\mathbf{J}_{\beta\beta} = - \begin{pmatrix} \frac{\partial^2 \ell}{\partial \beta_0^2} & \frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_1} & \cdots & \frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_p} \\ \frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_0} & \frac{\partial^2 \ell}{\partial \beta_1^2} & \cdots & \frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 \ell}{\partial \beta_p \partial \beta_0} & \frac{\partial^2 \ell}{\partial \beta_p \partial \beta_1} & \cdots & \frac{\partial^2 \ell}{\partial \beta_p^2} \end{pmatrix}$$

$$\begin{aligned} \mathbf{J}_{\beta\phi} &= - \left(\frac{\partial^2 \ell}{\partial \phi \partial \beta_0}, \frac{\partial^2 \ell}{\partial \phi \partial \beta_1}, \dots, \frac{\partial^2 \ell}{\partial \phi \partial \beta_p} \right)^\top \\ &= \phi^{-2} \mathbf{X}^\top \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}) \end{aligned}$$

$$\mathbf{J}_{\phi\phi} = - \frac{\partial^2 \ell}{\partial \phi^2}$$

Informação de Fisher

- A matriz de informação de Fisher esperada, denotada por $\mathbf{K}(\boldsymbol{\beta}, \phi)$, é o valor esperado da matriz de informação de Fisher observada:

$$\mathbf{K}(\boldsymbol{\beta}, \phi) = E[\mathbf{J}(\boldsymbol{\beta}, \phi)] = - \begin{pmatrix} E \left[\frac{\partial^2 \ell}{\partial \beta_0^2} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_1} \right] & \cdots & E \left[\frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_p} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_0 \partial \phi} \right] \\ E \left[\frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_0} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_1^2} \right] & \cdots & E \left[\frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_p} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_1 \partial \phi} \right] \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ E \left[\frac{\partial^2 \ell}{\partial \beta_p \partial \beta_0} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_p \partial \beta_1} \right] & \cdots & E \left[\frac{\partial^2 \ell}{\partial \beta_p^2} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_p \partial \phi} \right] \\ E \left[\frac{\partial^2 \ell}{\partial \phi \partial \beta_0} \right] & E \left[\frac{\partial^2 \ell}{\partial \phi \partial \beta_1} \right] & \cdots & E \left[\frac{\partial^2 \ell}{\partial \phi \partial \beta_p} \right] & E \left[\frac{\partial^2 \ell}{\partial \phi^2} \right] \end{pmatrix}$$

Informação de Fisher

- Os elementos de $\mathbf{K}(\boldsymbol{\beta}, \phi)$ são

$$E \left[\frac{\partial^2 \ell}{\partial \beta_j \partial \beta_l} \right] = -\phi^{-1} \sum_{i=1}^n w_i x_{ij} x_{il}$$

$$E \left[\frac{\partial^2 \ell}{\partial \beta_j \partial \phi} \right] = 0$$

$$E \left[\frac{\partial^2 \ell}{\partial \phi^2} \right] = 2\phi^{-3} \left(\sum_{i=1}^n \mu_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n E \left(\frac{\partial^2 c(Y_i, \phi)}{\partial \phi^2} \right)$$

Informação de Fisher

- Podemos escrever $\mathbf{K}(\boldsymbol{\beta}, \phi) = \begin{pmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\beta\phi}^\top & \mathbf{K}_{\phi\phi} \end{pmatrix}$ em que

$$\mathbf{K}_{\beta\beta} = - \begin{pmatrix} E \left[\frac{\partial^2 \ell}{\partial \beta_0^2} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_1} \right] & \cdots & E \left[\frac{\partial^2 \ell}{\partial \beta_0 \partial \beta_p} \right] \\ E \left[\frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_0} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_1^2} \right] & \cdots & E \left[\frac{\partial^2 \ell}{\partial \beta_1 \partial \beta_p} \right] \\ \vdots & \vdots & \ddots & \vdots \\ E \left[\frac{\partial^2 \ell}{\partial \beta_p \partial \beta_0} \right] & E \left[\frac{\partial^2 \ell}{\partial \beta_p \partial \beta_1} \right] & \cdots & E \left[\frac{\partial^2 \ell}{\partial \beta_p^2} \right] \end{pmatrix} = E[\mathbf{J}_{\beta\beta}]$$

$$\mathbf{K}_{\beta\phi} = - \left(E \left[\frac{\partial^2 \ell}{\partial \phi \partial \beta_0} \right], E \left[\frac{\partial^2 \ell}{\partial \phi \partial \beta_1} \right], \dots, E \left[\frac{\partial^2 \ell}{\partial \phi \partial \beta_p} \right] \right)^\top = E[\mathbf{J}_{\beta\phi}]$$

$$K_{\phi\phi} = -E \left[\frac{\partial^2 \ell}{\partial \phi^2} \right] = E[J_{\phi\phi}]$$

Informação de Fisher

- O termo $\mathbf{K}_{\beta\beta}$ pode ser escrito como $\mathbf{K}_{\beta\beta} = \phi^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{X}$
- Como $E \left[\frac{\partial^2 \ell}{\partial \beta_j \partial \phi} \right] = 0$, podemos escrever $\mathbf{K}_{\beta\phi} = \mathbf{O}_{(p+1) \times 1}$, onde $\mathbf{O}$ é o vetor-coluna de zeros de dimensão $p + 1$.

Assim,

$$\mathbf{K}(\boldsymbol{\beta}, \phi) = \begin{pmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\beta\phi}^\top & K_{\phi\phi} \end{pmatrix} = \begin{pmatrix} \phi^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{X} & \mathbf{O}_{(p+1) \times 1} \\ \mathbf{O}_{1 \times (p+1)} & K_{\phi\phi} \end{pmatrix}$$

Informação de Fisher

- Se a ligação é canônica, então

$$\mathbf{J}_{\beta\phi} = \phi^{-2} \mathbf{X}^{\top} (\mathbf{Y} - \mu)$$

$$\mathbf{K}_{\beta\beta} = \phi^{-1} \mathbf{X}^{\top} \mathbf{V} \mathbf{X}$$

$$\mathbf{J}_{\beta\beta} = \mathbf{K}_{\beta\beta}$$

Exemplo 3.1: regressão de Poisson

Considere um modelo de regressão de Poisson com função de ligação logarítmica, isto é,

$$Y_i \sim \text{Poisson}(\mu_i), \quad \log(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

A distribuição de Y_i pode ser escrita na forma da família exponencial como

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right\}, \text{ em que}$$

$$\theta_i = \log(\mu_i), \quad b(\theta_i) = e^{\theta_i}, \quad \phi = 1, \quad V(\mu_i) = \mu_i.$$

Determine:

- a. μ_i em função de $\boldsymbol{\beta}$.
- b. As matrizes $\mathbf{V}$ e $\mathbf{W}$.
- c. A função escore $U_{\boldsymbol{\beta}}$.
- d. A matriz de informação de Fisher esperada $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$.

Exemplo 3.2: regressão logística

Considere um modelo de regressão logística, isto é,

$$Y_i \sim \text{Bernoulli}(\mu_i), \quad \log\left(\frac{\mu_i}{1 - \mu_i}\right) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

A distribuição de Y_i pode ser escrita na forma da família exponencial como

$$f(y_i; \theta_i, \phi) = \exp\left\{\frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi)\right\}, \text{ em que}$$

$$\theta_i = \log\left(\frac{\mu_i}{1 - \mu_i}\right), \quad b(\theta_i) = \log(1 + e^{\theta_i}), \quad \phi = 1, \quad V(\mu_i) = \mu_i(1 - \mu_i).$$

Determine:

- μ_i em função de $\boldsymbol{\beta}$.
- As matrizes $\mathbf{V}$ e $\mathbf{W}$.
- A função escore $U_{\boldsymbol{\beta}}$.
- A matriz de informação de Fisher esperada $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$.

Estimador de Máxima Verossimilhança

- Os estimadores de máxima verossimilhança $\hat{\beta}$ e $\hat{\phi}$ são os valores de β e ϕ que maximizam a log-verossimilhança.
- Eles são obtidos como solução de

$$U(\beta, \phi) = 0$$

- Temos então:

$$\begin{cases} U_{\beta} = \phi^{-1} \mathbf{X}^{\top} \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}) = 0 \\ U_{\phi} = -\phi^{-2} \left(\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i) \right) + \sum_{i=1}^n \frac{\partial c(y_i, \phi)}{\partial \phi} = 0 \end{cases}$$

Estimador de Máxima Verossimilhança

- A equação $\mathbf{U}_\beta = 0$ equivale a $\mathbf{X}^\top \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu}) = 0$
- Como $\mathbf{W}$, $\mathbf{V}$ e $\boldsymbol{\mu}$ dependem apenas de β , o EMV de β é encontrado como solução de $\mathbf{U}_\beta = 0$, independentemente de ϕ .
- Assim, $\hat{\beta}$ é obtido como solução de

$$\mathbf{X}^\top \mathbf{W}^{1/2} \mathbf{V}^{-1/2} \boldsymbol{\mu} = \mathbf{X}^\top \mathbf{W}^{1/2} \mathbf{V}^{-1/2} \mathbf{Y}$$

- Quando a ligação é canônica, $\mathbf{W} = \mathbf{V}$.
- Assim, quando a ligação é canônica, $\hat{\beta}$ é solução de

$$\mathbf{X}^\top \boldsymbol{\mu} = \mathbf{X}^\top \mathbf{Y}$$

Estimador de Máxima Verossimilhança

- Agora, o EMV de ϕ , em geral, depende do valor de β .
- Temos que $U_\phi = 0$ equivale a

$$\sum_{i=1}^n y_i \theta_i - \sum_{i=1}^n b(\theta_i) = \phi^2 \sum_{i=1}^n \frac{\partial c(y_i, \phi)}{\partial \phi}$$

- Como $b'(\theta_i) = \mu_i = g^{-1}(\eta_i) = g^{-1}(\mathbf{x}_i^\top \boldsymbol{\beta})$, temos que θ_i depende de $\boldsymbol{\beta}$.
- Ou seja, substitui-se $\boldsymbol{\beta}$ por $\hat{\boldsymbol{\beta}}$ na equação acima para encontrar $\hat{\phi}$.

Estimador de Máxima Verossimilhança

- Os EMVs de η_i e de μ_i são

$$\hat{\eta}_i = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}} \quad \text{e} \quad \hat{\mu}_i = g^{-1}(\eta_i) = g^{-1}(\mathbf{x}_i^\top \hat{\boldsymbol{\beta}})$$

- O EMV de $\boldsymbol{\mu}$ é $\hat{\boldsymbol{\mu}} = (\hat{\mu}_1, \dots, \hat{\mu}_n)^\top$
- Seja $\boldsymbol{\eta}$ o vetor de preditores lineares

$$\boldsymbol{\eta} = (\eta_1, \dots, \eta_n)^\top = (\mathbf{x}_1^\top \boldsymbol{\beta}, \dots, \mathbf{x}_n^\top \boldsymbol{\beta})^\top$$

- Em notação matricial, temos $\boldsymbol{\eta} = \mathbf{X}\boldsymbol{\beta}$.
- O EMV de $\boldsymbol{\eta}$ é $\hat{\boldsymbol{\eta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$
- Quando ϕ é conhecido (exemplo: distribuição de Poisson e Bernoulli), apenas $\boldsymbol{\beta}$ precisa ser estimado.

Exemplo 3.3

Considere um modelo de regressão Normal com função de ligação identidade, isto é,

$$Y_i \sim N(\mu_i, \phi), \quad \mu_i = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

A distribuição de Y_i pode ser escrita na forma da família exponencial como

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right\},$$

em que

$$\theta_i = \mu_i, \quad b(\theta_i) = \frac{\theta_i^2}{2}, \quad c(y_i, \phi) = -\frac{1}{2} \left[\frac{y_i^2}{\phi} + \log(2\pi\phi) \right] \quad V(\mu_i) = 1.$$

Determine os estimadores de $\boldsymbol{\beta}$ e ϕ .

Exemplo 3.4

Considere um modelo de regressão de Poisson com função de ligação logarítmica, isto é,

$$Y_i \sim \text{Poisson}(\mu_i), \quad \log(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

A distribuição de Y_i pode ser escrita na forma da família exponencial como

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right\},$$

em que

$$\theta_i = \log(\mu_i), \quad b(\theta_i) = e^{\theta_i}, \quad V(\mu_i) = \mu_i, \quad \phi = 1.$$

Determine o estimador de $\boldsymbol{\beta}$ e verifique se ele possui forma fechada.

Exemplo 3.5

Considere um modelo de regressão logística, isto é,

$$Y_i \sim \text{Bernoulli}(\mu_i), \quad \log\left(\frac{\mu_i}{1 - \mu_i}\right) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

A distribuição de Y_i pode ser escrita na forma da família exponencial com

$$\theta_i = \log\left(\frac{\mu_i}{1 - \mu_i}\right), \quad b(\theta_i) = \log(1 + e^{\theta_i}), \quad V(\mu_i) = \mu_i(1 - \mu_i), \quad \phi = 1.$$

Determine o estimador de $\boldsymbol{\beta}$ e verifique se ele possui forma fechada.

O Método de Newton-Raphson

- Na obtenção dos EMVs de β e ϕ nem sempre é possível obter uma solução em forma fechada.
- Nesse caso, buscamos numericamente uma solução da equação

$$U_{\beta}(\beta) = \mathbf{0}.$$

- Um método que pode ser utilizado com essa finalidade é o método de Newton-Raphson.
- O método de Newton-Raphson produz uma sequência de aproximações $\beta^{(0)}, \beta^{(1)}, \dots$ até atingir um critério de convergência.
- Vejamos.

O Método de Newton-Raphson

- Considere o problema de encontrar a solução de $h(x) = 0$.
- A partir de uma aproximação inicial $x^{(0)}$, o método constrói uma sequência de aproximações usando a reta tangente à função

$$x^{(m)} = x^{(m-1)} - \frac{h(x^{(m-1)})}{h'(x^{(m-1)})}$$

- O processo é repetido até que as aproximações sucessivas sejam suficientemente próximas:

$$|x^{(m)} - x^{(m-1)}| < \varepsilon.$$

O Método de Newton-Raphson

- Para obter $\hat{\beta}$, aplica-se o método de Newton-Raphson à equação $U_{\beta}(\beta) = \mathbf{0}$.
- A atualização é dada por $\beta^{(m)} = \beta^{(m-1)} + \mathbf{J}_{\beta\beta}^{-1}(\beta^{(m-1)}) \mathbf{U}_{\beta}(\beta^{(m-1)})$.

Algoritmo

1. Escolha uma aproximação inicial $\beta^{(0)}$.
2. Calcule $\mathbf{U}_{\beta}(\beta^{(m-1)})$ e $\mathbf{J}_{\beta\beta}(\beta^{(m-1)})$.
3. Atualize β : $\beta^{(m)} = \beta^{(m-1)} + \mathbf{J}_{\beta\beta}^{-1} \mathbf{U}_{\beta}$.
4. Repita até que $\|\beta^{(m)} - \beta^{(m-1)}\| < \varepsilon$.

Então, $\hat{\beta} = \beta^{(m)}$.

O Método de Newton-Raphson

- Após obter $\hat{\beta}$, o estimador de máxima verossimilhança de ϕ é obtido resolvendo $U_{\phi}(\phi; \hat{\beta}) = 0$.
- Quando essa equação não possui solução em forma fechada, aplica-se o método de Newton-Raphson:

$$\phi^{(m)} = \phi^{(m-1)} - \frac{U_{\phi}(\phi^{(m-1)}; \hat{\beta})}{U'_{\phi}(\phi^{(m-1)}; \hat{\beta})} = \phi^{(m-1)} + \frac{U_{\phi}(\phi^{(m-1)}; \hat{\beta})}{J_{\phi\phi}(\phi^{(m-1)}; \hat{\beta})}$$

- O processo é repetido até $|\phi^{(m)} - \phi^{(m-1)}| < \varepsilon$. Obtendo-se, então,

$$\hat{\phi} = \phi^{(m)}$$

Método escore de Fisher

- O método escore de Fisher é uma variação do método de Newton-Raphson em que a informação de Fisher observada é substituída pela informação de Fisher esperada.
- Assim, para obter $\hat{\beta}$, $\mathbf{U}_{\beta}(\beta) = \mathbf{0}$ é resolvida iterativamente por

$$\beta^{(m)} = \beta^{(m-1)} + \mathbf{K}_{\beta\beta}^{-1} \mathbf{U}_{\beta},$$

em que $\mathbf{K}_{\beta\beta}$ é a informação de Fisher esperada.

Método escore de Fisher nos MLGs

- No MLG,

$$\mathbf{U}_\beta = \phi^{-1} \mathbf{X}^\top \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu})$$

e

$$\mathbf{K}_{\beta\beta} = \phi^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{X}.$$

- Substituindo na atualização do método escore de Fisher,

$$\boldsymbol{\beta}^{(m)} = \left[\mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{X} \right]^{-1} \mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{z}^{(m-1)}.$$

Método escore de Fisher nos MLGs

- A variável resposta ajustada é definida por

$$\mathbf{z}^{(m-1)} = \boldsymbol{\eta}^{(m-1)} + \left[\mathbf{W}^{(m-1)} \right]^{-1/2} \left[\mathbf{V}^{(m-1)} \right]^{-1/2} \left(\mathbf{Y} - \boldsymbol{\mu}^{(m-1)} \right).$$

- Assim, a cada iteração,

$$\boldsymbol{\beta}^{(m)} = \left(\mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{X} \right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{z}^{(m-1)}.$$

- Ou seja, cada atualização de $\boldsymbol{\beta}$ é obtida por **mínimos quadrados ponderados**.

Algoritmo do método escore de Fisher

1. Escolha uma aproximação inicial $\beta^{(0)}$.
2. Calcule $\eta^{(m-1)} = \mathbf{X}\beta^{(m-1)}$, $\mu^{(m-1)} = g^{-1}(\eta^{(m-1)})$.
3. Calcule $\mathbf{V}^{(m-1)}$, $\mathbf{W}^{(m-1)}$ e $\mathbf{z}^{(m-1)}$.
4. Atualize

$$\beta^{(m)} = \left(\mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{X} \right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m-1)} \mathbf{z}^{(m-1)}.$$

5. Repita até

$$\left\| \beta^{(m)} - \beta^{(m-1)} \right\| < \varepsilon.$$

Newton-Raphson × Escore de Fisher

- A diferença entre os métodos está na matriz utilizada na atualização:

Newton-Raphson $\mathbf{J}_{\beta\beta}$

Escore de Fisher $\mathbf{K}_{\beta\beta} = E[\mathbf{J}_{\beta\beta}]$

- Para uma função de ligação **canônica**, $\mathbf{J}_{\beta\beta} = \mathbf{K}_{\beta\beta}$, e, portanto, os dois métodos produzem a **mesma atualização** para β .

Fim