

Teste da razão de verossimilhanças

Testando a significância global do MLG

ESTAT0092 – Modelos Lineares Generalizados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/mlg>

Composição de um MLG

1. Componente aleatório: A variável resposta Y_i pertence à família exponencial na forma

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right\}.$$

- A média é $\mu_i = E(Y_i) = b'(\theta_i)$.
- A variância é $Var(Y_i) = \phi b''(\theta_i) = \phi V(\mu_i)$.

2. Componente sistemático: $\eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} = \mathbf{x}_i^\top \boldsymbol{\beta}$.

3. Função de ligação: $g(\mu_i) = \eta_i$.

Estimação dos parâmetros

- O vetor de parâmetros $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$ e o parâmetro ϕ são estimados por máxima verossimilhança.
- A função de verossimilhança é *[Math Processing Error]*
- A função de log-verossimilhança é *[Math Processing Error]*
- Os estimadores são obtidos fazendo *[Math Processing Error]*

Função escore

- As derivadas em $\mathbf{U}_\beta$ são $\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n \phi^{-1} \sqrt{\frac{w_i}{V_i}} (y_i - \mu_i) x_{ij}$
 - com *[Math Processing Error]* e $V_i = V(\mu_i)$
 - Notação matricial: $\mathbf{U}_\beta = \phi^{-1} \mathbf{X}^\top \mathbf{W}^{1/2} \mathbf{V}^{-1/2} (\mathbf{Y} - \boldsymbol{\mu})$
 - com $\mathbf{W} = \text{diag}\{w_1, \dots, w_n\}$ e $\mathbf{V} = \text{diag}\{V_1, \dots, V_n\}$
- Enquanto *[Math Processing Error]*

Informação de Fisher (observada)

- *[Math Processing Error]* em que *[Math Processing Error]*

```

\[\small \begin{aligned}
&\boldsymbol{J}_{\boldsymbol{\beta}}\boldsymbol{\phi}=-
\left(\frac{\partial^2\ell}
{\partial\boldsymbol{\phi}\partial\boldsymbol{\beta}_0},\frac{\partial^2\ell}
{\partial\boldsymbol{\phi}\partial\boldsymbol{\beta}_1},\ldots,\frac{\partial^2\ell}
{\partial\boldsymbol{\phi}\partial\boldsymbol{\beta}_p}\right)^{\text{top}}\quad;
\\
&=\boldsymbol{\phi}^{-2}\boldsymbol{X}^{\text{top}}\boldsymbol{W}^{1/2}\boldsymbol{V}^{-1/2}
(\boldsymbol{Y}-\boldsymbol{\mu})\boldsymbol{\boldsymbol{}}\boldsymbol{\boldsymbol{}}[10pt]
&\boldsymbol{J}_{\boldsymbol{\phi}}=- \end{aligned} \]

```


Informação de Fisher (esperada)

- *[Math Processing Error]* em que
 - *[Math Processing Error]*
 - *[Math Processing Error]*
 - $\mathbf{0}$ é o vetor-coluna de zeros de dimensão $p + 1$

Testando o Modelo Globalmente

- Após obter as estimativas de máxima verossimilhança para os parâmetros do modelo, precisamos avaliar se o conjunto de preditores utilizados $(\mathbf{x}_1, \dots, \mathbf{x}_p)$ realmente ajuda a explicar a variável resposta Y .
- A primeira coisa que fazemos é avaliar se o modelo proposto é globalmente superior a um modelo que contém apenas a constante β_0 (intercepto).

Hipóteses do Teste Global

- As hipóteses para a significância global do MLG são: *[Math Processing Error]*

Sob H_0 (modelo nulo)

- $\eta_i = \beta_0 \rightarrow \mu_i = g^{-1}(\beta_0)$
- A média da resposta é constante e não depende das covariáveis.
- O modelo possui apenas 2 parâmetros: β_0 e ϕ .

Sob H_1 (modelo completo)

- $\eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$
- Existe associação entre Y e ao menos uma covariável.
- O modelo possui $p + 2$ parâmetros: $\beta_0, \beta_1, \dots, \beta_p$ e ϕ .

Teste da Razão de Verossimilhanças (LRT)

- O teste avalia a plausibilidade de H_0 comparando o valor máximo da log-verossimilhança do modelo completo com o do modelo nulo.
- Sejam:
 - $\ell(\hat{\beta}, \hat{\phi})$: o máximo da log-verossimilhança sob o modelo completo.
 - $\ell(\hat{\beta}_0^0, \hat{\phi}_0^0)$: o máximo da log-verossimilhança sob o modelo nulo (H_0).
- A estatística da razão de verossimilhanças é dada por: *[Math Processing Error]*
- Quanto maior o valor de T_{RV} , maior é o ganho de ajuste ao incluir as preditoras e maior a evidência contra H_0 .

Teste da Razão de Verossimilhanças (LRT)

- *Distribuição assintótica*: Se n for suficientemente grande, sob H_0 , a estatística T_{RV} segue a distribuição Qui-Quadrado com p graus de liberdade (diferença na quantidade de coeficientes de regressão):

$$T_{RV} \stackrel{\text{aprox.}}{\sim} \chi_p^2$$

- *Regra de decisão*: Rejeita-se H_0 ao nível de significância α se:

$$t_{RV} > \chi_p^2(1 - \alpha) \quad \text{ou se} \quad p\text{-valor} = P(\chi_p^2 > t_{RV}) < \alpha$$

Caso particular: ϕ conhecido

- Se o parâmetro de dispersão ϕ for conhecido (ex: distribuições Poisson e Binomial em que $\phi = 1$), ele não precisa ser estimado.
- O número de parâmetros reduz-se para $p + 1$ no modelo completo e 1 (β_0) no modelo nulo.
- A estatística da razão de verossimilhanças simplifica para: *[Math Processing Error]*
- As propriedades assintóticas e a distribuição χ_p^2 permanecem exatamente as mesmas.

Exemplo 4.1

Regressão Gama (Variável Resposta Contínua Positiva)

- *Dataset*: `trees` (disponível no R base)
- *Descrição*: Dados de 31 cerejeiras-negras, com medições a 4 pés e 6 polegadas (aprox. 1,37 m) acima do solo.
- *Variáveis*:
 - `Girth`: embora *girth* signifique circunferência, é dado o diâmetro da árvore, em polegadas
 - `Height`: altura, em pés
 - `Volume`: volume de madeira, em pés³

Objetivo: Ajustar um MLG com distribuição Gama e ligação logarítmica para modelar o volume de madeira em função da altura e do diâmetro da árvore.

Exemplo 4.1

Testando diretamente as verossimilhanças.

```
# Conjunto de dados
data(trees)

# Ajuste do modelo completo e nulo
mod_gama_completo <- glm(Volume ~ Height + Girth, family = Gamma(link = "log"), data = trees)
mod_gama_nulo <- glm(Volume ~ 1, family = Gamma(link = "log"), data = trees)

# Extração das log-verossimilhanças
( l_gama_completo <- logLik(mod_gama_completo) )

'log Lik.' -71.50404 (df=4)

( l_gama_nulo <- logLik(mod_gama_nulo) )

'log Lik.' -125.7405 (df=2)

# Estatística TRV
( T_rv <- as.numeric(2 * (l_gama_completo - l_gama_nulo)) )

[1] 108.4729

# Cálculo do p-valor via distribuição Qui-Quadrado (df = p = 2)
( p_valor <- pchisq(T_rv, df = 2, lower.tail = FALSE) )

[1] 2.78873e-24
```


Exemplo 4.1

Usando uma função nativa do R:

```
# Teste da razão de verossimilhanças usando a função
# lrtest do pacote lmtxt
lmtest::lrtest(mod_gama_completo, mod_gama_nulo)
```

Likelihood ratio test

Model 1: Volume ~ Height + Girth

Model 2: Volume ~ 1

	#Df	LogLik	Df	Chisq	Pr(>Chisq)
1	4	-71.504			
2	2	-125.740	-2	108.47	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
# p-valor exato
lmtest::lrtest(mod_gama_completo, mod_gama_nulo)$`Pr(>Chisq)`[2]
```

[1] 2.78873e-24

Exemplo 4.2

Regressão Logística (Variável Resposta Binária)

- *Dataset:* `birthwt` (pacote MASS)
- *Descrição:* O conjunto possui 189 linhas e 10 colunas. Os dados foram coletados no Baystate Medical Center, Springfield, Massachusetts, em 1986.
- *Variáveis:*
 - `low`: Indicador de peso ao nascer inferior a 2,5 kg.
 - `lwt`: Peso da mãe, em libras, no momento da última menstruação.
 - `smoke`: Status de tabagismo durante a gravidez.

Objetivo: Ajustar um MLG com distribuição Binomial e ligação logit para modelar a probabilidade de um bebê nascer com baixo peso (`low`) em função do peso da mãe (`lwt`) e hábito de fumar (`smoke`).

Exemplo 4.3

Regressão de Poisson (Contagem)

- *Dataset:* `warpbreaks` (disponível no R base)
- *Descrição:* O conjunto de dados apresenta o número de rompimentos dos fios de urdidura por tear, em que um tear corresponde a um comprimento fixo de fio.
- *Variáveis:*
 - `breaks`: Número de rompimentos
 - `wool`: Tipo de lã (A ou B)
 - `tension`: Nível de tensão (L, M, H)

Objetivo: Ajustar um MLG com distribuição de Poisson e ligação log para modelar o número de quebras de fios (`breaks`) em função do tipo de lã (`wool`) e da tensão (`tension`).

Exemplo 4.4

Regressão Logística (Variável Resposta Binária)

- *Dataset:* `Pima.tr` (pacote MASS)
- *Descrição:* Dados de mulheres com pelo menos 21 anos de idade, de ascendência indígena Pima e residentes próximo a Phoenix, Arizona, testadas para diabetes de acordo com os critérios da Organização Mundial da Saúde (OMS).
- *Variáveis:*
 - `type`: `Yes` (Sim) ou `No` (Não), para diabética segundo os critérios da OMS.
 - `glu`: Concentração de glicose no plasma em um teste oral de tolerância à glicose.
 - `bmi`: Índice de massa corporal (peso em kg / (altura em m)²).
 - `age`: Idade em anos.

Objetivo: Ajustar um modelo de regressão logística para testar a presença de diabetes (`type`) em função da glicose (`glu`), IMC (`bmi`) e idade (`age`).

Próximos Passos

- H_0 foi rejeitada?
 - Concluímos que ao menos uma variável preditora é importante para o modelo.
- Pergunta seguinte:
 - *Quais* variáveis individualmente possuem efeito estatisticamente significativo sobre a resposta?
- Próxima Aula:
 - Avaliação da significância individual dos coeficientes de regressão via **Teste de Wald e Intervalos de Confiança**.

Fim