

O Modelo Normal Linear

Fundamentos e Diagnóstico

ESTAT0092 – Modelos Lineares Generalizados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/mlg>

Canais de Comunicação e Materiais da Disciplina

- Site: <http://sadraquelucena.github.io/mlg>
- Grupo no WhatsApp: <http://tiny.cc/mlg262>



Informações da disciplina

- **Componente curricular:** ESTAT0092 – Modelos Lineares Generalizados
- **Período:** 6º semestre
- **Carga horária:** 60 horas (4 créditos)
- **Horário:**
 - Quartas - 20h45 às 22h15
 - Sextas - 19h00 às 20h30
- **Docente:** Prof. Dr. Sadraque E. F. Lucena

Objetivo da Disciplina

- **Compreender** as limitações do Modelo Linear Clássico;
- **Dominar** a estrutura teórica da Família Exponencial de distribuições;
- **Estimar** parâmetros via Máxima Verossimilhança e Algoritmo IWLS;
- **Interpretar** coeficientes em diferentes escalas (Logit, Log, Identidade, etc.);
- **Avaliar** a qualidade do ajuste utilizando a *Deviance* e resíduos apropriados;
- **Aplicar** MLGs em problemas reais com dados biológicos, econômicos e sociais, entre outros.

Ementa

- Família exponencial de distribuições.
- Ajuste de modelos.
- Função de ligação.
- Modelos lineares generalizados especiais.
- Estimação.
- A função desvio.
- Testes de hipóteses.
- Análise de dados reais.
- Análise dos resíduos.
- Técnicas de diagnóstico.

Conteúdo Programático

Parte 1. Família Exponencial de Distribuições

A base probabilística dos MLGs

- Definição e forma canônica
- Média, variância e função de variância
- Propriedades teóricas
- Principais membros: Normal, Binomial, Poisson, Gama, Inversa Normal

Conteúdo Programático

Parte 2. Estrutura e Estimação nos MLGs

A mecânica da modelagem generalizada

- Componente aleatório, componente sistemático e função de ligação
- Ligações canônicas vs. não canônicas
- Função de verossimilhança e equações de estimação
- O Algoritmo IWLS (*Iteratively Reweighted Least Squares*)

Conteúdo Programático

Parte 3. Diagnóstico e Avaliação de Ajuste

Como saber se o MLG é adequado?

- Conceito de Modelo Saturado e *Deviance*
- Testes de Razão de Verossimilhança (LRT) e Análise de Deviance (ANODEV)
- Resíduos em MLG: Pearson, Deviance e Quantílicos
- Alavancagem e pontos influentes em MLG

Conteúdo Programático

Parte 4. Aplicações Principais

Modelos para dados reais

- Regressão Logística (respostas binárias e proporções)
- Regressão de Poisson e Binomial Negativa (dados de contagem e superdispersão)
- Modelos Gama e Log-Normal (dados contínuos assimétricos positivos)
- Tópicos avançados e seleção de modelos (AIC/BIC)

Avaliação




- Serão realizadas avaliações contínuas.
- A aprovação requer uma média maior ou igual a 5,0.

Datas Importantes

! Não haverá aula:

- 28/Out/2026: Dia do Servidor Público (recesso acadêmico)
- 20/Nov/2026: Dia Nacional de Zumbi e da Consciência Negra (feriado nacional)
- 25 e 27/Nov/25: XII SEMAC

Bibliografia Recomendada



Regressão Linear

O Modelo Normal Linear

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \varepsilon_i, \quad i = 1, \dots, n$$

em que:

- **Componente Aleatório:** $\varepsilon_i \sim N(0, \sigma^2)$ independentes
- **Média Condicional:** $E(Y_i | X_i) = \mu_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}$
- **Homocedasticidade:** $\text{Var}(\varepsilon_i) = \text{Var}(Y_i | X_i) = \sigma^2$ (constante)
- **Distribuição da Resposta:** $Y_i | X_i \sim N(\mu_i, \sigma^2)$

No MLG: Esta estrutura será flexibilizada. Y_i poderá seguir outras distribuições (Binomial, Poisson, Gama) e a média μ_i será conectada ao preditor linear por uma *função de ligação* $g(\mu_i)$.

Modelo Explicativo ou Preditivo?

Modelo Explicativo

- Interesse nos efeitos causais/associativos das covariáveis;
- Interpretação direta dos coeficientes (β);
- Foco em inferência, testes de hipóteses e ICs;
- Fortemente embasado na teoria do problema.

Modelo Preditivo

- Interesse em prever o valor de novas observações (Y_{novo});
- Foco na capacidade de generalização fora da amostra;
- Validação cruzada e erro quadrático médio de previsão;
- Pode sacrificar a interpretabilidade em favor da acurácia.

Atenção: Os critérios de seleção e avaliação dependem do objetivo! Um modelo com alto R^2 pode ter péssimo desempenho preditivo por *overfitting*.

Antes do Modelo: Conheça os Dados

- A análise estatística rigorosa começa na preparação e limpeza da base.
- **Checklist essencial:**
 - Qual é a variável resposta? Qual é o seu suporte (contínua, contagem, binária)?
 - Qual é a unidade observacional?
 - Quais são as variáveis explicativas e seus tipos?
 - Existem variáveis categóricas (necessidade de codificação em *dummies*)?
 - Existem valores impossíveis, erros de digitação ou duplicações?
 - Existem valores extremos (*outliers*) nas covariáveis e na resposta?
 - Qual o padrão de valores ausentes (*missing values*)?

Tipos de Variáveis e Tratamento de NA

Variáveis Categóricas

- Garantir que estejam codificadas como `factor` no R.
- O R criará automaticamente $k - 1$ variáveis *dummy* para um fator com k níveis, assumindo o primeiro nível como **categoria de referência**.

Valores Ausentes (NA)

- Avaliar o percentual e o mecanismo de ausência.
- **Abordagens:**
 - *Análise de casos completos*: Ok para baixo % de ausências aleatórias.
 - *Imputação simples*: Média/mediana (distorce a variância).
 - *Imputação múltipla (ex: pacote MICE)*: Recomendada quando há padrão de ausência moderado.

Ajuste do Modelo via Mínimos Quadrados e Verossimilhança

Em forma matricial:

$$Y = X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I_n)$$

1. **Mínimos Quadrados Ordinários (MQO):** Minimiza a Soma de Quadrados dos Resíduos $SQR(\beta) = (Y - X\beta)^\top (Y - X\beta)$, resultando em:

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y$$

2. **Máxima Verossimilhança (EMV):** Sob a suposição de Normalidade, o EMV para β é exatamente idêntico ao estimador de MQO.

Da Soma de Quadrados ao Conceito de Desvio

- A qualidade do ajuste no modelo normal é mensurada pela **Soma de Quadrados dos Resíduos (SQR)**:

$$SQR = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Estimador da Variância dos Erros (σ^2):

$$\hat{\sigma}^2 = \frac{SQR}{n - p - 1}$$

Nos MLGs, a SQR é generalizada pelo conceito de **Desvio (*Deviance*)**, medida baseada na verossimilhança que compara o modelo ajustado ao *modelo saturado*.

Matriz de Covariância dos Estimadores e Erros-Padrão

- Como $\hat{\beta} = (X^\top X)^{-1} X^\top Y$ é uma combinação linear de Y , sua matriz de variância-covariância é dada por:

$$\text{Var}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$$

- O erro-padrão do coeficiente $\hat{\beta}_j$, denotado por $SE(\hat{\beta}_j)$, é a raiz quadrada do j -ésimo elemento da diagonal de $\hat{\sigma}^2 (X^\top X)^{-1}$.
- Teste t de Wald para significância individual:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \implies t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t_{n-p-1}$$

Avaliação Global do Modelo

Medida	Fórmula / Definição	Pergunta / Interpretação
R^2	$1 - \frac{SQR}{SQT}$	Quanto da variabilidade observada de Y é explicada pelas covariáveis?
$R^2_{ajustado}$	$1 - \left[\frac{(1-R^2)(n-1)}{n-p-1} \right]$	O ganho de explicação compensa a penalização pelo número de parâmetros?
Teste F Global	$\frac{SQE/p}{SQR/(n-p-1)}$	O conjunto de regressores melhora o ajuste em relação ao modelo apenas com intercepto?

Avaliação Global do Modelo

Medida	Fórmula / Definição	Pergunta / Interpretação
AIC	$2k - 2 \ln(\hat{L})$	Qual modelo oferece melhor compromisso entre ajuste e complexidade?
BIC	$k \ln(n) - 2 \ln(\hat{L})$	Qual modelo é preferível quando aplicamos penalização mais severa para amostras grandes?

Comparação de Modelos Aninhados: O Teste F

Para comparar um **Modelo Reduzido** (R) com g parâmetros contra um **Modelo Completo** (F) com p parâmetros ($p > g$, com $q = p - g$ restrições):

$$H_0 : \beta_{g+1} = \cdots = \beta_p = 0$$

- Calculamos a estatística F parcial:

$$F = \frac{(SQR_R - SQR_F)/q}{SQR_F/(n - p - 1)} \sim F_{q, n-p-1}$$

Conexão com MLG: Nos MLGs, a comparação de modelos aninhados é feita de forma análoga substituindo o Teste F pelo **Teste de Razão de Verossimilhança (LRT)** baseado na diferença de *Deviances*.

Interpretação Prática dos Coeficientes (β)

1. Variável Contínua (X_j)

- Mantendo as demais variáveis constantes, o aumento de 1 unidade em X_j está associado a uma variação média de $\hat{\beta}_j$ unidades em Y .

2. Variável Categórica (Dummies)

- Se $X_{\text{sul}} = 1$ e a referência é o Norte: $\hat{\beta}_{\text{sul}}$ é a **diferença média** na resposta Y do grupo Sul em relação ao grupo Norte.

3. Variável de Interação ($X_1 \cdot X_2$)

- O efeito marginal de X_1 sobre Y depende do nível de X_2 :

$$\frac{\partial Y}{\partial X_1} = \hat{\beta}_1 + \hat{\beta}_{12}X_2$$

Interpretação em Escala Logarítmica

Quando aplicamos a transformação $\ln(Y) = \beta_0 + \beta_1 X_1 + \varepsilon$:

$$\hat{Y} = e^{\hat{\beta}_0 + \hat{\beta}_1 X_1}$$

- O coeficiente $\hat{\beta}_1$ representa uma **variação multiplicativa (percentual)** na escala original de Y :

$$\text{Variação \% em } Y \approx 100 \times \hat{\beta}_1 \% \quad (\text{ou exata: } 100 \times (e^{\hat{\beta}_1} - 1)\%)$$

Conexão com MLG: Esta é a exata mecânica da **função de ligação logaritmo** ($\ln(\mu) = X\beta$) empregada nas Regressões de Poisson e Gama!

Incerteza da Estimção: IC da Média vs. IP Individual

Ao realizar predições para um novo perfil de covariáveis x_0 , há duas perguntas diferentes:

	Média	Observação individual
Pergunta	Qual é a média de (Y) para esse perfil?	Qual será o valor de uma nova observação?
Intervalo	Intervalo de confiança	Intervalo de predição
Incerteza	Incerteza na estimação da média	Incerteza da média + variabilidade individual
Variância	$\sigma^2 \cdot x_0^\top (X^\top X)^{-1} x_0 = \sigma^2 \cdot h_{00}$	$\sigma^2 \cdot (1 + h_{00})$
Largura	Mais estreito	Mais amplo

Seleção de Variáveis: Abordagem Clássica

- Procedimento iterativo de construção de modelos:
 1. Avaliar significância individual e global;
 2. Testar remoção de regressores não significativos via Teste F parcial;
 3. Reajustar e reavaliar diagnósticos.
- Métodos Automáticos:
 - *Backward, Forward, Stepwise* (via `stepAIC()` no R).

Alerta Metodológico: A seleção automática não substitui o conhecimento teórico do problema. Variáveis de controle de grande relevância teórica devem ser mantidas no modelo mesmo que o p -valor não seja significativo.

Diagnóstico: Por que Analisar os Resíduos?

- Os resíduos ordinários são definidos por:

$$e_i = Y_i - \hat{Y}_i$$

- As suposições fundamentais do Modelo Normal Linear são:

1. Linearidade e Erro Nulo: $E(\varepsilon_i) = 0$

2. Homocedasticidade: $\text{Var}(\varepsilon_i) = \sigma^2$

3. Independência: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \quad \forall i \neq j$

4. Normalidade: $\varepsilon_i \sim N(0, \sigma^2)$

- A análise de resíduos é a principal ferramenta para checar se tais hipóteses são plausíveis na prática.

Diagnóstico 1: Resíduos × Valores Ajustados (*Residuals vs Fitted*)

Gráfico e_i versus $\hat{Y}_i$. Usado para verificar linearidade e homocedasticidade.

- **O que esperar:** Dispersão aleatória em torno do zero, sem padrão discernível e com amplitude constante.
- **Problemas e Sintomas:**
 - *Formato de funil:* Heterocedasticidade (variância cresce/diminui com a média).
 - *Formato de U ou curvatura:* Não linearidade (falta de termos quadráticos ou interações).
 - *Agrupamentos isolados:* Estrutura não modelada (variável categórica omitida).

Diagnóstico 1: Resíduos $\times$ Valores Ajustados (*Residuals vs Fitted*)




Figura 1

Diagnóstico 1: Resíduos × Valores Ajustados (*Residuals vs Fitted*)

Possíveis Soluções para Inadequações:

- Transformação da variável resposta Y (ex: $\sqrt{Y}$, $\ln(Y)$);
- Transformação de covariáveis ou inclusão de termos de ordem superior (X^2);
- Inclusão de termos de interação ($X_1 \cdot X_2$);
- Modelagem explícita da variância (Mínimos Quadrados Ponderados);
- **Migração para MLG** (ex: se a variância cresce com a média, a distribuição de Poisson ou Gama é mais adequada).

Diagnóstico 2: Q-Q Plot Normal

Gráfico dos quantis amostrais dos resíduos padronizados versus os quantis teóricos da distribuição Normal padrão.

- **O que esperar:** Pontos dispostos perfeitamente sobre a reta de referência de 45 graus.
- **Problemas Detectados:**
 - *Fugas nas pontas (caudas pesadas/leves):* Presença de *outliers* ou distribuição com caudas mais densas que a Normal.
 - *Formato em S (assimetria):* Resíduos com distribuição assimétrica positiva ou negativa.

Diagnóstico 2: Q-Q Plot Normal




Figura 2

Diagnóstico 2: Q-Q Plot Normal

Implicações e Soluções:

- Checar erros de digitação na base de dados;
- Avaliar a necessidade de transformação de Y ;
- Testar modelos alternativos apropriados para dados assimétricos;
- **Lembrar:** O Teorema Central do Limite garante a consistência assintótica das estimativas em amostras grandes, mas a inferência exata em amostras pequenas depende criticamente da Normalidade.

Diagnóstico 3: Scale-Location

Gráfico da raiz quadrada dos resíduos padronizados $\sqrt{|r_i^*|}$ versus os valores ajustados $\hat{Y}_i$.

- **Objetivo principal:** Avaliar a suposição de homocedasticidade de forma mais clara do que o gráfico clássico de resíduos.
- **O que esperar:** Linha suave (*lowess*) aproximadamente horizontal, com pontos espalhados aleatoriamente ao seu redor.
- **Sintoma de Violação:** Linha com inclinação acentuada indicando variação sistemática na dispersão do erro ao longo dos valores preditos.
- **Possíveis soluções:** As mesmas do Diagnóstico 1.

Diagnóstico 3: Scale-Location




Figura 3

Diagnóstico 4: Residuals vs Leverage e Matriz Chapéu (H)

Gráfico projetado para identificar pontos influentes que combinam alto *leverage* com resíduos elevados.

A Matriz Chapéu (*Hat Matrix* H)

A projeção que transforma observações em valores ajustados:

$$\hat{Y} = X\hat{\beta} = X(X^\top X)^{-1}X^\top Y = HY$$

- Os elementos da diagonal principal $h_{ii} = H_{ii}$ são os valores de **alavancagem** (*leverage*).
- Propriamente, $0 \leq h_{ii} \leq 1$ e $\sum h_{ii} = p + 1$.
- Avalia o quão distante a observação i está do centro do espaço das covariáveis X .

Alavancagem, Distância de Cook e Influência

Distância de Cook (D_i)

Avalia o impacto global no vetor de parâmetros $\hat{\beta}$ caso a observação i seja removida do ajuste:

$$D_i = \frac{r_i^{*2}}{p + 1} \left(\frac{h_{ii}}{1 - h_{ii}} \right)$$

onde r_i^* é o resíduo studentizado.

- **Responde a Pergunta:** Quanto o ajuste do modelo mudaria sem essa observação?

Alavancagem, Distância de Cook e Influência

Distância de Cook (D_i)

Situação	Nível de Resíduo	Nível de Leverage (h_{ii})	Diagnóstico / Ação
Caso A	Pequeno	Baixo	Observação típica e pouco preocupante
Caso B	Pequeno	Alto	Alto potencial de influência, mas ajusta-se bem
Caso C	Grande	Baixo	Possível <i>outlier</i> em Y
Caso D	Grande	Alto	Ponto Influyente Crítico (Alta D_i)

Gestão de Pontos Influentes

Quando identificar uma observação com alta Distância de Cook:

1. Investigar a origem:

- Erro de digitação ou medição? → *Corrigir*.
- Observação pertencente a outra população? → *Remover com justificativa*.
- Observação legítima de um evento raro? → *NÃO remover sumariamente*.

2. Regra de Ouro: Nunca exclua um ponto de dados legítimo apenas porque ele é influente ou ajusta-se mal ao modelo Normal!

Análise de Sensibilidade

Se o ponto influente for um dado legítimo, realize uma **Análise de Sensibilidade** (ajuste do modelo com e sem o ponto):

O que comparar:

- Alterações nos coeficientes $\hat{\beta}$;
- Erros-padrão e alteração de significância estatística;
- Mudanças nos intervalos de confiança;
- Alterações nas previsões e conclusões substantivas.

Como reportar:

- Apresente o modelo principal ajustado com **todos os dados**;
- Apresente em tabela comparativa o modelo sem as observações influentes;
- **Conclusões inalteradas:** O resultado é robusto.
- **Conclusões alteradas:** O resultado é sensível, e essa limitação deve ser explicitada.

Multicolinearidade e VIF

A multicolinearidade ocorre quando duas ou mais variáveis explicativas possuem forte correlação linear.

- **Consequência:** Inflação catastrófica das variâncias dos estimadores $\text{Var}(\hat{\beta}_j)$, tornando os coeficientes instáveis e imprecisos.
- **Fator de Inflação da Variância (VIF):**

$$VIF_j = \frac{1}{1 - R_j^2}$$

onde R_j^2 é o coeficiente de determinação da regressão de X_j contra todas as demais covariáveis.

- **Regra Prática:** $VIF_j > 5$ requer atenção; $VIF_j > 10$ indica multicolinearidade severa.

Do Modelo Normal aos MLGs

No Modelo Linear Normal:

$$Y_i \sim N(\mu_i, \sigma^2), \quad \mu_i = X_i \beta$$

Nos Modelos Lineares Generalizados (MLG):

$$Y_i \sim \text{Distribuição da Família Exponencial}(\mu_i, \phi)$$

$$g(\mu_i) = X_i \beta$$

em que $g(\cdot)$ é uma **função de ligação** diferenciável e monótona.

Do Modelo Normal aos MLGs

Exemplos de Estruturas de Modelagem:

Tipo de Resposta (Y)	Distribuição Típica	Função de Ligação Canônica	Equação do Modelo
Contínua Simétrica	Normal	Identidade	$\mu_i = X_i \beta$
Binária / Proporção	Binomial	Logit	$\ln\left(\frac{\mu_i}{1-\mu_i}\right) = X_i \beta$
Contagem (Taxa)	Poisson	Logaritmo	$\ln(\mu_i) = X_i \beta$
Contínua Assimétrica (+)	Gama	Inversa	$\frac{1}{\mu_i} = X_i \beta$

Projeto da Próxima Aula

Objetivo

Selecionar uma base de dados real e realizar uma análise completa e rigorosa aplicando o Modelo Normal Linear.

Requisitos Mínimos da Base de Dados

- Variável resposta quantitativa contínua;
- Pelo menos 3 variáveis explicativas;
- Pelo menos 1 variável categórica (fator);
- Tamanho amostral razoável ($n \geq 50$);
- **Dados reais** (não utilizar bases prontas didáticas como `mtcars` ou `iris`).

Projeto da Próxima Aula

O relatório deverá conter as seções:

1. **Introdução e Descrição dos Dados:** Contexto e dicionário de variáveis.
2. **Análise Exploratória:** Distribuição da resposta e relações bivariadas.
3. **Especificação e Ajuste:** Formulação do modelo inicial.
4. **Seleção de Modelos:** Comparação via $R^2_{ajustado}$, Teste F parcial e AIC/BIC.
5. **Diagnóstico Completo:** Avaliação dos 4 gráficos clássicos de resíduos e VIF.
6. **Análise de Influência e Sensibilidade:** Verificação de pontos influentes via D_i .
7. **Interpretação do Modelo:** Discussão prática dos coeficientes e previsões.
8. **Código Utilizado:** Apresentação do código usado para análise dos dados.

Fim