

Avaliação dos coeficientes individuais da regressão

Teste de Wald e intervalos de confiança

ESTAT0092 – Modelos Lineares Generalizados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/mlg>

Introdução

- Na aula anterior, utilizamos o **Teste da Razão de Verossimilhanças (TRV)** para avaliar a significância global dos coeficientes de regressão, comparando o modelo completo com o modelo nulo.
- O teste global avalia as hipóteses:

$$\begin{cases} H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \\ H_1 : \beta_j \neq 0, \quad \text{para pelo menos um } j. \end{cases}$$

- Quando H_0 é rejeitada no TRV, concluímos que *pelo menos um dos coeficientes associados às variáveis preditoras é diferente de zero.*
 - Ou seja, *pelo menos uma das variáveis preditoras é importante para o modelo.*
- Isso leva a pergunta: *Quais coeficientes são diferentes de zero?*
 - Isto é, *quais variáveis individualmente possuem efeito estatisticamente significativo sobre a resposta?*

Teste de Wald para a significância individual

- Seja Y a variável resposta e sejam $x_1, \dots, x_p$ as variáveis preditoras.
- Supõe-se que a relação entre Y e as preditoras seja descrita por um MLG:

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} = \mathbf{x}_i^\top \boldsymbol{\beta},$$

com

$$g(\mu_i) = \eta_i, \quad \mu_i = E(Y_i).$$

- O vetor de coeficientes é

$$\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top.$$

- **Objetivo:** avaliar, para cada j , se o coeficiente β_j é estatisticamente diferente de zero.

Hipóteses do teste

- Para avaliar a significância individual de β_j , consideramos

$$\begin{cases} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{cases}$$

- Sob H_0 , a variável preditora x_j não está associada à resposta por meio do coeficiente β_j .
- Se H_0 for rejeitada, há evidência estatística de que $\beta_j \neq 0$.
- Para testarmos essas hipóteses precisamos da distribuição de probabilidade de $\hat{\beta}_j$. Para isso usaremos resultados assintóticos.

Distribuição assintótica dos estimadores

- Sejam $\hat{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ e $\hat{\phi}$ os estimadores de máxima verossimilhança.
- Para n suficientemente grande, os estimadores de máxima verossimilhança têm distribuição normal assintótica:

$$\hat{\beta} \stackrel{a}{\sim} N_{p+1} \left(\beta, \mathbf{K}_{\beta\beta}^{-1} \right)$$

- Portanto, para cada $j = 0, \dots, p$,

$$\hat{\beta}_j \stackrel{a}{\sim} N \left(\beta_j, \text{Var}(\hat{\beta}_j) \right),$$

em que $\text{Var}(\hat{\beta}_j) = \left[\mathbf{K}_{\beta\beta}^{-1} \right]_{j+1, j+1}$

Estatística do teste de Wald

- Como $\hat{\beta}_j \stackrel{a}{\sim} N\left(\beta_j, Var(\hat{\beta}_j)\right)$, temos que

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{Var(\hat{\beta}_j)}} \stackrel{a}{\sim} N(0, 1).$$

- Soba a hipótese nula $H_0 : \beta_j = 0$, temos que a estatística

$$W_j = \frac{\hat{\beta}_j}{\sqrt{Var(\hat{\beta}_j)}} = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \stackrel{a}{\sim} N(0, 1)$$

para n suficientemente grande.

- $SE(\hat{\beta}_j) = \sqrt{Var(\hat{\beta}_j)}$ é o erro padrão do estimador $\hat{\beta}_j$.

Interpretação da estatística de Wald

- A estatística de Wald W_j expressa o coeficiente estimado em *unidades do seu erro-padrão*.
- Isso significa que:
 - $W_j \approx 0$: $\hat{\beta}_j$ está próximo de zero em relação à sua incerteza;
 - $|W_j|$ grande: $\hat{\beta}_j$ está distante de zero em relação ao seu erro-padrão.
- Assim, **quanto maior $|W_j|$, maior a evidência contra H_0** .
 - Isto é, maior a evidência de que o preditor x_j está associado à variável resposta.

Regra de decisão no teste de Wald

- Como $W_j \stackrel{a}{\sim} N(0, 1)$ sob H_0 , para um teste bilateral de nível α , rejeitamos H_0 se

$$|W_j| > z_{1-\alpha/2}.$$

- Equivalentemente, rejeitamos H_0 se

$$p\text{-valor} = 2P(Z > |w_j|) < \alpha, \quad Z \sim N(0, 1).$$

- **Observação:** No `summary()` do R, a referência utilizada para o p -valor depende da dispersão. Quando a dispersão é conhecida ou fixada, utiliza-se a Normal padrão; quando é estimada (modelos Poisson e Binomial), utiliza-se a distribuição t de Student com $n - p$ graus de liberdade.

Intervalo de confiança para β_j

- A mesma distribuição assintótica utilizada no teste de Wald permite construir um intervalo de confiança para β_j .
- Como

$$\frac{\hat{\beta}_j - \beta_j}{SE(\hat{\beta}_j)} \underset{approx.}{\sim} N(0, 1),$$

temos

$$IC_{1-\alpha}(\beta_j) = \hat{\beta}_j \pm z_{1-\alpha/2} SE(\hat{\beta}_j)$$

- Ou, equivalentemente,

$$\left(\hat{\beta}_j - z_{1-\alpha/2} SE(\hat{\beta}_j), \hat{\beta}_j + z_{1-\alpha/2} SE(\hat{\beta}_j) \right).$$

Teste de Wald e intervalo de confiança

- Para um teste bilateral de nível α , a hipótese

$$H_0 : \beta_j = 0$$

é rejeitada quando

$$0 \notin IC_{1-\alpha}(\beta_j).$$

- De forma equivalente,

$$p - \text{valor} < \alpha.$$

- Portanto, o teste de Wald e o intervalo de confiança são duas formas de utilizar a mesma aproximação normal assintótica.

Exemplo 5.1

Regressão Gama (Variável Resposta Contínua Positiva)

- *Dataset:* `trees` (R base)
- *Descrição:* 31 cerejeiras-negras, com medições realizadas a 1,37 m do solo.
- *Variáveis:*
 - `Girth`: diâmetro da árvore, em polegadas
 - `Height`: altura, em pés
 - `Volume`: volume de madeira, em pés³

Modelo: MLG Gama com ligação logarítmica, tendo `Volume` como resposta e `Girth` e `Height` como preditoras.

Objetivo: O teste da razão de verossimilhanças indicou significância global do modelo ($p < 0,05$). Agora, avalie a significância individual dos coeficientes por meio do teste de Wald, ao nível de 5%.

Exemplo 5.1

Teste de avaliação global do modelo:

```
# Ajuste do modelo completo e nulo
mod_gama_completo <- glm(Volume ~ Height + Girth, family = Gamma(link = "log"), data = trees)
mod_gama_nulo <- glm(Volume ~ 1, family = Gamma(link = "log"), data = trees)

# Teste da razão de verossimilhanças (avaliação global do modelo)
lmtest::lrtest(mod_gama_completo, mod_gama_nulo) # p-valor < 0.05 => ao menos um  $\beta$  é  $\neq$  de zero
```

Likelihood ratio test

Model 1: Volume ~ Height + Girth

Model 2: Volume ~ 1

	#Df	LogLik	Df	Chisq	Pr(>Chisq)
1	4	-71.504			
2	2	-125.740	-2	108.47	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Exemplo 5.1

```
# Estimativas dos coeficientes
( beta_hat <- coef(mod_gama_completo) )
```

```
(Intercept)      Height      Girth
  0.09230458  0.01657788  0.14528119
```

```
# Erros-padrão dos estimadores
( se_beta_hat <- sqrt(diag(vcov(mod_gama_completo))) )
```

```
(Intercept)      Height      Girth
0.215867640 0.003252454 0.006603923
```

```
# Estatísticas de Wald
( W <- beta_hat / se_beta_hat )
```

```
(Intercept)      Height      Girth
  0.427598      5.097039  21.999226
```

```
# Graus de liberdade residuais
( gl <- df.residual(mod_gama_completo) )
```

```
[1] 28
```

```
# p-valores do teste bilateral (na Gama o R usa a distribuição t com n-p graus de liberdade)
( p_valor <- 2 * pt(abs(W), df = gl, lower.tail = FALSE) )
```

```
(Intercept)      Height      Girth
6.722145e-01 2.127078e-05 3.286253e-19
```

Exemplo 5.1

```
# Resultado do teste de Wald
resultado_wald <- data.frame(Estimativa = beta_hat, SE = se_beta_hat, Wald = W, p.valor = p_valor)
resultado_wald
```

	Estimativa	SE	Wald	p.valor
(Intercept)	0.09230458	0.215867640	0.427598	6.722145e-01
Height	0.01657788	0.003252454	5.097039	2.127078e-05
Girth	0.14528119	0.006603923	21.999226	3.286253e-19

```
# Saída nativa do R
summary(mod_gama_completo)
```

Call:

```
glm(formula = Volume ~ Height + Girth, family = Gamma(link = "log"),
     data = trees)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.092305	0.215868	0.428	0.672
Height	0.016578	0.003252	5.097	2.13e-05 ***
Girth	0.145281	0.006604	21.999	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Gamma family taken to be 0.009410213)

Null deviance: 8.31720 on 30 degrees of freedom
Residual deviance: 0.26247 on 28 degrees of freedom
AIC: 151.01

Number of Fisher Scoring iterations: 4

Exemplo 5.1

```
# Intervalos de confiança de 95%  
confint.default(mod_gama_completo)
```

	2.5 %	97.5 %
(Intercept)	-0.33078822	0.51539738
Height	0.01020319	0.02295258
Girth	0.13233774	0.15822464

Exemplo 5.1

- Forma de apresentação dos resultados em uma tabela:

Tabela 5.1. Estimativas dos coeficientes do modelo de regressão Gama para o volume de madeira das cerejeiras-negras

Variável	$\hat{\beta}$	EP	Wald	p-valor	IC 95%
Intercepto	0,0923	0,2159	0,428	0,672	[−0,3308; 0,5134]
Height	0,0166	0,0033	5,097	<0,001	[0,0099; 0,0233]
Girth	0,1453	0,0066	21,999	<0,001	[0,1318; 0,1588]

Nota: Variável resposta: Volume (pés³). Modelo: regressão Gama com função de ligação logarítmica. $n = 31$. Os p -valores e intervalos de confiança foram obtidos utilizando a distribuição t de Student com 28 graus de liberdade.

Exemplo 5.2

Regressão Logística (Variável Resposta Binária)

- *Dataset:* `birthwt` (pacote MASS)
- *Descrição:* Dados de bebês nascidos no Baystate Medical Center, Springfield, Massachusetts, em 1986.
- *Variáveis:*
 - `low`: Indicador de peso ao nascer inferior a 2,5 kg.
 - `lwt`: Peso da mãe, em libras, no momento da última menstruação.
 - `smoke`: Status de tabagismo durante a gravidez.

Modelo: MLG Binomial com ligação logit, tendo `low` como resposta e `lwt` e `smoke` como preditoras.

Objetivo: O teste da razão de verossimilhanças indicou significância global do modelo ($p < 0,05$).

Agora, avalie a significância individual dos coeficientes por meio do teste de Wald, ao nível de 5%.

Exemplo 5.2

Teste de avaliação global do modelo:

```
# Ajuste do modelo completo e nulo
mod_logit_completo <- glm(low ~ lwt + smoke, family = binomial(link = "logit"),
                          data = MASS::birthwt)
mod_logit_nulo <- glm(low ~ 1, family = binomial(link = "logit"), data = MASS::birthwt)

# Teste da razão de verossimilhanças (avaliação global do modelo)
lmtest::lrtest(mod_logit_completo, mod_logit_nulo) # p-valor < 0.05 => ao menos um  $\beta$  é  $\neq$  de zero
```

Likelihood ratio test

Model 1: low ~ lwt + smoke

Model 2: low ~ 1

	#Df	LogLik	Df	Chisq	Pr(>Chisq)
1	3	-112.17			
2	1	-117.34	-2	10.331	0.005709 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Exemplo 5.2

```
# Estimativas dos coeficientes
( beta_hat <- coef(mod_logit_completo) )
```

```
(Intercept)          lwt          smoke
  0.62199682 -0.01332433  0.67667325
```

```
# Erros-padrão dos estimadores
( se_beta_hat <- sqrt(diag(vcov(mod_logit_completo))) )
```

```
(Intercept)          lwt          smoke
0.795916457 0.006089569 0.324698629
```

```
# Estatísticas de Wald
( W <- beta_hat / se_beta_hat )
```

```
(Intercept)          lwt          smoke
  0.7814851  -2.1880574   2.0840040
```

```
# p-valores do teste bilateral (na binomial o R a distribuição normal)
( p_valor <- 2 * pnorm(abs(W), lower.tail = FALSE) )
```

```
(Intercept)          lwt          smoke
0.43451726  0.02866542  0.03715980
```

Exemplo 5.2

```
# Resultado do teste de Wald
resultado_wald <- data.frame(Estimativa = beta_hat, SE = se_beta_hat, Wald = W, p.valor = p_valor)
resultado_wald
```

	Estimativa	SE	Wald	p.valor
(Intercept)	0.62199682	0.795916457	0.7814851	0.43451726
lwt	-0.01332433	0.006089569	-2.1880574	0.02866542
smoke	0.67667325	0.324698629	2.0840040	0.03715980

```
# Saída nativa do R
summary(mod_logit_completo)
```

Call:

```
glm(formula = low ~ lwt + smoke, family = binomial(link = "logit"),
     data = MASS::birthwt)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.62200	0.79592	0.781	0.4345
lwt	-0.01332	0.00609	-2.188	0.0287 *
smoke	0.67667	0.32470	2.084	0.0372 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 234.67 on 188 degrees of freedom
Residual deviance: 224.34 on 186 degrees of freedom
AIC: 230.34

Number of Fisher Scoring iterations: 4

Exemplo 5.2

```
# Intervalos de confiança de 95%  
confint.default(mod_logit_completo)
```

	2.5 %	97.5 %
(Intercept)	-0.93797077	2.181964412
lwt	-0.02525966	-0.001388991
smoke	0.04027563	1.313070865

Exemplo 5.2

- Forma de apresentação dos resultados em uma tabela:

Tabela 5.2. Estimativas dos coeficientes do modelo de regressão logística para o baixo peso ao nascer

Variável	$\hat{\beta}$	EP	Wald	p-valor	IC 95%
Intercepto	0,6120	0,7959	0,781	0,4345	[−0,9379; 2,1820]
lwt	−0,0133	0,0061	−2,188	0,0287	[−0,0253; −0,0014]
smoke	0,6767	0,3247	2,084	0,0372	[0,0403; 1,3131]

Nota: Variável resposta: baixo peso ao nascer. Modelo: regressão logística (família Binomial com função de ligação logit). $n = 189$. Os p -valores e intervalos de confiança foram obtidos utilizando a distribuição Normal padrão.

Interpretação dos coeficientes de regressão

- No MLG,

$$g(\mu_i) = \eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip},$$

onde $\mu_i = E(Y_i)$.

- Assim, o coeficiente β_j representa a variação no preditor linear (ou seja, no valor transformado $g(\mu)$) para cada aumento de uma unidade em x_j , mantendo as demais variáveis constantes.
- Isto implica que a interpretação de β_j depende da função de ligação utilizada no modelo.

Função de ligação identidade

- Se $g(\mu) = \mu$, então

$$\mu = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

- Nesse caso, β_j representa a variação esperada na média da resposta se aumentarmos uma unidade em x_j , mantendo as demais preditoras constantes.
 - $\beta_j > 0$: um aumento de uma unidade em x_j está associado a um aumento de β_j unidades na média da resposta.
 - $\beta_j < 0$: um aumento de uma unidade em x_j está associado a uma redução de $|\beta_j|$ unidades na média da resposta.
- **Exemplo:** $\hat{\mu} = 10 + 2x_1 - 0,5x_2$
 - aumento de uma unidade em $x_1 \rightarrow$ aumento de 2 unidades na média de Y .
 - aumento de uma unidade em $x_2 \rightarrow$ redução de 0,5 unidade na média de Y .

Função de ligação logarítmica

- Se $g(\mu) = \log(\mu)$, então

$$\log(\mu) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

- Aplicando a função exponencial para voltar à escala original da resposta:

$$\mu = e^{\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p} = e^{\beta_0} e^{\beta_1 x_1} \cdots e^{\beta_p x_p}$$

- Aqui a média varia multiplicativamente com os preditores.
- Se x_j aumenta uma unidade:

$$\mu(x_j + 1) = e^{\beta_0} e^{\beta_1 x_1} \cdots e^{\beta_j (x_j + 1)} \cdots e^{\beta_p x_p} = \underbrace{e^{\beta_0} e^{\beta_1 x_1} \cdots e^{\beta_j x_j} \cdots e^{\beta_p x_p}}_{\mu(x_j)} \cdot e^{\beta_j} = \mu(x_j) \cdot e^{\beta_j}$$

- Portanto, o aumento de uma unidade em x_j multiplica a média da resposta por e^{β_j} , mantidas as demais preditoras constantes.

Função de ligação logarítmica

- Exemplo: $\log(\mu) = 1 + 0,095x_1 - 0,223x_2 + 1,200x_3$
 - $e^{0,095} = 1,10$
 - aumento de uma unidade em $x_1 \Rightarrow$ média de Y é multiplicada por 1,10 (aumento de 10%).
 - $e^{-0,223} = 0,80$
 - aumento de uma unidade em $x_2 \Rightarrow$ média de Y é multiplicada por 0,80 ($1 - 0,80 = 0,20$, redução de 20%).
 - $e^{1,200} = 3,32$
 - aumento de uma unidade em $x_3 \Rightarrow$ média de Y é multiplicada por 3,32 ($3,32 - 1 = 2,32$, aumento de 232%).

Função de ligação logit

- Na regressão logística a função de ligação é $g(\mu) = \log\left(\frac{\mu}{1-\mu}\right)$, com $\mu = P(Y = 1)$. Assim,

$$\log\left(\frac{\mu}{1-\mu}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

- Vamos definir $odds(\mu) = \frac{\mu}{1-\mu}$ razão entre a *chance* (*odds*) do evento ocorrer sobre não ocorrer. Assim,

$$\log(odds) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

- Aplicando a função exponencial:

$$odds = e^{\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p} = e^{\beta_0} e^{\beta_1 x_1} \cdots e^{\beta_p x_p}$$

Função de ligação logit

- Se x_j aumenta uma unidade:

$$\begin{aligned} odds(x_j + 1) &= e^{\beta_0} e^{\beta_1 x_1} \dots e^{\beta_j (x_j + 1)} \dots e^{\beta_p x_p} \\ &= \underbrace{e^{\beta_0} e^{\beta_1 x_1} \dots e^{\beta_j x_j} \dots e^{\beta_p x_p}}_{odds(x_j)} \cdot e^{\beta_j} = odds(x_j) \cdot e^{\beta_j} \end{aligned}$$

- Dividindo ambos os lados, obtemos a **razão de chances (odds ratio – OR)**:

$$OR = \frac{odds(x_j + 1)}{odds(x_j)} = \frac{odds(x_j) e^{\beta_j}}{odds(x_j)} = e^{\beta_j}$$

- Portanto, e^{β_j} indica quantas vezes a chance do evento ocorrer aumenta para cada aumento de uma unidade em x_j , mantendo as demais variáveis constantes.

Função de ligação logit

- Exemplo: $\log\left(\frac{\mu}{1-\mu}\right) = 1 + 1,335x_1 - 0,357x_2 + 0,140x_3$
 - $OR = e^{1,335} = 3,80$
 - aumento de uma unidade em $x_1 \Rightarrow$ aumenta em 3,8 vezes a chance do evento ocorrer.
 - $OR = e^{-0,357} = 0,70$
 - aumento de uma unidade em $x_2 \Rightarrow$ reduz a chance do evento ocorrer em 30% ($1 - 0,70 = 0,30$).
 - $OR = e^{0,140} = 1,15$
 - aumento de uma unidade em $x_3 \Rightarrow$ aumenta em 15% a chance do evento ocorrer.

Interpretação dos coeficientes segundo a função de ligação

Função de ligação	Modelo na escala transformada	Interpretação de β_j
Identidade	$\mu = \eta$	Variação de β_j unidades na média de Y para +1 unidade em x_j
Log	$\log(\mu) = \eta$	A média é multiplicada por e^{β_j} para +1 unidade em x_j
Logit	$\log(\text{odds}) = \eta$	As chances são multiplicadas por e^{β_j} para +1 unidade em x_j

Exemplo 5.3

Agora vamos interpretar os coeficientes do modelo obtido no Exemplo 5.1 (regressão gama com função de ligação log).

Variável	$\hat{\beta}$	EP	Wald	p-valor	IC 95%
Intercepto	0,0923	0,2159	0,428	0,672	[−0,3308; 0,5134]
Height	0,0166	0,0033	5,097	<0,001	[0,0099; 0,0233]
Girth	0,1453	0,0066	21,999	<0,001	[0,1318; 0,1588]

- **Height:** $e^{0,0166} = 1,0167 \Rightarrow$ cada aumento de 1 pé na altura está associado a um aumento de 1,67% no volume médio da árvore.
- **Girth:** $e^{0,1453} = 1,1564 \Rightarrow$ cada aumento de 1 polegada no diâmetro está associado a um aumento de 15,64% no volume médio da árvore.

Exemplo 5.4

Agora vamos interpretar os coeficientes do modelo obtido no Exemplo 5.2 (regressão logística).

Variável	$\hat{\beta}$	EP	Wald	p-valor	IC 95%
Intercepto	0,6120	0,7959	0,781	0,4345	[-0,9379; 2,1820]
lwt	-0,0133	0,0061	-2,188	0,0287	[-0,0253; -0,0014]
smoke	0,6767	0,3247	2,084	0,0372	[0,0403; 1,3131]

- **lwt**: $OR = e^{-0,0133} = 0,9868 \Rightarrow$ cada 1 libra a mais no peso da mãe reduz a chance de baixo peso em 1,32% ($1 - 0,9868 = 0,0132$).
- **smoke**: $OR = e^{0,6767} = 1,967 \Rightarrow$ mães fumantes têm uma chance de ter bebê com baixo peso quase duas vezes maior ($1,97\times$) do que mães não fumantes.

Exemplo 5.5

Utilizando o banco de dados `birthwt` do pacote `MASS` (variável resposta `low`):

- a. Ajuste o modelo completo com todas as variáveis.
- b. Execute o teste de razão de verossimilhanças global (comparando o modelo completo com o modelo nulo).
- c. Faça a seleção de variáveis via Teste de Wald (removendo as não significativas uma a uma).
- d. Valide o descarte via TRV parcial (comparando o modelo reduzido com o completo).
- e. Interprete os $e^{\hat{\beta}}$ apenas do modelo final reduzido.

Considere um nível de significância de 0,05.

Próximos Passos

- H_0 foi rejeitada?
 - Concluímos que ao menos uma variável preditora é importante para o modelo.
- Pergunta seguinte:
 - *Quais* variáveis individualmente possuem efeito estatisticamente significativo sobre a resposta?
- Próxima Aula:
 - Avaliação da significância individual dos coeficientes de regressão via **Teste de Wald e Intervalos de Confiança**.

Fim