

Seleção de Variáveis e Construção do Modelo

Como decidir quais variáveis devem fazer parte de um Modelo Linear Generalizado?

ESTAT0092 – Modelos Lineares Generalizados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/mlg>

O problema da especificação

Considere um MLG com resposta Y e p variáveis preditoras:

$$g(\mu_i) = \eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$$

- A inclusão de uma variável no modelo deve ser justificada por razões *científicas, estatísticas* ou *práticas*. Entre os principais aspectos, consideramos:
 - Relevância conhecida no fenômeno estudado
 - Estrutura de associação entre os preditoras (multicolinearidade)
 - Evidência estatística de associação com a resposta
 - Parcimônia
- A seguir veremos ferramentas estatísticas para construção de um MLG. No entanto, precisamos ter em mente o seguinte:
 - Primeiro pensamos no modelo que faz sentido; depois usamos ferramentas estatísticas para avaliar e aperfeiçoar esse modelo.

Exemplo de especificação orientada pela teoria

- Suponha que queremos modelar a **probabilidade de inadimplência** de um cliente.
- **Variáveis disponíveis:** renda, dívida, idade, histórico de inadimplência, número de empréstimos, tempo de relacionamento e taxa de juros.
- A teoria de **risco de crédito** sugere que a capacidade de pagamento e o histórico financeiro devem estar relacionados à inadimplência.
- Por exemplo, a capacidade de pagamento pode ser representada pela **razão dívida/renda**:

$$X_i = \frac{\text{Dívida}_i}{\text{Renda}_i}.$$

- Assim, podemos especificar:

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 X_i + \beta_2 \text{Inadimplência prévia}_i + \beta_3 \text{Idade}_i.$$

Modelos candidatos

- Em algumas situações, não existe uma especificação determinada pela teoria.
- Se temos p variáveis candidatas $(x_1, \dots, x_p)$, cada variável pode *entrar ou não* no modelo.
- Com $p = 3$ preditoras (x_1, x_2, x_3) temos $2^3 = 8$ submodelos possíveis:

$$M_0 : \eta = \beta_0$$

$$M_1 : \eta = \beta_0 + \beta_1 x_1$$

$$M_2 : \eta = \beta_0 + \beta_2 x_2$$

$$M_3 : \eta = \beta_0 + \beta_3 x_3$$

$$M_{12} : \eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

$$M_{13} : \eta = \beta_0 + \beta_1 x_1 + \beta_3 x_3$$

$$M_{23} : \eta = \beta_0 + \beta_2 x_2 + \beta_3 x_3$$

$$M_{123} : \eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3.$$

- Precisamos de uma estratégia para explorar e comparar esses modelos.

Como comparar modelos?

- Não existe um único critério universal para definir o modelo mais adequado. Podemos considerar:
 - **Critério do p -valor:** utilizar testes de hipóteses para avaliar a contribuição das variáveis ao modelo.
 - Aqui mantemos apenas as variáveis com $p\text{-valor} < \alpha$.
 - **Critério de Informação de Akaike (AIC):** equilibra qualidade do ajuste e complexidade do modelo.

$$AIC = -2\ell(\hat{\beta}) + 2k,$$

- em que $\ell(\hat{\beta})$ é a log-verossimilhança maximizada e k é o número de parâmetros estimados.
 - Regra de comparação: **menor AIC $\implies$ melhor modelo.**
- **Critério científico:** considera a teoria, o conhecimento substantivo e o objetivo da análise.

Estratégias de busca

- Diferentes estratégias podem ser utilizadas para explorar os modelos possíveis:
 - **Busca exaustiva:** Ajusta todos os subconjuntos possíveis 2^p .
 - **Forward:** Começa com um modelo simples e adiciona variáveis.
 - **Backward:** Começa com um modelo completo e remove variáveis.
 - **Stepwise:** Permite adicionar e remover variáveis durante a busca.
- É importante entender que

Estratégia de busca $\neq$ critério de comparação

- **Exemplo:** Podemos usar backward para explorar os modelos e AIC para decidir entre eles.

O procedimento na prática

- **1. Especificar o modelo inicial**
 - Definir as variáveis candidatas.
- **2. Escolher uma estratégia de busca**
 - Busca exaustiva, forward, backward ou stepwise.
- **3. Definir o critério de comparação**
 - AIC e/ou p-valor.
- **4. Comparar os modelos candidatos**
 - Considerar ajuste, complexidade e o critério de comparação escolhido.
- **5. Avaliar o modelo escolhido**
 - Diagnóstico dos resíduos, observações influentes, forma funcional e adequação das demais especificações.
- **6. Reespecificar, se necessário**

Exemplo 6.1

Considere o banco de dados `birthwt`, disponível no pacote `MASS`. Construa um modelo de regressão logística capaz de explicar a probabilidade de baixo peso ao nascer usando todos os preditores disponível no conjunto de dados.

Exemplo 6.1

Primeiro vamos organizar e traduzir o conjunto de dados.

```
library(MASS)

dados <- birthwt |>
  # remover bwt (peso de cada bebê)
  dplyr::select(-bwt) |>
  # codificar como fator as preditoras categóricas e renomear as demais
  dplyr::mutate(
    baixo_peso = low,
    idade = age,
    peso_mae = lwt,
    raca = factor(race, levels = c(1, 2, 3), labels = c("Branca", "Negra", "Outra")),
    fumante = factor(smoke, levels = c(0, 1), labels = c("Não", "Sim")),
    partos_prematuros = ptl,
    hipertensao = factor(ht, levels = c(0, 1), labels = c("Não", "Sim")),
    irritabilidade_uterina = factor(ui, levels = c(0, 1), labels = c("Não", "Sim")),
    consultas_pre_natal = ftv
  )
```

Exemplo 6.1

Ajustando o modelo completo e verificando se ao menos uma variável é importante no modelo.

```
# Modelo completo
modelo_completo <- glm(baixo_peso ~ idade + peso_mae + partos_prematuros +
  consultas_pre_natal + raca + fumante + hipertensao + irritabilidade_uterina,
  family = binomial(link = "logit"), data = dados)

# modelo nulo
modelo_nulo <- glm(baixo_peso ~ 1 , family = binomial(link = "logit"), data = dados)

# Teste da razão de verossimilhanças
lmtest::lrtest(modelo_completo, modelo_nulo)
```

Likelihood ratio test

Model 1: baixo_peso ~ idade + peso_mae + partos_prematuros + consultas_pre_natal +
raca + fumante + hipertensao + irritabilidade_uterina

Model 2: baixo_peso ~ 1

	#Df	LogLik	Df	Chisq	Pr(>Chisq)	
1	10	-100.64				
2	1	-117.34	-9	33.387	0.0001143	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Exemplo 6.1

Teste individual das preditoras.

```
summary(modelo_completo)
```

Call:

```
glm(formula = baixo_peso ~ idade + peso_mae + partos_prematuros +  
    consultas_pre_natal + raca + fumante + hipertensao + irritabilidade_uterina,  
    family = binomial(link = "logit"), data = dados)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	0.480623	1.196888	0.402	0.68801	
idade	-0.029549	0.037031	-0.798	0.42489	
peso_mae	-0.015424	0.006919	-2.229	0.02580	*
partos_prematuros	0.543337	0.345403	1.573	0.11571	
consultas_pre_natal	0.065302	0.172394	0.379	0.70484	
racaNegra	1.272260	0.527357	2.413	0.01584	*
racaOutra	0.880496	0.440778	1.998	0.04576	*
fumanteSim	0.938846	0.402147	2.335	0.01957	*
hipertensaoSim	1.863303	0.697533	2.671	0.00756	**
irritabilidade_uterinaSim	0.767648	0.459318	1.671	0.09467	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 234.67 on 188 degrees of freedom
Residual deviance: 201.28 on 179 degrees of freedom
AIC: 221.28

Number of Fisher Scoring iterations: 4

Exemplo 6.1

Stepwise removeu as preditoras `idade` e `consultas_pre_natal`. Agora pela regra do p-valor, podemos remover `partos_prematuros`.

```
modelo2 <- glm(baixo_peso ~ peso_mae + raca + fumante + hipertensao + irritabilidade_uterina,
  family = binomial(link = "logit"), data = dados)
summary(modelo2)
```

Call:

```
glm(formula = baixo_peso ~ peso_mae + raca + fumante + hipertensao +
  irritabilidade_uterina, family = binomial(link = "logit"),
  data = dados)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	0.056276	0.937853	0.060	0.95215	
peso_mae	-0.016732	0.006803	-2.459	0.01392	*
racaNegra	1.324562	0.521464	2.540	0.01108	*
racaOutra	0.926197	0.430386	2.152	0.03140	*
fumanteSim	1.035831	0.392558	2.639	0.00832	**
hipertensaoSim	1.871416	0.690902	2.709	0.00676	**
irritabilidade_uterinaSim	0.904974	0.447553	2.022	0.04317	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 234.67 on 188 degrees of freedom
Residual deviance: 204.22 on 182 degrees of freedom
AIC: 218.22

Number of Fisher Scoring iterations: 4

Exemplo 6.1

Podemos retirar cada variável uma a uma em ordem de maior p -valor. Podemos também fazer seleção via stepwise.

```
modelo_AIC <- step(modelo_completo, trace = 0) # `trace = 0` não imprime saídas na tela
summary(modelo_AIC)
```

Call:

```
glm(formula = baixo_peso ~ peso_mae + partos_prematuros + raca +
     fumante + hipertensao + irritabilidade_uterina, family = binomial(link = "logit"),
     data = dados)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-0.086550	0.951760	-0.091	0.92754	
peso_mae	-0.015905	0.006855	-2.320	0.02033	*
partos_prematuros	0.503215	0.341231	1.475	0.14029	
racaNegra	1.325719	0.522243	2.539	0.01113	*
racaOutra	0.897078	0.433881	2.068	0.03868	*
fumanteSim	0.938727	0.398717	2.354	0.01855	*
hipertensaoSim	1.855042	0.695118	2.669	0.00762	**
irritabilidade_uterinaSim	0.785698	0.456441	1.721	0.08519	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 234.67 on 188 degrees of freedom

Residual deviance: 201.99 on 181 degrees of freedom

AIC: 217.99

Number of Fisher Scoring iterations: 4

Exemplo 6.1

Como todas as variáveis são significativas ao nível de 5%, vamos fazer o teste da razão de verossimilhança para comparar o modelo completo com o modelo reduzido (`modelo2`).

```
lmtest::lrtest(modelo_completo, modelo2)
```

Likelihood ratio test

Model 1: baixo_peso ~ idade + peso_mae + partos_prematuros + consultas_pre_natal +
 raca + fumante + hipertensao + irritabilidade_uterina

Model 2: baixo_peso ~ peso_mae + raca + fumante + hipertensao + irritabilidade_uterina

	#Df	LogLik	Df	Chisq	Pr(>Chisq)
1	10	-100.64			
2	7	-102.11	-3	2.9318	0.4023

- O teste está indicando que usar o modelo reduzido é equivalente a usar o modelo completo, não vamos usar o modelo reduzido.

Exemplo 6.1

Unificando os resultados interessantes para nós.

```
coeficientes <- summary(modelo2)$coefficients

ic <- confint(modelo2)

resultado <- data.frame(
  Variável = rownames(coeficientes),
  Estimativa = round(coeficientes[, "Estimate"], 3),
  Erro_padrao = round(coeficientes[, "Std. Error"], 3),
  OR = round(exp(coeficientes[, "Estimate"]), 3),
  OR_IC_inf = round(exp(ic[, 1]), 3),
  OR_IC_sup = round(exp(ic[, 2]), 3),
  p_valor = round(coeficientes[, "Pr(>|z|)"], 4),
  row.names = NULL
)
```

Exemplo 6.1

Unificando os resultados interessantes para nós.

resultado

	Variável	Estimativa	Erro_padrao	OR	OR_IC_inf	OR_IC_sup
1	(Intercept)	0.056	0.938	1.058	0.177	7.097
2	peso_mae	-0.017	0.007	0.983	0.970	0.996
3	racaNegra	1.325	0.521	3.761	1.356	10.658
4	racaOutra	0.926	0.430	2.525	1.101	6.013
5	fumanteSim	1.036	0.393	2.817	1.324	6.228
6	hipertensaoSim	1.871	0.691	6.497	1.735	27.486
7	irritabilidade_uterinaSim	0.905	0.448	2.472	1.022	5.984
p_valor						
1	0.9522					
2	0.0139					
3	0.0111					
4	0.0314					
5	0.0083					
6	0.0068					
7	0.0432					

Exemplo 6.1

Interpretação dos *odds ratio*:

Variável	OR	Interpretação
<code>peso_mae</code>	0,983	A cada aumento de 1 libra no peso da mãe, as chances de baixo peso ao nascer são multiplicadas por 0,983, isto é, diminuem aproximadamente 1,7% .
<code>racaNegra</code>	3,761	As chances de baixo peso ao nascer são aproximadamente 3,76 vezes maiores para mães classificadas como negras do que para mães brancas.
<code>racaOutra</code>	2,525	As chances de baixo peso ao nascer são aproximadamente 2,52 vezes maiores para mães da categoria “Outra” do que para mães brancas.

Exemplo 6.1

Interpretação dos *odds ratio*:

Variável	OR	Interpretação
fumanteSim	2,817	As chances de baixo peso ao nascer são aproximadamente 2,82 vezes maiores para mães fumantes do que para mães não fumantes.
hipertensaoSim	6,497	As chances de baixo peso ao nascer são aproximadamente 6,50 vezes maiores para mães com hipertensão do que para mães sem hipertensão.
irritabilidade_uterinaSim	2,472	As chances de baixo peso ao nascer são aproximadamente 2,47 vezes maiores para mães com irritabilidade uterina do que para mães sem irritabilidade uterina.

Exemplo 6.2

Utilize o conjunto de dados *Default of Credit Card Clients*, disponível no Kaggle (<https://www.kaggle.com/datasets/uciml/default-of-credit-card-clients-dataset>), que contém informações demográficas, características do crédito e histórico de pagamentos de clientes de cartão de crédito. A variável `default.payment.next.month` indica se o cliente apresentou inadimplência no mês seguinte (`1 = sim`, `0 = não`).

- **Variável resposta:** `default.payment.next.month`
- **Variáveis preditoras:** `LIMIT_BAL`, `SEX`, `EDUCATION`, `MARRIAGE`, `AGE`, `PAY_0`, `PAY_2`, `BILL_AMT1`, `BILL_AMT2` e `PAY_AMT1`.

Construa o modelo completo, realize a seleção de variáveis e interprete os coeficientes das variáveis preditoras do modelo final.

Fim