

Variáveis qualitativas e variáveis *dummy*

Como representar categorias no preditor linear dos MLGs

ESTAT0092 – Modelos Lineares Generalizados

Prof. Dr. Sadraque E. F. Lucena

<http://sadraquelucena.github.io/mlg>

O problema da especificação

Em um MLG, temos

$$g(\mu_i) = \eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}.$$

- Cada componente que entra em η_i precisa possuir uma representação numérica coerente com a estrutura do modelo.
- Como se dá a representação de uma variável qualitativa\$
 - Se a variável *Possui imóvel próprio* (x) foi codificada como
 - $x = 1$ (sim)
 - $x = 2$ (não)

não podemos interpretar os códigos 1 e 2 como uma escala quantitativa.

Dummy: a ideia

- Uma variável *dummy* assume apenas os valores **0** ou **1**.
- Ela representa a presença de uma categoria em relação a uma categoria de referência.

$$x = \begin{cases} 0, & \text{referência} \\ 1, & \text{categoria de interesse} \end{cases}$$

- Isso permite adicionar uma variável qualitativa no preditor linear de forma interpretável.
- No modelo: $\eta = \beta_0 + \beta_1 (\text{possui imóvel próprio})$
 - Se a referência é **não**, temos:
 - Não possui imóvel próprio (**possui imóvel próprio = 0**): $\eta = \beta_0$
 - Possui imóvel próprio (**possui imóvel próprio = 1**): $\eta = \beta_0 + \beta_1$
 - β_1 representa o impacto na resposta em relação à categoria de referência.

k categorias $\rightarrow k - 1$ dummies

- Se x possui k categorias, definimos uma como referência e criamos $k - 1$ dummies.
- Por quê?
 - Se criarmos k dummies, temos a seguinte restrição linear exata:

$$x_1 + x_2 + \cdots + x_k = 1$$

- Essa soma gera multicolinearidade perfeita entre as colunas da matriz de dados ao considerar o intercepto (β_0), tornando impossível estimar os parâmetros de forma única.

Exemplo com 3 categorias

- Considere a variável $X \in \{A, B, C\}$ com A como categoria de referência:

$$x_B = \begin{cases} 1, \text{ se } X = B \\ 0, \text{ caso contrário} \end{cases} \quad \text{e} \quad x_C = \begin{cases} 1, \text{ se } X = C \\ 0, \text{ caso contrário} \end{cases}$$

- Modelo: $\eta = \beta_0 + \beta_B x_B + \beta_C x_C$

Categoria (x)	x_B	x_C	Preditor Linear (η)
A (Referência)	0	0	$\eta_A = \beta_0$
B	1	0	$\eta_B = \beta_0 + \beta_B$
C	0	1	$\eta_C = \beta_0 + \beta_C$

- β_B e β_C representam o impacto na resposta causado pela mudança da categoria A para as categorias B e C , respectivamente.

Impacto da Função de Ligação

1. Ligação Identidade ($\mu = \eta$)

- Comparações diretas na escala original:

$$\mu(x = 1) - \mu(x = 0) = \beta_1 \implies \boxed{\beta_i = \text{diferença entre as médias}}$$

- **Exemplo:** $\hat{\beta}_1 = 4,2 \rightarrow$ O grupo *sem imóvel próprio* apresenta média estimada 4,2 unidades superior ao grupo *com imóvel próprio*, mantendo as demais covariáveis constantes.

Impacto da Função de Ligação

2. Ligação Log ($\log(\mu) = \eta$)

- Comparações relativas (multiplicativas): *[Math Processing Error]*

$$\frac{\mu_1}{\mu_0} = e^{\beta_1} = \text{Razão de Médias}$$

- **Exemplo:** $\hat{\beta}_1 = 0,3 \Rightarrow e^{\hat{\beta}_1} = e^{0,3} = 1,35 \rightarrow$ A média esperada do grupo *sem imóvel próprio* é 1,35 vezes a média do grupo *com imóvel próprio* (ou seja, 35% maior), mantendo constantes as demais covariáveis.

Impacto da Função de Ligação

3. Ligação Logit (*[Math Processing Error]*)

- Comparações em termos de chance (*odds*): *[Math Processing Error]*

$$\frac{\text{odds}_1}{\text{odds}_0} = e^{\beta_1} = \text{Razão de Chances (Odds Ratio)}$$

- **Exemplo:** $\hat{\beta}_1 = 0,693 \Rightarrow e^{\hat{\beta}_1} = e^{0,693} = 2,0 \rightarrow$ A chance (*odds*) de ocorrer o desfecho no grupo *sem imóvel próprio* é 2 vezes a chance do grupo *com imóvel próprio* (100% maior), mantendo constantes as demais covariáveis.

Modelo com Interação (Duas Variáveis Binárias)

- O termo de interação permite que o efeito de uma variável dependa do nível de outra:

$$\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12}(x_1 x_2)$$

- O produto $(x_1 x_2)$ assume valor 1 apenas quando $x_1 = 1$ e $x_2 = 1$ *simultaneamente* (zero nos demais casos).
- A combinação das duas variáveis binárias gera 4 cenários no preditor linear:

x_1	x_2	Termo de interação $(x_1 x_2)$	Preditor Linear (η)
0	0	0	$\eta_{00} = \beta_0$
1	0	0	$\eta_{10} = \beta_0 + \beta_1$
0	1	0	$\eta_{01} = \beta_0 + \beta_2$
1	1	1	$\eta_{11} = \beta_0 + \beta_1 + \beta_2 + \beta_{12}$

Interpretação do Coeficiente de Interação (β_{12})

- $\beta_{12} = 0$: Não há interação (efeitos são puramente aditivos).
- $\beta_{12} > 0$: O efeito de x_2 é potencializado (mais forte) quando $x_1 = 1$.
- $\beta_{12} < 0$: O efeito de x_2 é atenuado (mais fraco) quando $x_1 = 1$.

Exemplo

Avaliar impacto do Ensino Superior (x_1) e do Gênero (x_2) no Salário (η em mil R\$). - $x_1: 0 =$ sem superior, $1 =$ com superior - $x_2: 0 =$ homem, $1 =$ mulher

$$\text{Salário} = 3 + 2x_1 + 1x_2 + 1,5(x_1x_2)$$

- Calculando o efeito do Ensino Superior (x_1) no Salário:
 - Para Homens ($x_2 = 0$):
 - Sem superior: 3 ○ Com superior: $3 + 2 = 5$
 - Aumento: $+R\$2.000 (\beta_1)$
 - Para Mulheres ($x_2 = 1$):
 - Sem superior: $3 + 1 = 4$ ○ Com Superior: $3 + 2 + 1 + 1,5 = 7,5$
 - Aumento: $+R\$ 3.500 (\beta_1 + \beta_{12})$
- *Interpretação de $\beta_{12} = 1,5$* : O retorno financeiro do diploma superior é $R\$1.500$ MAIOR para mulheres do que para homens.

Tratamento Automatizado de Fatores no R

No R, não é necessário criar as variáveis *dummies* manualmente. A função `factor()` faz a gestão automaticamente.

```
# 1. Converter para fator e definir rótulos
dados$raca_f <- factor(
  dados$raca,
  levels = c(1, 2, 3),
  labels = c("Branca", "Negra", "Outra")
)

# 2. Definir explicitamente a categoria de referência
dados$raca_f <- relevel(dados$raca_f, ref = "Branca")

# 3. Ajustar o modelo (o R cria k-1 dummies internamente)
modelo <- glm(
  low ~ lwt + smoke_f + raca_f,
  family = binomial(link = "logit"),
  data = dados
)
```

Exemplo 7.1

Vamos modelar a precificação de apólices de automóveis com base na frequência esperada de sinistros por segurado no 3º trimestre de 1973. Vamos usar os dados da base *Insurance* do pacote *MASS* no R.

As variáveis disponíveis na base de dados são:

- *Claims* (Y): Número total de sinistros registrados no período (contagem).
- *Holders* (N): Número de apólices ativas/segurados expostos ao risco.
- *District*: Região de residência do segurado (1 a 4, sendo 4 grandes centros urbanos).
- *Group*: Cilindrada do motor do veículo (<1 litre, 1–1.5 litre, 1.5–2 litre, >2 litre).
- *Age*: Faixa etária do segurado (<25, 25–29, 30–35, >35).

Exemplo 7.1

```
# Carregar o pacote e os dados
library(MASS)
data("Insurance")

# Visualizar a taxa bruta de sinistros por faixa etária e grupo do veículo
Insurance$taxa_bruta <- Insurance$Claims / Insurance$Holders
aggregate(taxa_bruta ~ Age + Group, data = Insurance, FUN = mean)
```

	Age	Group	taxa_bruta
1	<25	<1l	0.1736435
2	25-29	<1l	0.1428666
3	30-35	<1l	0.1098389
4	>35	<1l	0.1009060
5	<25	1-1.5l	0.2010255
6	25-29	1-1.5l	0.1494878
7	30-35	1-1.5l	0.1448283
8	>35	1-1.5l	0.1214083
9	<25	1.5-2l	0.2415224
10	25-29	1.5-2l	0.2169381
11	30-35	1.5-2l	0.2046406
12	>35	1.5-2l	0.1499988
13	<25	>2l	0.2599206
14	25-29	>2l	0.2524967
15	30-35	>2l	0.2161581
16	>35	>2l	0.1938611

Exemplo 7.1

```
Insurance$Group <- factor(Insurance$Group, ordered = FALSE)
Insurance$Age    <- factor(Insurance$Age, ordered = FALSE)

# Ajustar o Modelo de Poisson COM Interação e Offset
# offset(log(Holders)) controlando o modelo pelo tamanho desigual da base de clientes em cada grupo
modelo_seguro <- glm(
  Claims ~ District + Group * Age + offset(log(Holders)),
  family = poisson(link = "log"),
  data = Insurance
)

summary(modelo_seguro)
```

Exemplo 7.1

Call:

```
glm(formula = Claims ~ District + Group * Age + offset(log(Holders)),
     family = poisson(link = "log"), data = Insurance)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.64140	0.12316	-13.327	< 2e-16	***
District2	0.02572	0.04302	0.598	0.549921	
District3	0.03845	0.05052	0.761	0.446575	
District4	0.23481	0.06168	3.807	0.000141	***
Group1-1.5l	0.02029	0.15637	0.130	0.896769	
Group1.5-2l	-0.04510	0.19149	-0.236	0.813808	
Group>2l	0.24824	0.32532	0.763	0.445423	
Age25-29	-0.37201	0.17093	-2.176	0.029527	*
Age30-35	-0.63222	0.18112	-3.491	0.000482	***
Age>35	-0.73049	0.13357	-5.469	4.52e-08	***
Group1-1.5l:Age25-29	0.10134	0.21131	0.480	0.631529	
Group1.5-2l:Age25-29	0.48865	0.24293	2.011	0.044275	*
Group>2l:Age25-29	0.33929	0.38015	0.893	0.372118	
Group1-1.5l:Age30-35	0.20376	0.21768	0.936	0.349250	
Group1.5-2l:Age30-35	0.67270	0.24710	2.722	0.006482	**
Group>2l:Age30-35	0.35735	0.38075	0.939	0.347965	
Group1-1.5l:Age>35	0.16667	0.16841	0.990	0.322339	

```
Group1.5-21:Age>35      0.43137      0.20349      2.120 0.034015 *
Group>21:Age>35          0.34770      0.33723      1.031 0.302513
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

(Dispersion parameter for poisson family taken to be 1)

```
Null deviance: 236.259  on 63  degrees of freedom
Residual deviance:  40.907  on 45  degrees of freedom
AIC: 396.23
```

Number of Fisher Scoring iterations: 4

Exemplo 7.1

```
# Comparando o modelo sem interação vs com interação (TRV)
modelo_sem_int <- glm(
  Claims ~ District + Group + Age + offset(log(Holders)),
  family = poisson(link = "log"),
  data = Insurance
)

lmtest::lrtest(modelo_seguro, modelo_sem_int)
```

Likelihood ratio test

Model 1: Claims ~ District + Group * Age + offset(log(Holders))

Model 2: Claims ~ District + Group + Age + offset(log(Holders))

	#Df	LogLik	Df	Chisq	Pr(>Chisq)
1	19	-179.11			
2	10	-184.37	-9	10.513	0.3106

Como os modelos são estatisticamente equivalentes, vamos usar o modelo sem interação.

Exemplo 7.1

```
summary(modelo_sem_int)
```

Call:

```
glm(formula = Claims ~ District + Group + Age + offset(log(Holders)),
     family = poisson(link = "log"), data = Insurance)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.82174	0.07679	-23.724	< 2e-16	***
District2	0.02587	0.04302	0.601	0.547597	
District3	0.03852	0.05051	0.763	0.445657	
District4	0.23421	0.06167	3.798	0.000146	***
Group1-1.5l	0.16134	0.05053	3.193	0.001409	**
Group1.5-2l	0.39281	0.05500	7.142	9.18e-13	***
Group>2l	0.56341	0.07232	7.791	6.65e-15	***
Age25-29	-0.19101	0.08286	-2.305	0.021149	*
Age30-35	-0.34495	0.08137	-4.239	2.24e-05	***
Age>35	-0.53667	0.06996	-7.672	1.70e-14	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 236.26 on 63 degrees of freedom

Residual deviance: 51.42 on 54 degrees of freedom
AIC: 388.74

Number of Fisher Scoring iterations: 4

Exemplo 7.1

A referência é **District1** (região rural/cidades menores), **Group<1l** (carro popular) e **Age<25** (motoristas jovens).

- **District4**: $e^{\beta} = e^{0,23421} = 1,264 \rightarrow$ morar na metrópole (District4) aumenta a taxa de risco em 26,4%.
- **Group1-1.5l**: $e^{\beta} = e^{0,16134} = 1,175 \rightarrow$ taxa de risco 17,5% maior que carros < 1L.
- **Group1.5-2l**: $e^{\beta} = e^{0,39281} = 1,481 \rightarrow$ taxa de risco 48,1% maior que carros < 1L.
- **Group>2l**: $e^{\beta} = e^{0,56341} = 1,757 \rightarrow$ taxa de risco 75,7% maior que carros < 1L.
- **Age25-29**: $e^{\beta} = e^{-0,19101} = 0,826 \rightarrow$ redução de 17,4% no risco em relação a < 25 anos.
- **Age30-35**: $e^{\beta} = e^{-0,34495} = 0,708 \rightarrow$ redução de 29,2% no risco em relação a < 25 anos.
- **Age>35**: $e^{\beta} = e^{-0,53667} = 0,585 \rightarrow$ redução de 41,5% no risco em relação a < 25 anos.

Exemplo 7.1

Qual a taxa de risco para um motorista de 32 anos ([Age30-35](#)), dirigindo um carro de 1.8 Litros ([Group1.5-2l](#)), morando no Distrito 4?

```
# 1. Criar o data frame com o perfil do cliente
# Observação: Definimos Holders = 1 para obter a taxa por segurado (ou 1000 para a contagem)
novo_cliente <- data.frame(
  District = "4",
  Group    = "1.5-2l",
  Age      = "30-35",
  Holders  = 1
)

# 2. Prever a taxa esperada de sinistros (type = "response")
taxa_esperada <- predict(modelo_sem_int, newdata = novo_cliente, type = "response")
taxa_esperada
```

1

0.2144508

- O risco é de 21,44%.

Exemplo 7.2

Agora use os dados na base `DoctorVisits` do pacote `AER`.

- `visits` (Y): Número de consultas médicas nas últimas 2 semanas (contagem).
- `gender`: Sexo (female, male).
- `age`: Idade do indivíduo (em anos / 100).
- `income`: Renda anual (em dezenas de milhares de dólares).
- `illness`: Número de doenças registradas nas últimas 2 semanas.
- `reduced`: Número de dias com atividade reduzida por doença/lesão nas últimas 2 semanas.
- `health`: Escore de saúde (escores maiores indicam pior estado de saúde).
- `private`: Possui plano de saúde privado? (yes, no).

Exemplo 7.2

- **freepoor**: Possui gratuidade governamental por baixa renda? (yes, no).
- **freerepat**: Possui gratuidade governamental? (yes, no).
- **nchronic**: Possui doença crônica que não limita atividades? (yes, no).
- **lchronic**: Possui doença crônica que limita atividades? (yes, no).

Exemplo 7.2

- Adicione $I(\text{age}^2)$ no modelo além de age .
- Faça seleção de variáveis.
- Interprete os coeficientes.
- Calcule o número de visitas esperados para uma pessoa com as seguintes características:

```

novo_paciente <- data.frame(
  gender      = "female",  # Sexo feminino
  age         = 0.30,      # Idade: 30 anos (30 / 100)
  income      = 0.20,      # Renda anual: $20.000 ($20.000 / 100.000)
  illness     = 1,         # 1 doença recente nas últimas 2 semanas
  reduced     = 0,         # 0 dias de atividade reduzida
  health      = 0,         # Escore de saúde geral: 0 (boa saúde)
  private     = "no",      # Sem plano de saúde privado
  freepoor    = "no",      # Sem gratuidade governamental por baixa renda
  freerepat   = "no",      # Sem gratuidade governamental por idade/deficiência/veterano
  nchronic    = "no",      # Sem doença crônica não limitante
  lchronic    = "no"       # Sem doença crônica limitante
)

```

Fim