Análise de desvio

Como medir a discrepância entre os dados e o modelo?

ESTAT0092 – Modelos Lineares Generalizados
Prof. Dr. Sadraque E. F. Lucena
http://sadraquelucena.github.io/mlg

Introdução

- Já vimos que é possível comparar modelos usando um teste global da razão de veorssimilhanças.
- Hoje vamos nos debruçar um pouco mais sobre a significância global de um modelo usando o **desvio**.

Na regressão linear

- Considere dois modelos de regressão linear normal encaixados:

$$\begin{cases} M_0: & Y_i = \beta_0 + \varepsilon_i \\ M_1: & Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \end{cases}$$

- O modelo M_1 acrescenta a covariável x.
- Ao estimar seus parâmetros por mínimos quadrados, a soma de quadrados residual não aumenta:

$$SQE(M_1) \leq SQE(M_0).$$

- A diferença $SQE(M_0) - SQE(M_1)$ mede quanto a inclusão de x diminui a variação residual.
- Mas essa redução, sozinha, não responde se o ganho é grande em relação à variabilidade residual e ao custo de adicionar um parâmetro.
  - Para isso, usamos o teste F de comparação entre modelos encaixados.

O que muda nos MLG?

- Em um MLG, a resposta pode ser binária, uma contagem ou uma variável contínua com outra distribuição.
- A diferença $Y_i - \widehat{\mu}_i$ não fornece, por si só, uma medida universal e comparável da discrepância.
- Por exemplo:
  - Na regressão logística, Y_i assume 0 ou 1, enquanto $\widehat{\mu}_i = \hat{p}_i$ é uma probabilidade.
  - Na regressão de Poisson, a variância condicional muda de acordo com o valor da média.
- Precisamos, portanto, de uma medida de discrepância coerente com a distribuição probabilística especificada para o MLG: **o desvio (*deviance*)**.

Equivalência

- A ANOVA na regressão linear é substituída pela Análise de Desvio em um MLG. A única diferença é que trocamos a Soma de Quadrados pela Deviance e o Teste F pelo Teste da Razão de Verossimilhanças.

Regressão linear normal	**Modelos lineares generalizados**
Soma de quadrados dos resíduos	Desvio residual
Teste F para modelos encaixados	Teste da razão de verossimilhanças, em condições apropriadas
Distribuição normal com variância constante, na forma clássica	Família probabilística e função de ligação especificadas pelo MLG

Três modelos para entender o desvio

- Para entendermos o desvio, precisamos entender a definição de 3 modelos:
  - **Modelo nulo:** Contém apenas o intercepto. Não utiliza as covariáveis para explicar diferenças entre as médias condicionais.
  - **Modelo ajustado:** É o modelo de interesse, com um conjunto definido de preditores. Ele busca representar os dados com uma estrutura mais simples que a do modelo saturado.
  - **Modelo saturado:** Possui número de parâmetros igual ao número de observações coletadas nos dados. Serve como referência de ajuste máximo, mas normalmente não é útil para explicar ou resumir os dados.
- **Obs.:** O modelo saturado é uma referência matemática, não necessariamente um modelo que deveríamos usar para previsão ou interpretação.

O que é o desvio?

- O desvio mede a discrepância entre o modelo ajustado e o modelo saturado, comparando suas log-verossimilhanças máximas:

$$D = 2\{\ell(\text{modelo saturado}) - \ell(\text{modelo ajustado})\}$$

- Aqui, ℓ representa a log-verossimilhança maximizada.
- Mantidas a família probabilística e as condições de comparação, o modelo saturado alcança uma log-verossimilhança pelo menos tão alta quanto a do modelo ajustado; por isso, o desvio é não negativo.
- **Interpretação:** quanto menor o desvio, mais próximo o modelo ajustado está do modelo saturado em termos de log-verossimilhança.
  - Cabe lembrar que isso não garante, por si só, adequação absoluta nem bom desempenho fora da amostra.

Desvio escalonado

- O Desvio (D) mede a “distância” total entre o modelo saturado e o modelo ajustado.
- Porém, um erro de 100 é grande ou pequeno? Depende da dispersão dos dados (ϕ).
  - Se a dispersão (ϕ) for 1.000, um erro de 100 é pequeno.
  - Se a dispersão (ϕ) for $0{,}1$, um erro de 100 é gigantesco.
- Nesse caso, podemos utilizar o Desvio Escalonado (D^*):

$$D^* = \frac{D}{\phi}$$

- Para famílias como binomial e Poisson, a dispersão é frequentemente fixada em $\phi = 1$, e o desvio e desvio escalonado coincidem.
- R ou Python geralmente imprimem no `summary` o Desvio Não Escalonado (D).

Desvio escalonado

- O devio escalonado pode ser usado com duas finalidades:
  1. Avaliando UM modelo isolado: O Teste de Qualidade do Ajuste (*Goodness-of-Fit*).
  2. Avaliando VARIÁVEIS sequencialmente: A Tabela ANODEV (A ANOVA dos MLGs).

1. Testando a Qualidade do Ajuste de um Modelo

- Uma vez que o Desvio Escalonado (D^*) mede a distância entre o Modelo Ajustado e o Modelo Saturado (ajuste perfeito), ele ode ser usado como uma meidade de qualidade do ajuste (*goodness-of-fit*).
- Sob condições regulares, $D^* \sim \chi^2_{n-p}$ (n observações, p parâmetros).
- Se $D^* < \chi^2_{n-p,1-\alpha} \implies$ Não há evidência de falta de ajuste (O modelo é adequado).
- Como o valor esperado de uma χ^2_{n-p} é $n-p$, um valor de D^* próximo de $n-p$ pode ser um indicativo de que o modelo ajustado aos dados é adequado.
- **Regra de bolso:** $\frac{D^*}{n-p} \approx 1 \implies$ o modelo está bem ajustado aos dados.

1. Testando a Qualidade do Ajuste de um Modelo

No R:

```r
# Ajuste do modelo
modelo <- glm(y ~ x1 + x2, family = gamma(link = "log"))

# Desvio não escalonado (D)
D <- deviance(modelo)

# Estimativa da dispersão (phi)
phi <- summary(modelo)$dispersion

# Desvio Escalonado (D*)
D_star <- D / phi
```

- Em famílias como Poisson e Binomial, $\phi = 1 \implies D^* = D$.
- Em famílias como Gama, Normal e Gaussiana Inversa, ϕ precisa ser estimado $\implies D^* = D/\hat{\phi}$.

2. Análise de Desvio (ANODEV)

- ANODEV é a ANOVA para os MLGs.
- Na análise de desvio é um procedimento para avaliar a relevância de variáveis explicativas em MLGs.
- Ele é estatisticamente mais preciso e robusto que o teste de Wald em amostras pequenas e moderadas, além de evitar distorções graves (como o efeito Hauck-Donner).
- Aqui, as variáveis explicativas são adicionadas uama a uma (de forma sequencial) e mede quanto o desvio cai a cada passo:

$$\text{Modelo Nulo } (M_0) \xrightarrow{+A} M_1 \xrightarrow{+B} M_2 \xrightarrow{+A:B} M_3$$

- Se a redução no desvio for significativa, a variavel deve permanecer no modelo.

2. Análise de Desvio (ANODEV)

- Para comparar dois modelos encaixados (M_p com p parâmetros e M_q com q parâmetros, $p < q$), a estatística do LRT é dada pela diferença de desvios.
  - Para Binomial e Poisson ($\phi = 1$), usa-se diretamente o Teste LRT (χ^2).:

$$T_{\text{LRT}} = \frac{D_p - D_q}{\phi} \sim \chi^2_{q-p} \quad (\text{quando } \phi \text{ é conhecido})$$

  - Para famílias como Gaussiana, Gama e Normal Inversa ($\phi \neq 1$), utiliza-se a estatística do Teste F:

$$F = \frac{(D_p - D_q)/(q-p)}{\hat{\phi}_m} \sim F_{q-p,\, n-m}$$

2. Análise de Desvio (ANODEV)

Considere uma sequência de entrada $M_0 \to A \to A+B \to A+B+AB$:

Modelo	G.L.	Desvio Residual	Redução do Desvio (ΔD)	Teste LRT ($\phi = 1$)	Teste F (ϕ estimado)
Nulo	$n-1$	D_0	–	–	–
A	$n_A - 1$	D_A	$D_0 - D_A$	$(D_0 - D_A) \sim \chi^2_{n_A-1}$	$\frac{(D_0-D_A)/(n_A-1)}{\hat{\phi}_m} \sim F$
A + B	$n_B - 1$	D_{A+B}	$D_A - D_{A+B}$	$(D_A - D_{A+B}) \sim \chi^2_{n_B-1}$	$\frac{(D_A-D_{A+B})/(n_B-1)}{\hat{\phi}_m} \sim F$
A + B + AB	$(n_A-1)(n_B-1)$	D_{A+B+AB}	$D_{A+B} - D_{A+B+AB}$	$\Delta D_{AB} \sim \chi^2_{(n_A-1)(n_B-1)}$	$\frac{\Delta D_{AB}/\mathrm{GL}_{AB}}{\hat{\phi}_m} \sim F$

2. Análise de Desvio (ANODEV)

No R:

```r
# 1. Ajuste do modelo completo com interações
modelo_gama <- glm(yield ~ lineage + epoca + lineage:epoca,
                   family = Gamma(link = "log"), data = cotton)

# 2. Gerando a Tabela ANODEV via Teste F (pois phi é estimado na Gama)
anova(modelo_gama, test = "F")

# 3. Caso fosse um modelo Poisson ou Regressão Logística (phi = 1)
modelo_poisson <- glm(counts ~ A + B, family = poisson)
anova(modelo_poisson, test = "LRT")
```

Exemplo 8.1

```
Call:
glm(formula = infec ~ idade + uti + tempo_internacao + vacinado,
    family = binomial(link = "logit"), data = dados_hosp)

Coefficients:
                 Estimate Std. Error z value Pr(>|z|)
(Intercept)      -2.04042    0.97578  -2.091   0.0365 *
idade             0.02764    0.02806   0.985   0.3246
utiSim            1.54600    0.30232   5.114 3.16e-07 ***
tempo_internacao -0.02619    0.03043  -0.861   0.3894
vacinadoSim       0.08475    0.29287   0.289   0.7723
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 316.17  on 247  degrees of freedom
Residual deviance: 287.19  on 243  degrees of freedom
AIC: 297.19

Number of Fisher Scoring iterations: 4
```

Exemplo 8.1

1. A qualidade do ajuste é boa?

$$\frac{\texttt{Residual deviance}}{\texttt{degrees of freedom}} = \frac{287{,}19}{243} = 1{,}18$$

- A razão está acima de 1, o que acende um primeiro alerta de que o modelo pode ter ruído ou falta de ajuste.

2. Teste Qui-Quadrado de qualidade de ajuste:

```
options(scipen = 999)
1 - pchisq(287.19, df = 243)
```

```
[1] 0.02716094
```

- Como $p \approx 0{,}028 < 0{,}05$, rejeitamos a hipótese nula de bom ajuste! Há evidências estatísticas de que o modelo atual apresenta falta de ajuste em relação ao modelo saturado.

Exemplo 8.1

3. Mas será que o conjunto de variáveis é importante para o modelo?

- Vamos calcular a redução no desvio (Modelo Nulo vs. Modelo Residual)
- $\Delta D = \texttt{Null deviance} - \texttt{Residual deviance} = 316{,}17 - 287{,}19 = 28{,}98$
- Graus de liberdade: $247 - 243 = 4$
- Teste global: `1 - pchisq(28.98, df = 4) =` 0.0000079
  - O conjunto de 4 variáveis reduz a deviança em relação ao modelo nulo de forma significativa.

Exemplo 8.1

```r
anova(modelo_hosp, test = "LRT")
```

```
Analysis of Deviance Table

Model: binomial, link: logit

Response: infec

Terms added sequentially (first to last)

                 Df Deviance Resid. Df Resid. Dev     Pr(>Chi)
NULL                            247     316.17
idade             1   0.0031       246     316.17       0.9557
uti               1  28.1088       245     288.06 0.0000001147 ***
tempo_internacao  1   0.7835       244     287.28       0.3761
vacinado          1   0.0838       243     287.19       0.7722
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Exemplo 8.1

```r
modelo_final <- glm(infec ~ uti, family = binomial(link = "logit"), data = dados_hosp)
summary(modelo_final)
```

```
Call:
glm(formula = infec ~ uti, family = binomial(link = "logit"),
    data = dados_hosp)

Coefficients:
            Estimate Std. Error z value        Pr(>|z|)
(Intercept)  -1.3952     0.2111  -6.609 0.0000000000387 ***
utiSim        1.4513     0.2863   5.069 0.0000004003453 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 316.17  on 247  degrees of freedom
Residual deviance: 288.81  on 246  degrees of freedom
AIC: 292.81

Number of Fisher Scoring iterations: 4
```

Exemplo 8.1

Para o modelo final:

- Qualidade do ajuste:

$$\frac{\texttt{Residual deviance}}{\texttt{degrees of freedom}} = \frac{288{,}81}{246} = 1{,}17$$

  - Teste Qui-Quadrado de qualidade de ajuste:

```
options(scipen = 999)
1 - pchisq(288.81, df = 246)
```

```
[1] 0.03159413
```

- O modelo melhorou mas continua mal ajustado.
- Deve haver outras variáveis importantes no modelo que não foram medidas.

Exemplo 8.2

Considere o conjunto de dados `ToothGrowth`, de um ensaio clínico sobre o impacto da Vitamina C no crescimento dentário em 60 cobaias (porquinhos-da-índia). As variáveis são:

- `len` (resposta): Comprimento dos dentes em mícrones
- `supp`: Tipo de suplemento de Vitamina C (factor com 2 níveis)
  - `OJ`: Sumo de laranja (Orange Juice)
  - `VC`: Ácido ascórbico / Vitamina C pura (Ascorbic Acid).
- `dose`: Dose diária administrada (numeric, com os níveis 0.5, 1.0 e 2.0 mg/dia).

Exemplo 8.2

```r
data("ToothGrowth")
dados <- ToothGrowth

dados$dose_f <- factor(dados$dose, levels = c(0.5, 1.0, 2.0))

fit_gama <- glm(len ~ supp * dose_f, family = Gamma(link = "log"), data = dados)

summary(fit_gama)
```

Exemplo 8.2

```
Call:
glm(formula = len ~ supp * dose_f, family = Gamma(link = "log"),
    data = dados)

Coefficients:
              Estimate Std. Error t value             Pr(>|t|)
(Intercept)    2.58249    0.07398  34.910 < 0.0000000000000002 ***
suppVC        -0.50555    0.10462  -4.832            0.0000115698 ***
dose_f1        0.53988    0.10462   5.161            0.0000036212 ***
dose_f2        0.67791    0.10462   6.480            0.0000000287 ***
suppVC:dose_f1  0.20278    0.14795   1.371                  0.17618
suppVC:dose_f2  0.50861    0.14795   3.438                  0.00114 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Gamma family taken to be 0.05472392)

    Null deviance: 12.6523  on 59  degrees of freedom
Residual deviance:  3.0094  on 54  degrees of freedom
AIC: 344.71

Number of Fisher Scoring iterations: 4
```

Exemplo 8.2

Vamos verificar se alguma variável deve sair do modelo usando ANODEV.

```
anova(fit_gama, test = "F") # No modelo Gama usamos teste F pois phi != 1
```

```
Analysis of Deviance Table

Model: Gamma, link: log

Response: len

Terms added sequentially (first to last)

            Df Deviance Resid. Df Resid. Dev       F                Pr(>F)
NULL                         59    12.6523
supp         1   0.5830        58    12.0693 10.6535              0.001909 **
dose_f       2   8.4061        56     3.6632 76.8047 < 0.00000000000000022 ***
supp:dose_f  2   0.6538        54     3.0094  5.9735              0.004533 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- O teste F indica que todas as variávis devem permanecer no modelo.

Exemplo 8.2

Vamos avaliar a qualidade do ajuste.

```
# Avaliação da Qualidade do Ajuste (Goodness-of-Fit)
( D_res   <- deviance(fit_gama) )            # desvio residual
```

```
[1] 3.009401
```

```
( phi_hat <- summary(fit_gama)$dispersion )  # phi
```

```
[1] 0.05472392
```

```
( gl_res  <- df.residual(fit_gama) )         # graus de liberdade
```

```
[1] 54
```

```
( D_star  <- D_res / phi_hat )               # Desvio Escalonado D* = D / phi_hat
```

```
[1] 54.99242
```

```
1 - pchisq(D_star, df = gl_res)
```

```
[1] 0.4368243
```

- O desvio escalonado é próximo dos graus de liberdade.
- O p-valor do teste qui-quadrado indica que o modelo está bem ajustado.

Exercício 8.1

Considere o conjunto de dados `birthwt` do pacote `MASS`. Ajuste um modelo de regressão. Faça selecção de variáveis usado o desvio. Avalie a qualidade do ajuste do modelo final.

```
library(MASS)

dados <- birthwt |>
  # remover bwt (peso de cada bebê)
  dplyr::select(-bwt) |>
  # codificar como fator as preditoras categóricas e renomear as demais
  dplyr::mutate(
    baixo_peso = low,
    idade = age,
    peso_mae = lwt,
    raca = factor(race, levels = c(1, 2, 3), labels = c("Branca", "Negra", "Outra")),
    fumante = factor(smoke, levels = c(0, 1), labels = c("Não", "Sim")),
    partos_prematuros = ptl,
    hipertensao = factor(ht, levels = c(0, 1), labels = c("Não", "Sim")),
    irritabilidade_uterina = factor(ui, levels = c(0, 1), labels = c("Não", "Sim")),
    consultas_pre_natal = ftv
  )
```

Fim