



Lista de Exercícios 3

- 3.1) **Regressão Gamma.** Considere um modelo de regressão Gamma com função de ligação logarítmica, isto é,

$$Y_i \sim \text{Gamma}(\mu_i, \phi), \quad \log(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

A distribuição de Y_i pode ser escrita na forma da família exponencial como

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right\},$$

em que

$$\theta_i = -\frac{1}{\mu_i}, \quad b(\theta_i) = -\log(-\theta_i), \quad V(\mu_i) = \mu_i^2.$$

Determine:

- (a) μ_i em função de $\boldsymbol{\beta}$.
 - (b) As derivadas $\frac{d\mu_i}{d\eta_i}$ e $\frac{d\theta_i}{d\mu_i}$.
 - (c) As matrizes $\mathbf{V}$ e $\mathbf{W}$.
 - (d) A função escore $U_{\boldsymbol{\beta}}$.
 - (e) A matriz de informação de Fisher esperada $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$.
- 3.2) **Regressão Inversa Gaussiana.** Considere um modelo de regressão Inversa Gaussiana com função de ligação identidade, isto é,

$$Y_i \sim \text{IG}(\mu_i, \phi), \quad \mu_i = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

A distribuição de Y_i pode ser escrita na forma da família exponencial como

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{\phi} + c(y_i, \phi) \right\},$$

em que

$$\theta_i = -\frac{1}{2\mu_i^2}, \quad b(\theta_i) = -\sqrt{-2\theta_i}, \quad V(\mu_i) = \mu_i^3.$$

Determine:

- (a) μ_i em função de $\boldsymbol{\beta}$.

- (b) As derivadas $\frac{d\mu_i}{d\eta_i}$ e $\frac{d\theta_i}{d\mu_i}$.
- (c) As matrizes $\mathbf{V}$ e $\mathbf{W}$.
- (d) A função escore U_{β} .
- (e) A matriz de informação de Fisher esperada $\mathbf{K}_{\beta\beta}$.

Respostas:

3.1) (a) $\mu_i = \exp(\mathbf{x}_i^\top \boldsymbol{\beta})$

(b) $\frac{d\mu_i}{d\eta_i} = \exp(\eta_i) = \mu_i$

$$\frac{d\theta_i}{d\mu_i} = -(-1)\mu_i^{-2} = \frac{1}{\mu_i^2}$$

(Nota: Em MLG, sabemos que $\frac{d\theta_i}{d\mu_i} = \frac{1}{V(\mu_i)}$, o que confirma o resultado $\frac{1}{\mu_i^2}$)

(c) $\mathbf{V} = \text{diag}(\mu_1^2, \mu_2^2, \dots, \mu_n^2)$

$$\mathbf{W} = \text{diag}(1, 1, \dots, 1) = \mathbf{I}_n$$

(d) $U_{\beta_j} = \sum_{i=1}^n \frac{y_i - \mu_i}{\phi \mu_i^2} (\mu_i) x_{ij} = \sum_{i=1}^n \frac{y_i - \mu_i}{\phi \mu_i} x_{ij}$.

Em notação matricial, o vetor escore é $\mathbf{U}_{\boldsymbol{\beta}} = \frac{1}{\phi} \mathbf{X}^\top \text{diag}\left(\frac{1}{\mu_i}\right) (\mathbf{y} - \boldsymbol{\mu})$

(e) $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \frac{1}{\phi} \mathbf{X}^\top \mathbf{X}$

3.2) (a) $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$

(b) $\frac{d\mu_i}{d\eta_i} = 1$

$$\frac{d\theta_i}{d\mu_i} = \left(-\frac{1}{2}\right) \cdot (-2)\mu_i^{-3} = \frac{1}{\mu_i^3}$$

(c) $\mathbf{V} = \text{diag}(\mu_1^3, \mu_2^3, \dots, \mu_n^3)$

$$\mathbf{W} = \text{diag}\left(\frac{1}{\mu_1^3}, \frac{1}{\mu_2^3}, \dots, \frac{1}{\mu_n^3}\right)$$

(d) $U_{\beta_j} = \sum_{i=1}^n \frac{y_i - \mu_i}{\phi \mu_i^3} x_{ij}$

Em forma matricial, $\mathbf{U}_{\boldsymbol{\beta}} = \frac{1}{\phi} \mathbf{X}^\top \mathbf{W} (\mathbf{y} - \boldsymbol{\mu}) = \frac{1}{\phi} \mathbf{X}^\top \text{diag}\left(\frac{1}{\mu_i^3}\right) (\mathbf{y} - \boldsymbol{\mu})$

(e) $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \frac{1}{\phi} \mathbf{X}^\top \text{diag}\left(\frac{1}{\mu_1^3}, \frac{1}{\mu_2^3}, \dots, \frac{1}{\mu_n^3}\right) \mathbf{X}$