Análise de Resíduos

O modelo está bem ajustado aos dados?

ESTAT0092 – Modelos Lineares Generalizados
Prof. Dr. Sadraque E. F. Lucena
http://sadraquelucena.github.io/mlg

- O desvio mede a discrepância *global* do modelo, mas resumi-lo a um único número oculta falhas locais de ajuste.
- Uma medida global pode resumir o ajuste, mas não mostra quais observações o modelo tem mais dificuldade de ajustar.
- Nesta aula, vamos aprender a **calcular, comparar e interpretar resíduos** em modelos lineares generalizados (MLGs).
- A análise será exploratória: identificar sinais que merecem investigação, sem confundir resíduo com diagnóstico definitivo.

Por que o desvio global não basta?

- Imagine dois modelos ajustados com mesmo desvio total ($D = 10$):
  - **Modelo A:** 1 observação concentra 90% do desvio ($d_1 = 9$) *(indício de outlier, ponto influente ou erro de medição)*.
  - **Modelo B:** 10 observações contribuem uniformemente com 1 unidade cada *(Indício de subajuste geral ou omissão de preditor relevante)*.
- **Diferença de perspectiva:**
  - **Desvio global:** Responde *"quanta discrepância total o modelo acumula?"*
  - **Resíduos:** Respondem *"onde a discrepância está, em qual direção e com qual padrão?"*
- **Observação:** O desvio valida a qualidade geral do modelo, enquanto os resíduos apontam onde e como corrigir o modelo.

Exemplo: número de falhas em fios

O conjunto `warpbreaks`, disponível no R, registra o número de falhas (`breaks`) em amostras de fios, sob diferentes tipos de lã (`wool`) e níveis de tensão (`tension`).

- Resposta: contagem de falhas (`breaks`)
- Preditoras: tipo de lã (`wool`) e tensão (`tension`)
- Modelo inicial: regressão de Poisson com ligação log.

Ajuste do modelo no R:

```
dados <- warpbreaks
modelo <- glm(
  breaks ~ wool + tension,
  family = poisson(link = "log"),
  data = dados
)
summary(modelo)
```

Exemplo: número de falhas em fios

```
Call:
glm(formula = breaks ~ wool + tension, family = poisson(link = "log"),
    data = dados)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  3.69196    0.04541  81.302  < 2e-16 ***
woolB       -0.20599    0.05157  -3.994 6.49e-05 ***
tensionM    -0.32132    0.06027  -5.332 9.73e-08 ***
tensionH    -0.51849    0.06396  -8.107 5.21e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 297.37  on 53  degrees of freedom
Residual deviance: 210.39  on 50  degrees of freedom
AIC: 493.06

Number of Fisher Scoring iterations: 4
```

Exemplo: número de falhas em fios

- O ajuste global do modelo não está muito bom, pois

$$\frac{\texttt{Residual deviance}}{\texttt{degrees of freedom}} = \frac{210{,}39}{50} \approx 4{,}21 \quad (\text{muito maior que } 1)$$

  (Lembre que em um MLG bem ajustado, `Residual deviance` é proximo de `degrees of freedom`).

- Vamos comparar os números de falhas observados e os valores estimados pelo modelo.

Exemplo: número de falhas em fios

```
comparacao <- data.frame(
  observacao = seq_len(nrow(dados)),
  wool = dados$wool,
  tension = dados$tension,
  observado = dados$breaks,
  ajustado = fitted(modelo)
)
head(comparacao, 10)
```

```
   observacao wool tension observado ajustado
1           1    A       L        26 40.12354
2           2    A       L        30 40.12354
3           3    A       L        54 40.12354
4           4    A       L        25 40.12354
5           5    A       L        70 40.12354
6           6    A       L        52 40.12354
7           7    A       L        51 40.12354
8           8    A       L        26 40.12354
9           9    A       L        67 40.12354
10         10    A       M        18 29.09722
```

Exemplo: número de falhas em fios

- Vamos olhar a diferença bruta $y_i - \hat{\mu}_i$:

```
comparacao$erro_bruto <- comparacao$observado - comparacao$ajustado
comparacao[order(abs(comparacao$erro_bruto), decreasing = TRUE), ][1:10, ]
```

```
   observacao wool tension observado ajustado erro_bruto
5           5    A       L        70 40.12354   29.87646
9           9    A       L        67 40.12354   26.87646
24         24    A       H        43 23.89035   19.10965
29         29    B       L        14 32.65424  -18.65424
37         37    B       M        42 23.68056   18.31944
14         14    A       M        12 29.09722  -17.09722
41         41    B       M        39 23.68056   15.31944
44         44    B       M        39 23.68056   15.31944
4           4    A       L        25 40.12354  -15.12354
1           1    A       L        26 40.12354  -14.12354
```

- Essa diferença é ótima para explicar o erro no mundo real (ex.: “o modelo errou por 5 falhas no fio”), mas não serve para comparar observações do ponto de vista estatístico, pois a variância muda de acordo com a média na Poisson.

Exemplo: número de falhas em fios

Como o erro bruto engana, algumas métricas ajustadas podem ser utilizadas, cada uma com um papel específico:

```
comparacao$r_resposta <- residuals(modelo, type = "response")
comparacao$r_pearson <- residuals(modelo, type = "pearson")
comparacao$r_desvio <- residuals(modelo, type = "deviance")
comparacao$t_desvio <- rstandard(modelo, type = "deviance")
head(comparacao[,4:10], 10)
```

```
   observado ajustado erro_bruto r_resposta r_pearson  r_desvio  t_desvio
1         26 40.12354  -14.12354  -14.12354 -2.229687 -2.384536 -2.489762
2         30 40.12354  -10.12354  -10.12354 -1.598206 -1.673658 -1.747513
3         54 40.12354   13.87646   13.87646  2.190681  2.079744  2.171519
4         25 40.12354  -15.12354  -15.12354 -2.387557 -2.567627 -2.680932
5         70 40.12354   29.87646   29.87646  4.716606  4.261639  4.449698
6         52 40.12354   11.87646   11.87646  1.874940  1.792277  1.871367
7         51 40.12354   10.87646   10.87646  1.717070  1.647134  1.719819
8         26 40.12354  -14.12354  -14.12354 -2.229687 -2.384536 -2.489762
9         67 40.12354   26.87646   26.87646  4.242995  3.866888  4.037528
10        18 29.09722  -11.09722  -11.09722 -2.057257 -2.214653 -2.304977
```

Exemplo: número de falhas em fios

- `r_resposta` (resíduo de resposta): O erro simples na escala original ($y_i - \hat{\mu}_i$).
- `r_pearson` (resíduo de Pearson): O erro simples ponderado pelo desvio padrão esperado da observação.
- `r_desvio` (Resíduo componente do desvio): A contribuição de cada ponto para a verossimilhança (o "desvio" do modelo).
- `t_desvio` (Resíduo componente do desvio padronizado): O resíduo do desvio ajustado pela alavancagem (*leverage*), que leva em conta a influência daquela observação no ajuste.

Resíduo de resposta

- O resíduo de resposta é a diferença bruta entre o valor observado y_i e a média estimada $\hat{\mu}_i$:

$$e_i = y_i - \hat{\mu}_i.$$

  - $e_i > 0$: observado acima do ajustado; o modelo subestimou a resposta;
  - $e_i < 0$: observado abaixo do ajustado; o modelo superestimou a resposta;
  - $e_i = 0$: observado igual ao ajustado.
- É fácil interpretar na unidade original, mas não ajusta a diferença pela variabilidade esperada.

Por que a diferença bruta não basta?

- Em um MLG, a variância condicional depende da média estimada:

$$Var(Y_i \mid x_i) = \phi V(\mu_i),$$

  em que $V(\mu_i)$ é a função de variância e ϕ é o parâmetro de dispersão.

- A diferença observada $-$ ajustada precisa ser ponderada pela variabilidade esperada.
  - Um mesmo erro de $+5$ unidades é gigantesco se $Var(Y) = 2$, mas irrisório se $Var(Y) = 500$.
- **Exemplos:**
  - **Poisson:** $V(\mu) = \mu$ (a variância cresce linearmente com a média) e $\phi = 1$.
  - **Binomial:** $V(\mu) = \mu(1 - \mu)$ e $\phi = 1$.
  - Outras famílias possuem convenções e funções de variância próprias.

Resíduo de Pearson

- O resíduo de Pearson padroniza a diferença bruta dividindo-a pelo desvio-padrão teórico vindo da função de variância:

$$r_{Pi} = \frac{y_i - \hat{\mu}_i}{\sqrt{V(\hat{\mu}_i)}}$$

- Ele mede a discrepância em unidades do desvio-padrão da resposta.
- Em modelos com parâmetro de escala ϕ (Gama, Normal Inversa), o denominador pode incluir a dispersão estimada: $\sqrt{\hat{\phi} V(\hat{\mu}_i)}$.
- **No R:** O comando `residuals(modelo, type = "pearson")` aplica a convenção da família escolhida (ex.: em Poisson, assume $\phi = 1$).

Resíduo de Pearson

Distribuição	Função de variância $V(\mu)$	Resíduo de Pearson usual
Normal com variância unitária	1	$y_i - \hat{\mu}_i$
Poisson	μ_i	$(y_i - \hat{\mu}_i)/\sqrt{\hat{\mu}_i}$
Bernoulli	$\mu_i(1-\mu_i)$	$(y_i - \hat{\mu}_i)/\sqrt{\hat{\mu}_i(1-\hat{\mu}_i)}$
Gama	μ_i^2	$(y_i - \hat{\mu}_i)/\hat{\mu}_i$

- Na **Gama**, como $V(\mu) = \mu^2$, a raiz resulta em $\hat{\mu}_i$. O resíduo torna-se o **erro relativo** da observação.
- **Nota:** As fórmulas acima consideram a convenção teórica de $V(\mu)$. O parâmetro de dispersão ϕ, se presente, pode ser tratado separadamente.

Resíduo componente do desvio

- O desvio compara a log-verossimilhança do modelo ajustado com a do modelo saturado.
- Cada observação tem uma contribuição d_i^2 para essa discrepância total:

$$r_{Di} = \text{sign}(y_i - \hat{\mu}_i)\sqrt{d_i^2}$$

- Mede o peso individual da observação no desvio total do modelo.
- O sinal informa a direção do erro:
  - Positivo ($y_i > \hat{\mu}_i$): o modelo subestimou a resposta.
  - Negativo ($y_i < \hat{\mu}_i$): o modelo superestimou a resposta.

Resíduo de desvio na Poisson

- Para uma resposta de contagem com distribuição de Poisson, a contribuição individual ao desvio é:

$$d_i^2 = 2\left[\ell(y_i) - \ell(\widehat{\mu}_i)\right] = 2\left[y_i \log\left(\frac{y_i}{\widehat{\mu}_i}\right) - y_i + \widehat{\mu}_i\right]$$

- Substituindo na expressão do resíduo componente do desvio:

$$r_{Di} = \operatorname{sign}(y_i - \hat{\mu}_i)\sqrt{2\left[y_i \log\left(\frac{y_i}{\hat{\mu}_i}\right) - y_i + \hat{\mu}_i\right]}.$$

- Quando $y_i = 0$, define-se $y_i \log(y_i/\hat{\mu}_i) = 0$ por continuidade.

Relação entre resíduo de desvio e desvio global

- A soma dos quadrados dos resíduos componentes do desvio é exatamente o **Desvio Residual Total** (D):

$$D(y;\hat{\mu}) = \sum_{i=1}^{n} r_{Di}^2$$

- Assim, r_{Di}^2 é a contribuição da observação i ao desvio.

Pearson × componente do desvio

Aspecto	Pearson	Componente do desvio
Escala	Função de variância	Contribuição ao desvio
Direção da discrepância	Sim	Sim
Soma dos quadrados é o desvio	Não, em geral	Sim
Uso	Discrepância relativa à variância	Discrepância na escala da verossimilhança

- Não existe um único tipo de resíduo que responda a todas as perguntas.
- Comparar medidas pode ajudar a entender a natureza da discrepância.

Resíduos padronizados

- r_P e r_D ajustam o erro pela variação da média (μ_i), mas ignoram a posição do ponto no espaço dos preditores (x_i).
- Podemos então ponderar esses resíduos pela medida de alavancagem h_i, que é o i-ésimo elemento da diagonal da matriz chapéu ponderada ($0 \leq h_i \leq 1$), e mede o quão distante uma observação está quando compardos os davlores dos preditores.
- O resíduo padronizado divide o resíduo (Pearson ou Desvio) pelo seu desvio-padrão estimado, que inclui a alavancagem:

$$r_i^* = \frac{r_i}{\sqrt{\phi(1-h_i)}}$$

- No R: `rstandard(modelo, type = "deviance")` ou `type = "pearson"`.

Obtendo resíduos no R

```
r_resposta <- residuals(modelo, type = "response")
r_pearson <- residuals(modelo, type = "pearson")
r_desvio <- residuals(modelo, type = "deviance")
t_pearson <- rstandard(modelo, type = "pearson")
t_desvio <- rstandard(modelo, type = "deviance")
```

- `residuals(..., type = "response")`: diferença na escala da resposta
- `type = "pearson"`: resíduo de Pearson
- `type = "deviance"`: componente do desvio
- `rstandard()`: versão padronizada disponível para o modelo

Voltando ao exemplo

```
residuos <- data.frame(
  observacao = seq_len(nrow(dados)),
  observado = dados$breaks,
  ajustado = fitted(modelo),
  resposta = residuals(modelo, type = "response"),
  pearson = residuals(modelo, type = "pearson"),
  desvio = residuals(modelo, type = "deviance"),
  pearson_pad = rstandard(modelo, type = "pearson"),
  desvio_pad = rstandard(modelo, type = "deviance")
)
head(residuos[,-1])
```

```
  observado ajustado  resposta   pearson    desvio pearson_pad desvio_pad
1        26 40.12354 -14.12354 -2.229687 -2.384536   -2.328079  -2.489762
2        30 40.12354 -10.12354 -1.598206 -1.673658   -1.668732  -1.747513
3        54 40.12354  13.87646  2.190681  2.079744    2.287352   2.171519
4        25 40.12354 -15.12354 -2.387557 -2.567627   -2.492916  -2.680932
5        70 40.12354  29.87646  4.716606  4.261639    4.924741   4.449698
6        52 40.12354  11.87646  1.874940  1.792277    1.957678   1.871367
```

Voltando ao exemplo

```
c(
  desvio_glm = deviance(modelo),
  soma_quadrados_componentes = sum(residuals(modelo, type = "deviance")^2)
)
```

```
                desvio_glm soma_quadrados_componentes
                  210.3919                   210.3919
```

- Os resultados coincidem.

Voltando ao exemplo

- Localizando as maiores discrepâncias padronizadas:

```
residuos <- residuos[order(abs(residuos$desvio_pad), decreasing = TRUE), ]
head(residuos[-1], 5)
```

```
   observado ajustado  resposta   pearson    desvio pearson_pad desvio_pad
5         70 40.12354  29.87646  4.716606  4.261639    4.924741   4.449698
9         67 40.12354  26.87646  4.242995  3.866888    4.430231   4.037528
29        14 32.65424 -18.65424 -3.264433 -3.687112   -3.396493  -3.836271
14        12 29.09722 -17.09722 -3.169566 -3.596773   -3.298834  -3.743465
24        43 23.89035  19.10965  3.909682  3.510711    4.063005   3.648388
```

- A ordenação é um mecanismo de triagem, não uma regra de exclusão.
- Para cada observação destacada, volte às variáveis originais e pergunte: o registro é plausível? Há uma condição experimental diferente? A discrepância é parte da variabilidade esperada ou sugere uma estrutura que o modelo não capturou?

Avliação gráfia dos resíduos

- A avaliação do ajuste em MLGs é predominantemente **exploratória** e se beneficia da inspeção visual.
- Enquanto testes formais fornecem apenas uma decisão sumarizada (sim/não), os gráficos revelam a **natureza**, a **direção** e a **localização** das falhas de especificação.
- **Principais gráficos utilizados:**
  - **Resíduos vs. Valores Ajustados ($\hat{\mu}$):** avalia a estrutura de média, a função de ligação e a estabilidade da variância.
  - **Resíduos vs. Variáveis Preditoras (X):** identifica não-linearidades ou termos omitidos.
  - **Resíduos vs. Ordem de Coleta:** detecta autocorrelação ou tendências temporais/lote.
  - **Envelope Simulado (Meio-Normal):** valida a qualidade global do ajuste em relação ao padrão esperado sob a família adotada.

Gráfico 1: Resíduos padronizados vs. Ajustados

- **Objetivo:** investigar possíveis inadequações na estrutura de média e variância do modelo.
  - **Nuvem sem padrão claro:** ausência de sinal evidente nesse gráfico, não prova de que o modelo está correto.
  - **Curvatura ou tendência:** possível inadequação da forma funcional das preditoras, da função de ligação ou omissão de variáveis relevantes.
  - **Dispersão que muda com valores os ajustados:** investigar se o padrão é compatível com a função de variância especificada e se há sobredispersão ou estrutura não representada pelo modelo.
  - **Pontos isolados:** observações que merecem investigação, sem concluir automaticamente que sejam erros ou influentes.
- As linhas em -2 e 2 são referências exploratórias, não limites universais.

Gráfico 1: Resíduos padronizados vs. Ajustados

```
tD <- rstandard(modelo, type = "deviance")
plot(fitted(modelo), tD,
     xlab = "Valores ajustados", ylab = "Resíduos de desvio padronizados",
     pch = 19, col = "darkblue")
abline(h = 0, lty = 2, col = "red")
abline(h = c(-2, 2), lty = 3, col = "gray40")
```

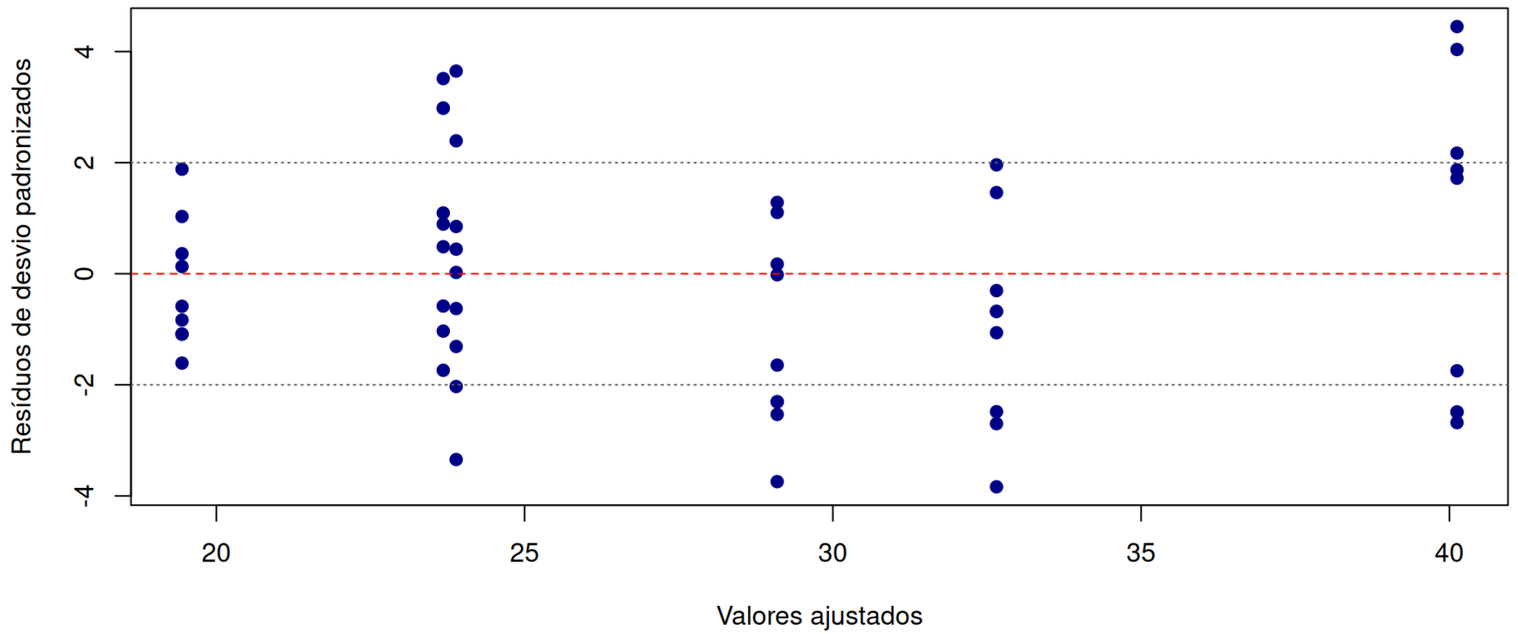


Gráfico 2: Resíduos vs. Variáveis Preditoras

- **Objetivo:** Vinvestigar padrões residuais associados às preditoras que possam indicar inadequação da especificação do modelo.
- Como interpretar:
  - **Preditoras categóricas (Boxplots):** diferenças sistemáticas na localização dos resíduos entre categorias podem sugerir efeitos não representados, variáveis omitidas ou interações que mereçam investigação. Dispersões muito distintas entre grupos podem indicar heterogeneidade não explicada.
  - **Preditoras numéricas (gráfico de dispersão):** curvaturas ou tendências sistemáticas podem indicar forma funcional inadequada. Uma alternativa é investigar termos quadráticos (βx^2) ou outras formas funcionais justificadas.

Gráfico 2: Resíduos vs. Variáveis Preditoras

```
par(mfrow = c(1, 2))
boxplot(tD ~ wool, data = dados, xlab = "Tipo de lã",
        ylab = "Resíduo de desvio padronizado")
abline(h = 0, lty = 2)
boxplot(tD ~ tension, data = dados, xlab = "Tensão",
        ylab = "Resíduo de desvio padronizado")
abline(h = 0, lty = 2)
```

```
par(mfrow = c(1, 1))
```

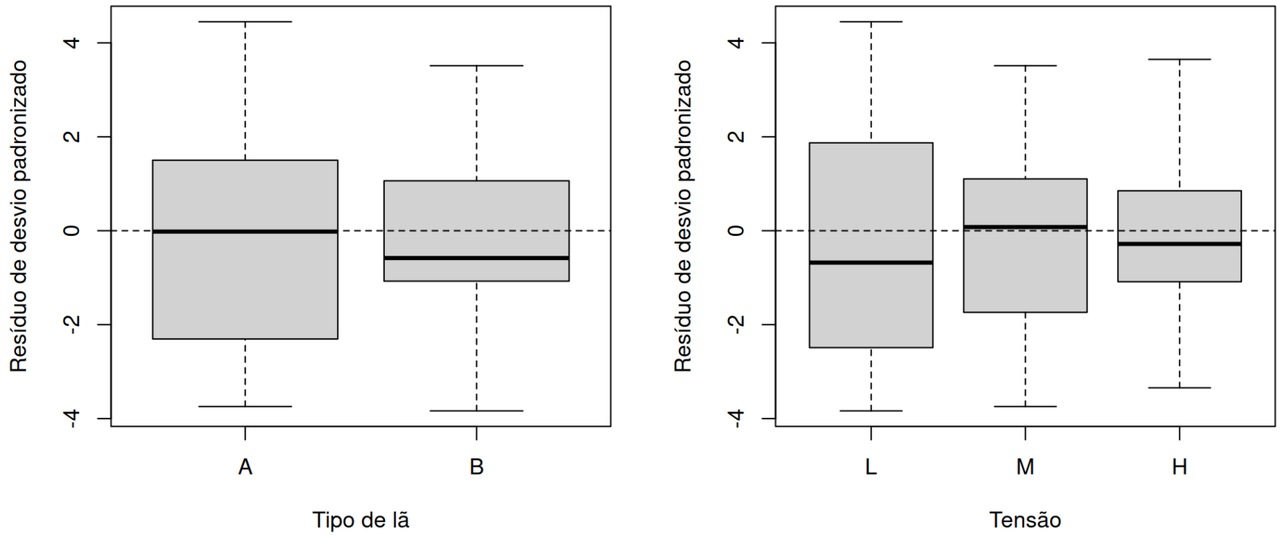


Gráfico 3: Resíduos vs. Ordem

- **Atenção:** interprete este gráfico somente quando a ordem das observações tiver significado, como tempo, lote ou sequência de medição.
- Sinais de alerta:
  - **Sequências prolongadas de resíduos com o mesmo sinal:** podem indicar dependência temporal, tendência não modelada ou outra estrutura sistemática.
  - **Saltos de patamar:** podem sugerir mudança no processo, descalibração do equipamento, alteração do procedimento de coleta ou mudança nas condições experimentais.
- **Conduta:** investigar a origem da dependência. Para dados agrupados ou medidas repetidas, considerar modelos mistos generalizados (GLMMs). Para dependência temporal, avaliar modelos com estrutura de correlação autorregressiva, como AR(1), ou modelos específicos de séries temporais.

Gráfico 3: Resíduos vs. Ordem

```
plot(tD, pch = 19, xlab = "Índice da observação",
     ylab = "Resíduo de desvio padronizado")
abline(h = 0, lty = 2)
```

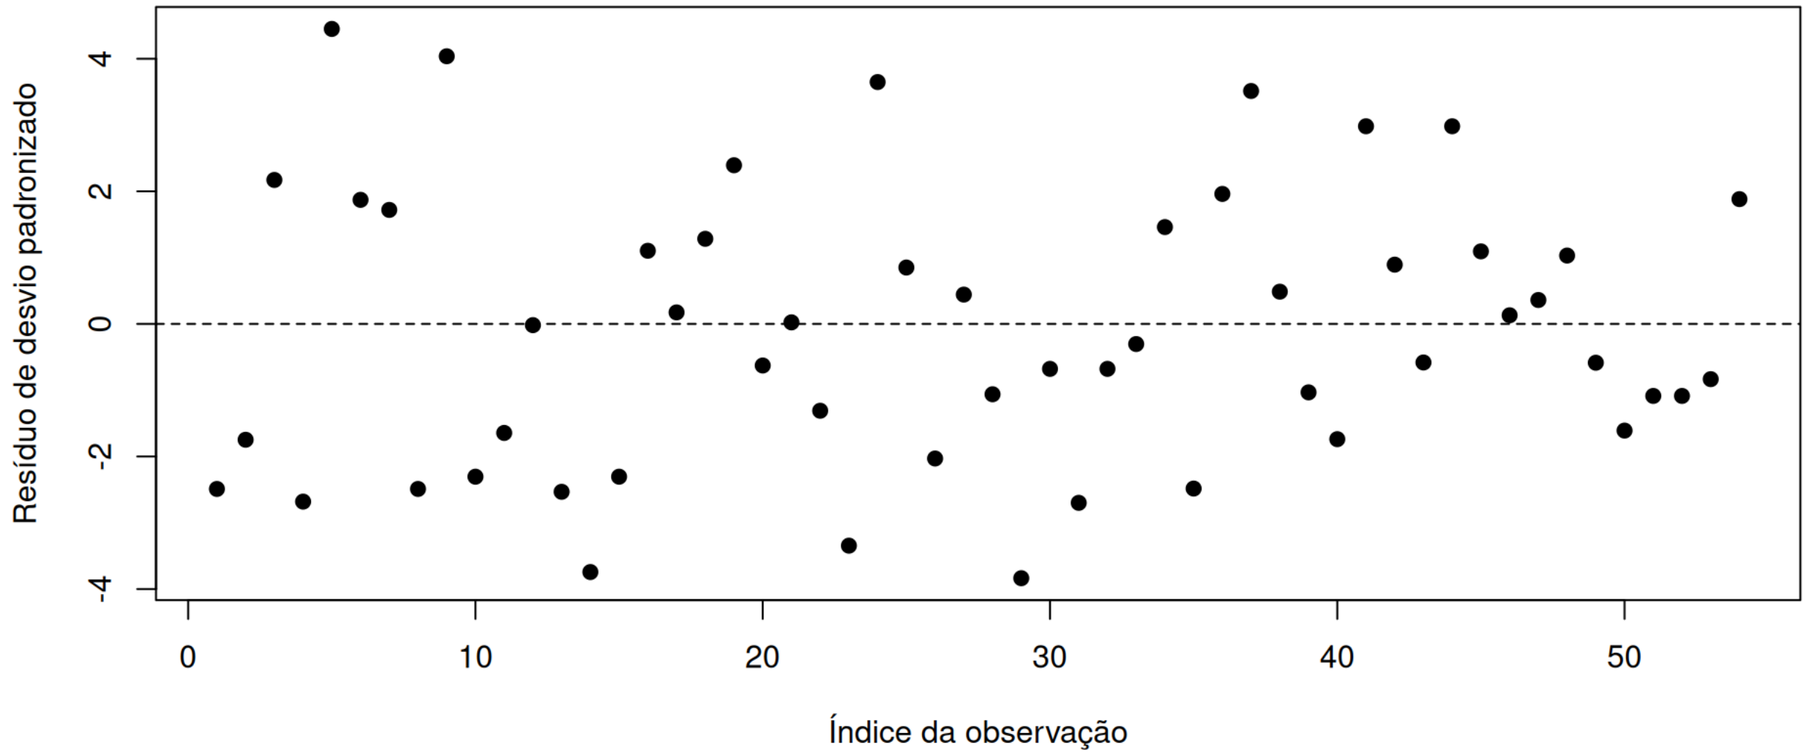


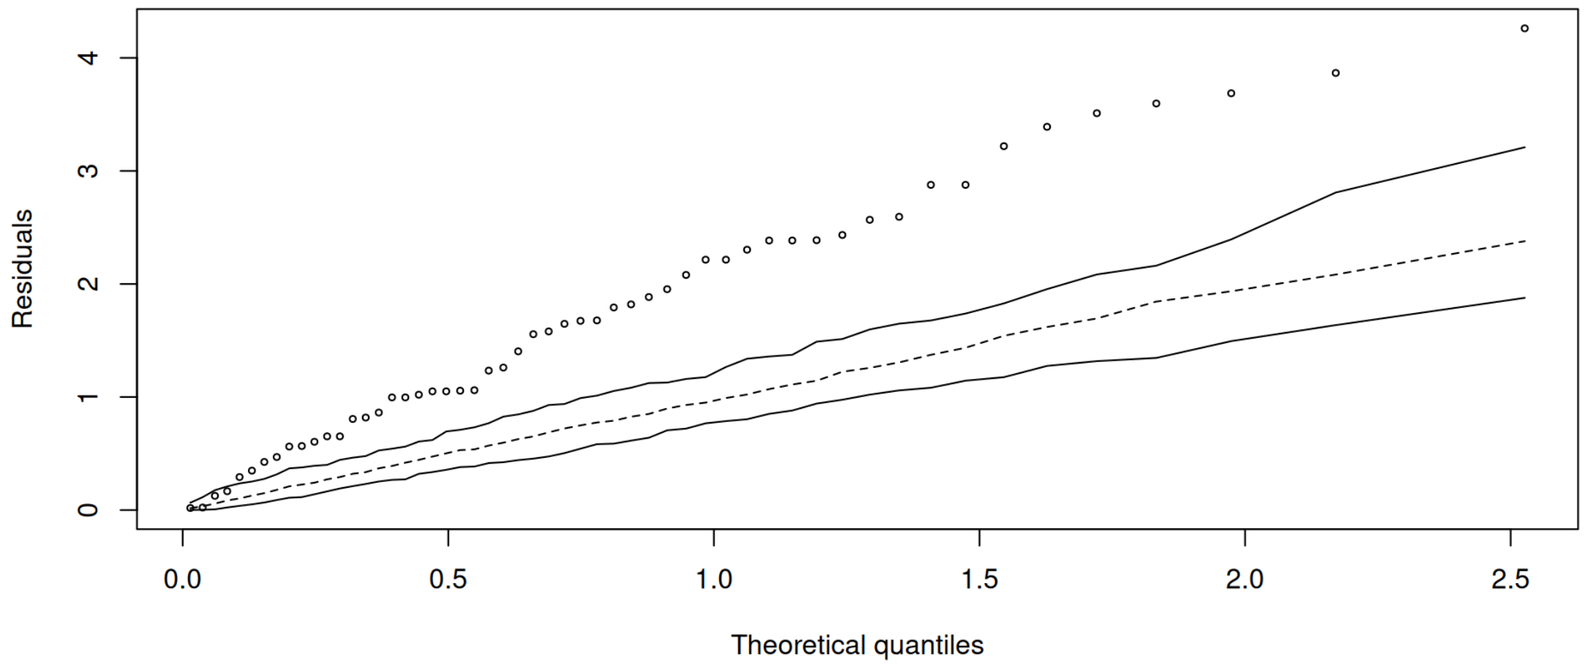
Gráfico 4: Envelope Simulado (Meio-Normal)

- O gráfico meio-normal com envelope de Monte Carlo gera bandas de confiança empíricas para os resíduos, superando a limitação de que em MLGs os resíduos não possuem distribuição Normal exata.
- Interpretação:
  - **Pontos dentro da banda:** o padrão residual é totalmente compatível com o modelo teórico ajustado.
  - **Pontos fora da banda ou tendência de fuga:** indicam más especificações globais ou presença de outliers severos.

Gráfico 4: Envelope Simulado (Meio-Normal)

```r
# Instale uma única vez, se necessário:
# install.packages("hnp")
library(hnp)
hnp(modelo, resid.type = "deviance", sim = 99, halfnormal = TRUE)
```

```
Poisson model
```



Qual gráfico responde a qual pergunta?

Pergunta	Gráfico	Sinal a investigar
Há discrepâncias individuais?	Resíduos padronizados	Posições muito além das faixas $[-2, 2]$
O ajuste muda com a média?	Resíduos × ajustados	Curvatura, tendência ou funil
Alguma preditora parece mal especificada?	Resíduos × preditora	Curvatura ou diferenças entre categorias
Há estrutura na ordem?	Resíduos × índice ordenado	Tendência, ciclos ou sequências
O padrão residual é compatível com o modelo?	Meio-normal com envelope simulado	Muitos pontos fora do envelope

Roteiro Prático para Análise de Resíduos

1. **Ajustar e Comparar:** Ajuste o MLG inicial e faça um primeiro confronto visual entre valores observados (y_i) e ajustados ($\hat{\mu}_i$).
2. **Calcular Métricas:** Extraia os resíduos de resposta, Pearson (r_{Pi}) e componente do desvio (r_{Di}).
3. **Padronizar e Filtrar:** Calcule os resíduos padronizados (r^*_{Di}) para ajustar pela alavancagem (h_i) e selecione observações atípicas para investigação.
4. **Avaliar Graficamente:** Explore gráficos de resíduos contra valores ajustados e contra as variáveis preditoras (X).
5. **Validar Estrutura:** Aplique gráficos de ordem temporal (se houver sequência) e envelopes simulados (hnp) para verificar a calibração do modelo.
6. **Investigar e Agir:** Registre hipóteses sobre causas de más especificações; **jamais elimine observações atípicas** sem confirmação de erro de dados ou motivação substantiva do domínio.

Exercício

No conjunto `warpbreaks`:

a. Tente ajustar um modelo de Poisson com outras funções de ligação disponíveis na função `glm`.

b. Avalie o AIC dos modelos e compare o envelope simulado.

c. Ajuste um modelo com distribuição binomial negativa (função `glm.nb` do pacote `MASS`), avalie o AIC e o envelope simulado.

Próxima aula: diagnóstico de MLGs

- Na próxima aula, vamos combinar evidências residuais com alavancagem, influência, forma funcional, distribuição, função de ligação e análise de sensibilidade para decidir o que investigar e como avaliar a robustez do modelo.

Fim