Diagnóstico de Modelos Lineares Generalizados

Alguma observação afeta excessivamente o ajuste?

ESTAT0092 – Modelos Lineares Generalizados
Prof. Dr. Sadraque E. F. Lucena
http://sadraquelucena.github.io/mlg

UNIVERSIDADE FEDERAL DE SERGIPE

Na aula passada

- Utilizamos o conjunto de dados `warpbreaks`, que registra o número de falhas (`breaks`) em amostras de fios, sob diferentes tipos de lã (`wool`) e níveis de tensão (`tension`).
- Após ajustar e analisar os resíduos, verificamos que o modelo binomial negativo com função de ligação logarítmica era o mais adequado.
- Agora vamos realizar uma análise de diagnóstico para identificarmos
  - observações cuja combinação de preditoras é muito distinta das demais e
  - observações que alteram desproporcionalmente as estimativas do modelo.

Análise de Diagnóstico

O objetivo da **Análise de Diagnóstico** é investigar observações individuais que podem distorcer as estimativas. Para isso, usamos as seguintes medidas:

- **Alavancagem (h_i):**
  - Elemento da diagonal da matriz chapéu ponderada $H = W^{1/2}X(X^TWX)^{-1}X^TW^{1/2}$.
  - Mede o quão extrema é a observação i no espaço das variáveis explicativas (X).
- **Distância de Cook (D_i):**
  - Mede o impacto **global** da remoção da observação i sobre todo o vetor de coeficientes $\hat{\beta}$.
- **DFBETAs ($DFBETA_{j(i)}$):**
  - Avalia o impacto **específico** da remoção da observação i sobre a estimativa do coeficiente $\hat{\beta}_j$.

Alavancagem (h_{ii})

- A alavancagem quantifica o afastamento da i-ésima observação em relação ao centroide das variáveis explicativas no espaço p-dimensional.
- É obtida pelos elementos diagonais h_{ii} da matriz de projeção ponderada:

$$H = W^{1/2} X (X^T W X)^{-1} X^T W^{1/2}$$

  - X é a matriz de delineamento e $W = \mathrm{diag}(w_i)$ é a matriz de pesos iterativos do algoritmo de estimação dos parâmetros, IWLS, que depende do valor ajustado $\hat{\mu}_i$ e da função de variância $V(\mu)$.
- A alavancagem mede o potencial (e não o impacto efetivo) de uma observação alterar o ajuste.
- Emprega-se a regra empírica $h_{ii} > \frac{2p}{n}$ para sinalizar observações com alta alavancagem.
  - Em amostras pequenas ($n < 30$) ou com muitos parâmetros, adota-se $h_{ii} > \frac{3p}{n}$.

Distância de Cook (D_i): Influência Global

- A Distância de Cook quantifica o impacto conjunto da remoção da i-ésima observação sobre todo o vetor de parâmetros estimados $\hat{\boldsymbol{\beta}}$ (ou, equivalentemente, sobre a estrutura de médias $\hat{\boldsymbol{\mu}}$):

$$D_i = \frac{(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})^T (X^T W X)(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})}{p\phi} \approx \frac{r_{P,i}^2}{p\phi} \left(\frac{h_{ii}}{1 - h_{ii}} \right)$$

  - $r_{P,i}$ é o resíduo de Pearson padronizado, h_{ii} é a alavancagem, p é o número de coeficientes e ϕ é o parâmetro de dispersão.
- **Interpretação:** Mede o impacto no ajuste do modelo quando a observação i é excluída.
- O gráfico da distância de Cook contra o índice da observação permite localizar os pontos mais influentes.
- $D_i > \frac{4}{n}$ indica que a observação é influente no ajuste do modelo.

DFBETAs: Influência em Coeficientes Específicos

- Enquanto a Distância de Cook resume a influência global, o DFBETAS quantifica o impacto individual da i-ésima observação sobre a estimativa do j-ésimo coeficiente $\hat{\beta}_j$:

$$\mathrm{DFBETAS}_{ij} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\mathrm{EP}(\hat{\beta}_{j(i)})}$$

  em que $\hat{\beta}_{j(i)}$ e $\mathrm{EP}(\hat{\beta}_{j(i)})$ são a estimativa e o erro-padrão obtidos sem a observação i.

- Ela permite avaliar se a significância (p-valor) de uma variável específica ($\hat{\beta}_j$\$) depende criticamente de uma única observação.
- Em geral, observações com $|\mathrm{DFBETAS}_{ij}| > \frac{2}{\sqrt{n}}$ são sinalizadas para inspeção em amostras moderadas ou grandes.

Voltando ao ajuste do conjunto `warpbreaks`

Roteiro Geral: Ajuste e Avaliação de um MLG

A modelagem via MLGs segue um fluxo sistemático e iterativo em quatro etapas principais:

1. **Especificação e Seleção de Preditoras:**
   - Definição da componente aleatória (família), da função de ligação e seleção das variáveis explicativas (ANODEV / Stepwise).
2. **Avaliação do Ajuste Global e Comparação:**
   - Verificação da qualidade geral do ajuste (Deviance, Pseudo-R^2) e comparação entre modelos candidatos (AIC).
3. **Análise de Resíduos e Inspeção Gráfica:**
   - Validação de premissas teóricas, forma funcional, estabilidade da variância e calibração local via envelopes simulados.
4. **Diagnóstico de Alavancagem e Influência (Aula de hoje):**
   - Identificação de pontos extremos no espaço dos preditores (h_i) e de observações que alteram desproporcionalmente as estimativas do modelo (D_i, DFBETAs).

4. Análise de Diagnóstico

Agora, avançaremos para a **Análise de Diagnóstico**, investigando observações individuais que podem distorcer as estimativas:

- **Alavancagem (h_i):**
  - Elemento da diagonal da matriz chapéu ponderada $H = W^{1/2}X(X^TWX)^{-1}X^TW^{1/2}$.
  - Mede o quão extrema é a observação i no espaço das variáveis explicativas (X).
- **Distância de Cook (D_i):**
  - Mede o impacto **global** da remoção da observação i sobre todo o vetor de coeficientes $\hat{\beta}$.
- **DFBETAs ($DFBETA_{j(i)}$):**
  - Avalia o impacto **específico** da remoção da observação i sobre a estimativa do coeficiente $\hat{\beta}_j$.

Alavancagem

- A alavancagem mede o potencial de uma observação exercer influência devido à sua posição no espaço das covariáveis.
- Ela é obtida pelos elementos diagonais (h_{ii}) da matriz de projeção ponderada:

$$H = W^{1/2} X (X^T W X)^{-1} X^T W^{1/2}$$

- Um valor elevado de h_{ii} indica alta alavancagem (afastamento da observação em relação ao centro dos preditores).
- Uma regra comum é sinalizar valores superiores a $2p/n$, em que p é o número de coeficientes estimados e n é o tamanho amostral. Esse limite não é universal.

Medidas de Influência (Distância de Cook)

Uma observação é **influente** se sua remoção altera significativamente o vetor de parâmetros $\hat{\beta}$.

Distância de Cook para MLGs

- Combina o resíduo padronizado (discrepância na resposta) e a alavancagem (posição em X):

$$D_i = \frac{(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})^T (X^T W X)(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})}{p\phi} \approx \frac{r_{P,i}^2}{p\phi} \left(\frac{h_{ii}}{1 - h_{ii}} \right)$$

  - r_{Pi} : Resíduo de Pearson.
  - h_i : Alavancagem da observação i.
- **Interpretação:** Mede a mudança no ajuste do modelo quando a observação i é excluída.
- O gráfico da distância de Cook contra o índice da observação permite localizar os pontos mais influentes.

DFBETAs: influência sobre cada coeficiente

- DFBETAS quantifica o impacto individual da i-ésima observação sobre a estimativa do j-ésimo coeficiente $\hat{\beta}_j$:

$$\mathrm{DFBETAS}_{ij} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\mathrm{EP}(\hat{\beta}_{j(i)})}$$

  em que $\hat{\beta}_{j(i)}$ e $\mathrm{EP}(\hat{\beta}_{j(i)})$ são a estimativa e o erro-padrão obtidos sem a observação i.

- Ela permite avaliar se a significância (p-valor) de uma variável específica ($\hat{\beta}_j$\$) depende criticamente de uma única observação.
- Em geral, observações com $|\mathrm{DFBETAS}_{ij}| > \frac{2}{\sqrt{n}}$ são sinalizadas para inspeção em amostras moderadas ou grandes.

Voltando aos dados `warpbreaks`

```r
modelo <- MASS::glm.nb(breaks ~ wool + tension,  link = "log",  data = warpbreaks)

# Medidas de diagnóstico
h <- hatvalues(modelo)           # Alavancagem
cook <- cooks.distance(modelo)  # Cook
dfb <- dfbetas(modelo)           # DFBETAs

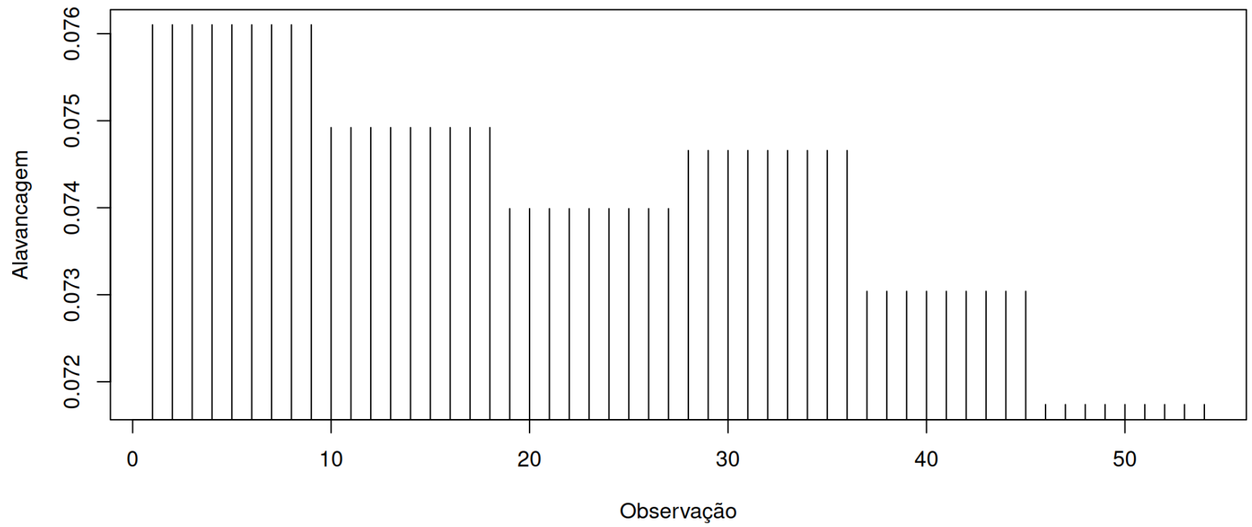

# Observações que merecem investigação
diagnostico <- data.frame(
  observacao = seq_len(nrow(warpbreaks)),
  residuo_dev = rstandard(modelo, type = "deviance"),
  alavancagem = h,
  cook = cook
)

head( diagnostico[order(diagnostico$cook, decreasing = TRUE),] )
```

```
   observacao residuo_dev alavancagem       cook
5           5    1.895561  0.07610143 0.10694292
24         24    1.877179  0.07398891 0.10168187
9           9    1.735365  0.07610143 0.08701163
37         37    1.708338  0.07303891 0.08047189
14         14   -2.094378  0.07492075 0.05632966
41         41    1.454267  0.07303891 0.05558430
```

Alavancagem

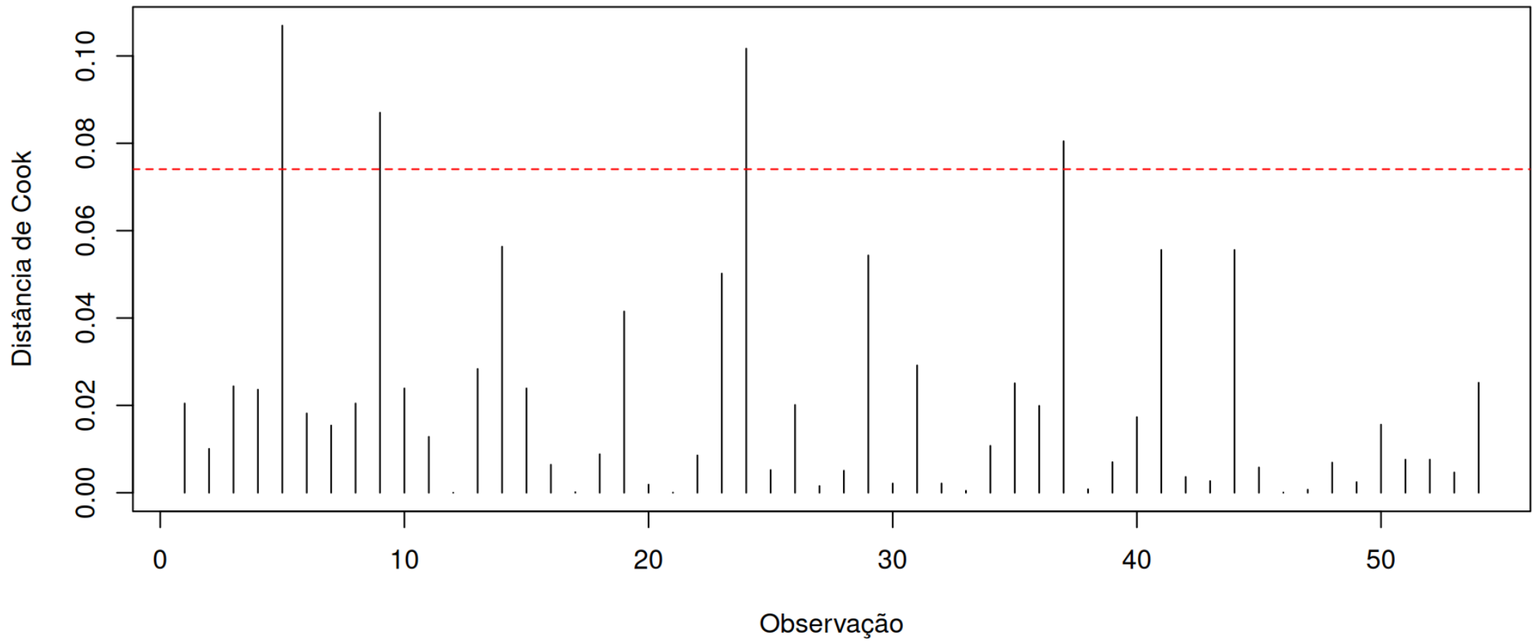
```
# Gráfico da alavancagem
plot(h, type = "h", xlab = "Observação", ylab = "Alavancagem")
abline(h = 2*(length(modelo$coefficients) - 1)/length(modelo$fitted.values),
               col = "red", lty = 2) # 2p/n
```



- Nenhuma observação ultrapassa o limite de referência para alavancagem.
- As observações não apresentam alavancagem elevada segundo esse critério.

Distância ce Cook

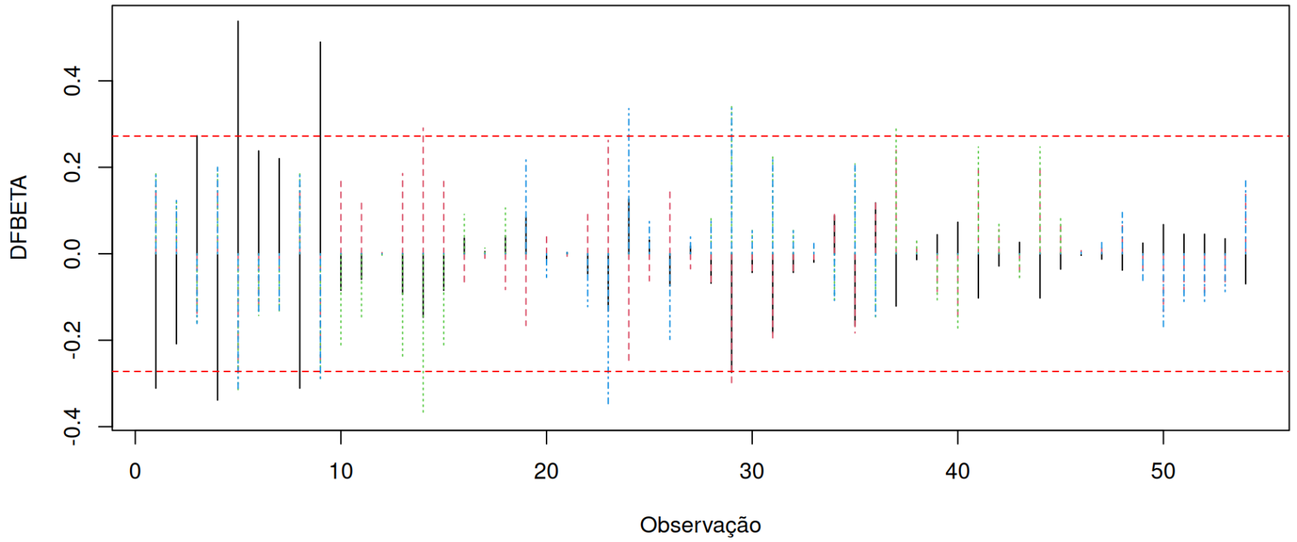
```
# Gráfico da distância de Cook
plot(cook, type = "h", xlab = "Observação", ylab = "Distância de Cook")
abline(h = 4/length(modelo$fitted.values), col = "red", lty = 2) # Linha de alerta: 4/n
```



- As observações 5, 9, 24 e 37 apresentam distância de Cook acima do limite de referência.

DFBETAs

```r
# DFBETAs
matplot(dfb, type = "h", xlab = "Observação", ylab = "DFBETA")
corte_dfb <- 2/sqrt(length(modelo$fitted.values)) # 2/sqrt(n)
abline(h = c(-corte_dfb, corte_dfb), col = "red", lty = 2) # Linhas limites
```



- Algumas observações ultrapassam os limites de referência dos DFBETAs, indicando possível influência sobre as estimativas de determinados coeficientes.

Novo Exemplo: `faraway::gala`

Estudo sobre a riqueza de espécies de plantas em $n = 30$ ilhas do Arquipélago de Galápagos (Johnson & Raven, 1973).

- **Objetivo:** Modelar a relação entre a contagem de espécies de plantas e características geográficas da ilha.
- **Variáveis:**
  - `Species` *(Resposta* Y*)*: número de espécies de plantas encontradas na ilha.
  - `Area`: área total da ilha (km^2).
  - `Elevation`: altitude máxima da ilha (m).
  - `Nearest`: distância até a ilha mais próxima (km).
  - `Scruz`: distância até a ilha Santa Cruz (km).
  - `Adjacent`: área da ilha adjacente (km^2).

Novo Exemplo: `faraway::gala`

```
# Carregamento e visualização inicial
library(faraway)
data(gala)
head(gala)
```

	Species	Endemics	Area	Elevation	Nearest	Scruz	Adjacent
Baltra	58	23	25.09	346	0.6	0.6	1.84
Bartolome	31	21	1.24	109	0.6	26.3	572.33
Caldwell	3	3	0.21	114	2.8	58.7	0.78
Champion	25	9	0.10	46	1.9	47.4	0.18
Coamano	2	1	0.05	77	1.9	1.9	903.82
Daphne.Major	18	11	0.34	119	8.0	8.0	1.84

- A variável `Endemics` representa o número de espécies endêmicas (que só existem naquela ilha) e é um subconjunto do total de espécies (Species). Usar `Endemics` como variável explicativa (X) para prever `Species` (Y) significa usar a resposta para explicar a si mesma.

1. Especificação e Seleção de Preditoras

- Como os dados são de contagem, vamos ajustar os modelos de *Poisson* com função de ligação *log* e *raiz quadrada* e o modelo *Binomial Negativo* com função de ligação *log*.
  - R não conseguiu estimar os parâmetros com as outras funções de ligação.

```
# Modelo Poisson com ligação log
mod_poisson_log <- glm(Species ~ Area + Elevation + Nearest + Scruz + Adjacent,
                       family = poisson(link = "log"), data = gala)

# Modelo Poisson com ligação raiz quadrada
mod_poisson_raiz <- glm(Species ~ Area + Elevation + Nearest + Scruz + Adjacent,
                       family = poisson(link = "sqrt"), data = gala)

# Modelo Binomial Negativo com ligação log
mod_binNeg_log <- MASS::glm.nb(Species ~ Area + Elevation + Nearest + Scruz + Adjacent,
                       link = log, data = gala)
```

1. Especificação e Seleção de Preditoras

- Vamos encolher um modelo pelo menor AIC.

```
AIC(mod_poisson_log, mod_poisson_raiz, mod_binNeg_log)
```

```
                df      AIC
mod_poisson_log  6 889.6767
mod_poisson_raiz 6 904.8808
mod_binNeg_log   7 304.2228
```

- Vamos olhar também a razão de dispersão.

```
# Razão de dispersão phi_D = D / gl (ideal é próximo a 1)
razao_dispersao <- function(modelo) return(modelo$deviance / modelo$df.residual)
razao_dispersao(mod_poisson_log)
```

```
[1] 29.86857
```

```
razao_dispersao(mod_poisson_raiz)
```

```
[1] 30.50207
```

```
razao_dispersao(mod_binNeg_log)
```

```
[1] 1.383185
```

1. Especificação e Seleção de Preditoras

- Como o modelo Binomial Negativo teve menor AIC (e a razão de dispersão é próxima a 1), vamos avaliar a significância das preditoras.

```
# ANODEV marginal - avalia o efeito de remover cada variável
drop1(mod_binNeg_log, test = "Chisq")
```

```
Single term deletions

Model:
Species ~ Area + Elevation + Nearest + Scruz + Adjacent
          Df Deviance    AIC    LRT  Pr(>Chi)
<none>         33.196 302.22
Area       1   36.665 303.69  3.468  0.062562 .
Elevation  1   65.866 332.89 32.670 1.092e-08 ***
Nearest    1   33.263 300.29  0.067  0.795920
Scruz      1   33.569 300.60  0.372  0.541732
Adjacent   1   41.151 308.18  7.955  0.004796 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

1. Especificação e Seleção de Preditoras

- Modelo sem `Nearest`.

```
# Modelo Binomial Negativo com ligação log sem Nearest
mod_binNeg_log2 <- MASS::glm.nb(Species ~ Area + Elevation + Scruz + Adjacent,
                      link = log, data = gala)

drop1(mod_binNeg_log2, test = "Chisq")
```

```
Single term deletions

Model:
Species ~ Area + Elevation + Scruz + Adjacent
          Df Deviance    AIC    LRT  Pr(>Chi)
<none>         33.194 300.29
Area       1   36.796 301.89  3.602  0.057711 .
Elevation  1   67.553 332.65 34.358 4.584e-09 ***
Scruz      1   33.500 298.60  0.306  0.580306
Adjacent   1   41.563 306.66  8.368  0.003818 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

1. Especificação e Seleção de Preditoras

- Modelo sem `Nearest` e `Scruz`.

```
# Modelo Binomial Negativo com ligação log sem Nearest e Scruz
mod_binNeg_log3 <- MASS::glm.nb(Species ~ Area + Elevation + Adjacent,
                        link = log, data = gala)

drop1(mod_binNeg_log3, test = "Chisq")
```

```
Single term deletions

Model:
Species ~ Area + Elevation + Adjacent
          Df Deviance    AIC    LRT  Pr(>Chi)
<none>         33.155 298.59
Area       1   36.676 300.11  3.520  0.060618 .
Elevation  1   67.847 331.29 34.692 3.862e-09 ***
Adjacent   1   41.723 305.16  8.567  0.003422 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

1. Especificação e Seleção de Preditoras

- Modelo sem `Nearest`, `Scruz` e `Area`.

```
# Modelo Binomial Negativo com ligação log sem Nearest, Scruz e Area
mod_binNeg_log4 <- MASS::glm.nb(Species ~ Elevation + Adjacent,
                        link = log, data = gala)

drop1(mod_binNeg_log4, test = "Chisq")
```

```
Single term deletions

Model:
Species ~ Elevation + Adjacent
          Df Deviance    AIC    LRT  Pr(>Chi)
<none>         33.161 299.92
Elevation  1   78.535 343.30 45.374 1.627e-11 ***
Adjacent   1   39.583 304.34  6.422   0.01127 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

2. Avaliação global do modelo

- Avaliação e teste global do modelo reduzido e comparação com AIC.

```
razao_dispersao(mod_binNeg_log) # modelo completo
```

```
[1] 1.383185
```

```
razao_dispersao(mod_binNeg_log4) # modelo apenas com variáveis significativas
```

```
[1] 1.228183
```

```
lmtest::lrtest(mod_binNeg_log, mod_binNeg_log4) # tesando se a diferença é significativa
```

```
Likelihood ratio test

Model 1: Species ~ Area + Elevation + Nearest + Scruz + Adjacent
Model 2: Species ~ Elevation + Adjacent
  #Df  LogLik Df  Chisq Pr(>Chisq)
1   7 -145.11
2   4 -146.96 -3 3.6998     0.2958
```

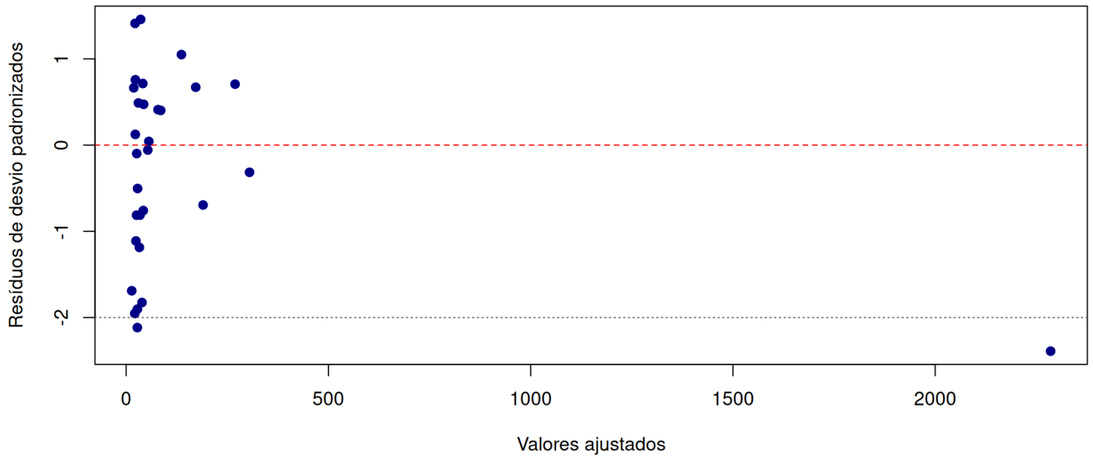
```
AIC(mod_binNeg_log,mod_binNeg_log4) # comparando AICs
```

```
                df      AIC
mod_binNeg_log   7 304.2228
mod_binNeg_log4  4 301.9226
```

3. Análise de resíduos

- Há inadequações na estrutura de média e variância do modelo? *(Gráfico dos Resíduos padronizados vs. Ajustados)*

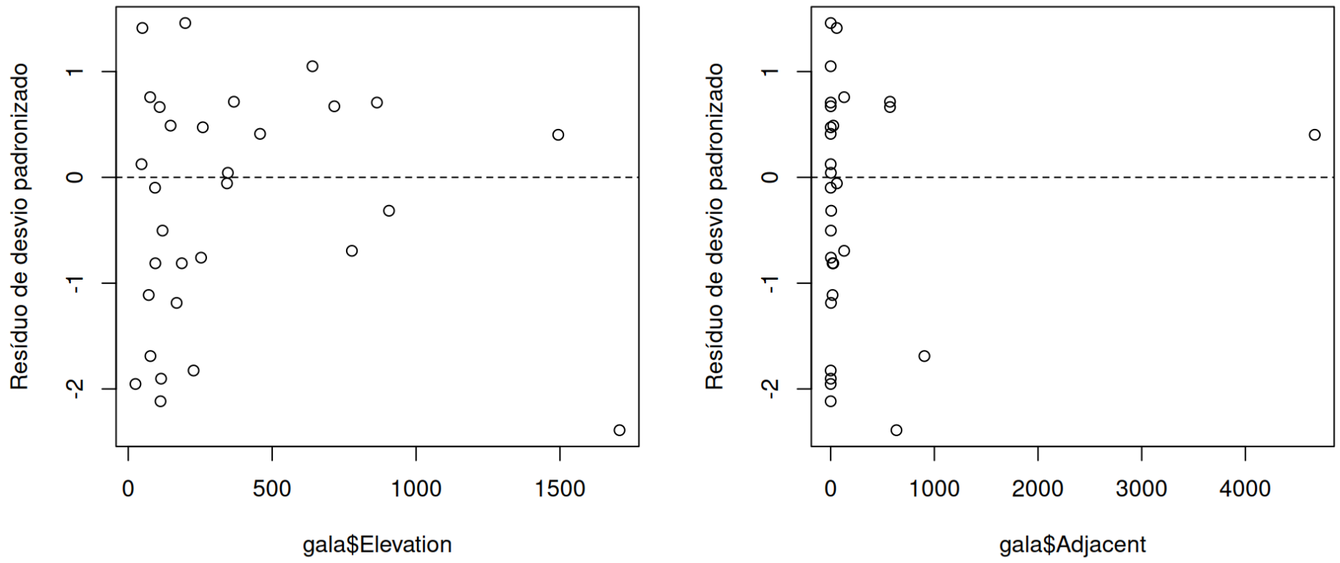
```
tD <- rstandard(mod_binNeg_log4, type = "deviance")
plot(fitted(mod_binNeg_log4), tD,
     xlab = "Valores ajustados", ylab = "Resíduos de desvio padronizados",
     pch = 19, col = "darkblue")
abline(h = 0, lty = 2, col = "red")
abline(h = c(-2, 2), lty = 3, col = "gray40")
```



3. Análise de resíduos

- As variáveis preditoras estão bem especificadas? *(Gráfico dos Resíduos vs. Variáveis Preditoras)*

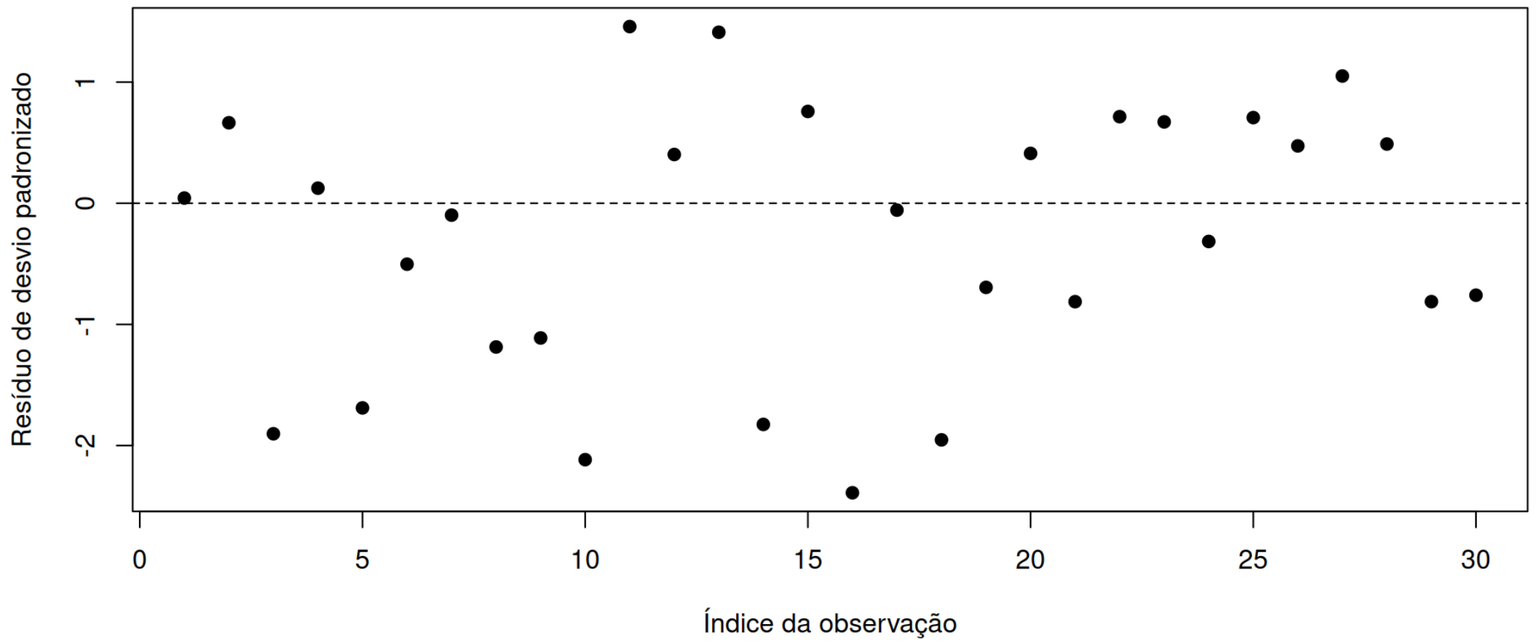
```
par(mfrow = c(1, 2))
plot(gala$Elevation, tD, ylab = "Resíduo de desvio padronizado")
abline(h = 0, lty = 2)
plot(gala$Adjacent, tD, ylab = "Resíduo de desvio padronizado")
abline(h = 0, lty = 2)
```



3. Análise de resíduos

- As observações são independentes? *(Gráfico dos Resíduos vs. Ordem)*

```
plot(tD, pch = 19, xlab = "Índice da observação",
     ylab = "Resíduo de desvio padronizado")
abline(h = 0, lty = 2)
```

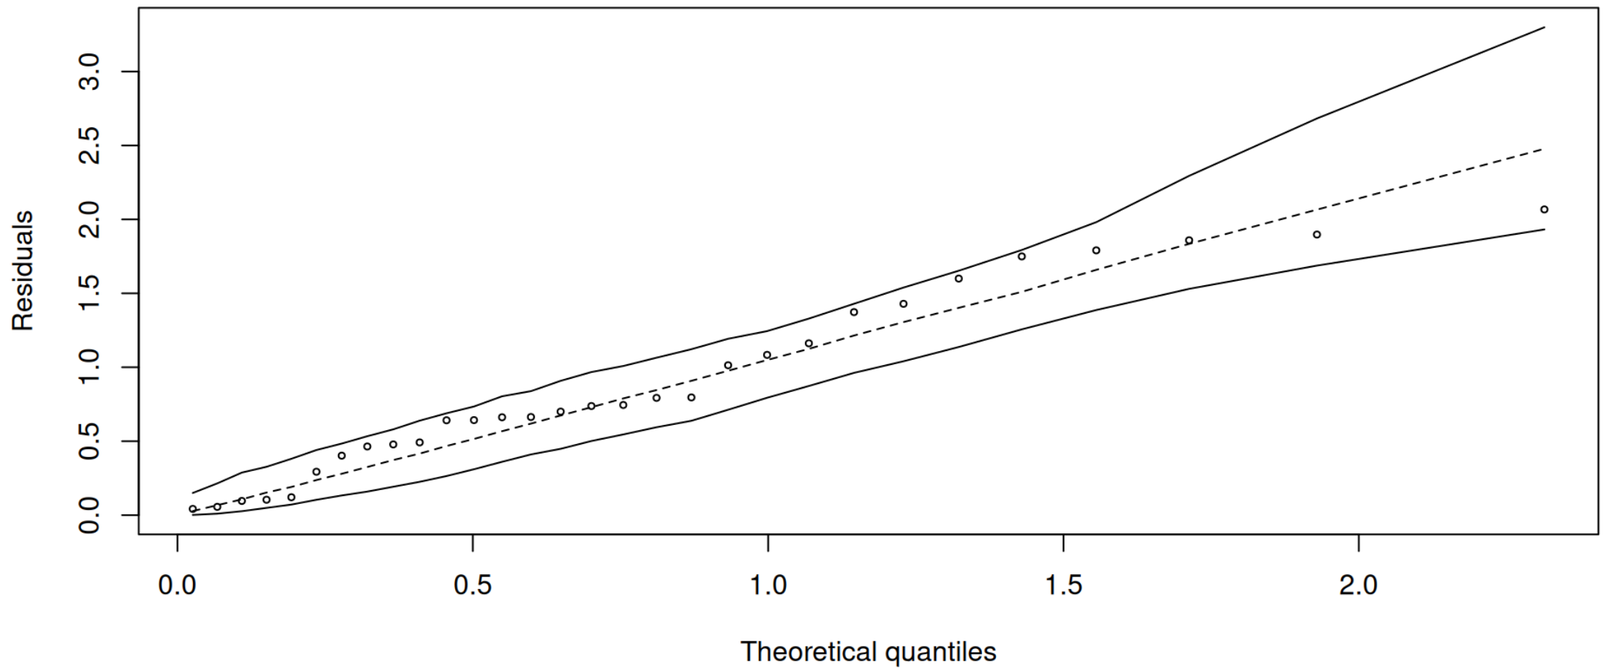


3. Análise de resíduos

- O modelo está adequado? *(Gráfico Meio-Normal com Envelope Simulado)*

```
hnp::hnp(mod_binNeg_log4, resid.type = "deviance", sim = 999, halfnormal = TRUE)
```

```
Negative binomial model (using MASS package)
```



4. Análise de Diganóstico

- Vamos agora verificar se alguma variável tem alta alavancagem.

```
h <- hatvalues(mod_binNeg_log4) # Alavancagem
cook <- cooks.distance(mod_binNeg_log4)  # Cook
dfb <- dfbetas(mod_binNeg_log4)          # DFBETAs

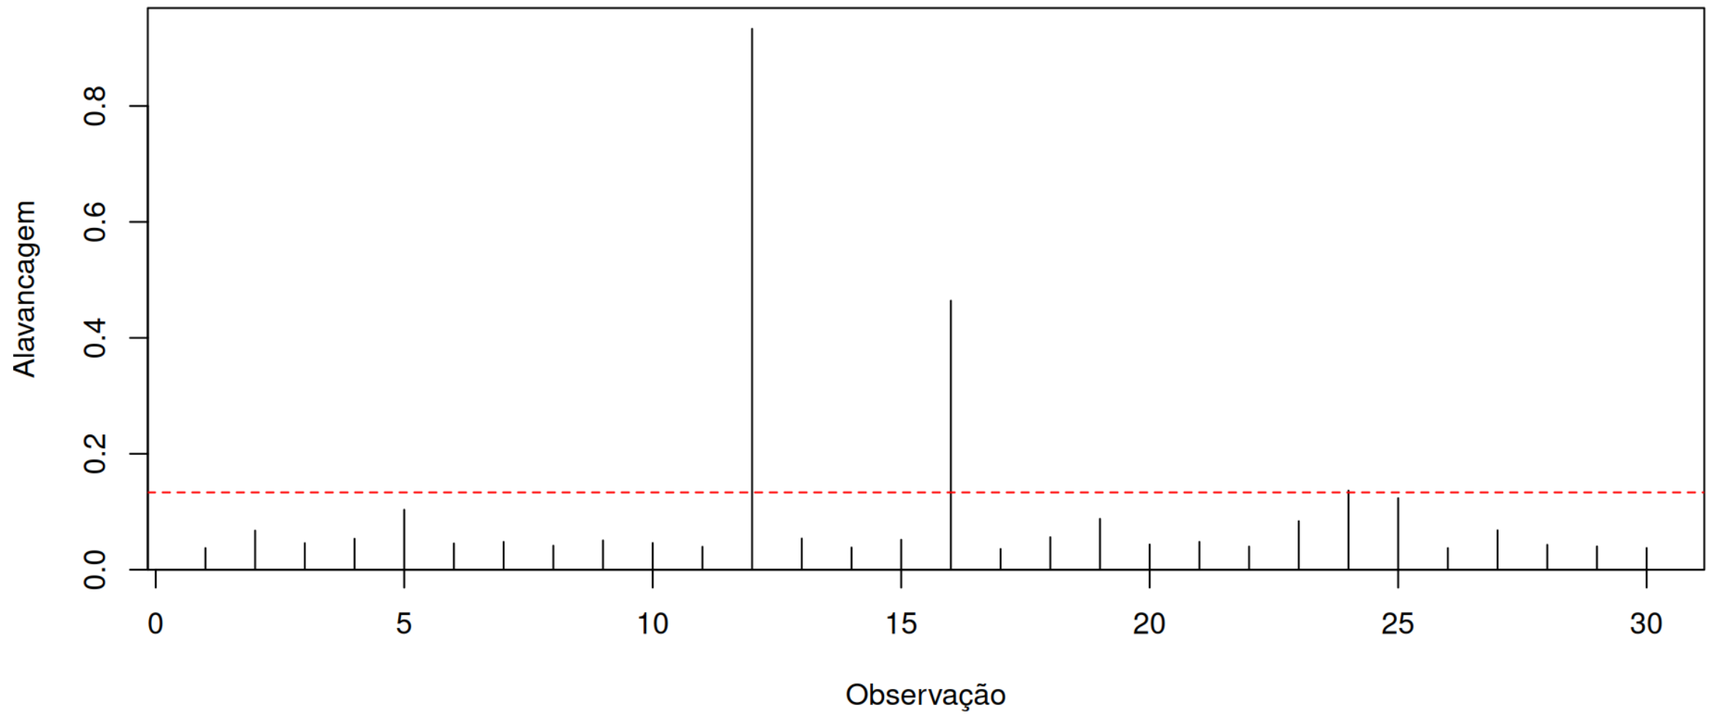
# Observações que merecem investigação
diagnostico <- data.frame(
  observacao = seq_len(nrow(gala)),
  residuo_dev = rstandard(mod_binNeg_log4, type = "deviance"),
  alavancagem = h,
  cook = cook
)

diagnostico[
  order(diagnostico$cook, decreasing = TRUE),
][1:5, ]
```

```
           observacao residuo_dev alavancagem       cook
Fernandina         12    0.402150  0.93310538 0.79576802
Isabela            16   -2.389927  0.46411182 0.57252849
Gardner1           13    1.411402  0.05378127 0.07472278
Espanola           11    1.458194  0.03960425 0.05932752
SantaMaria         27    1.049976  0.06805231 0.04501408
```

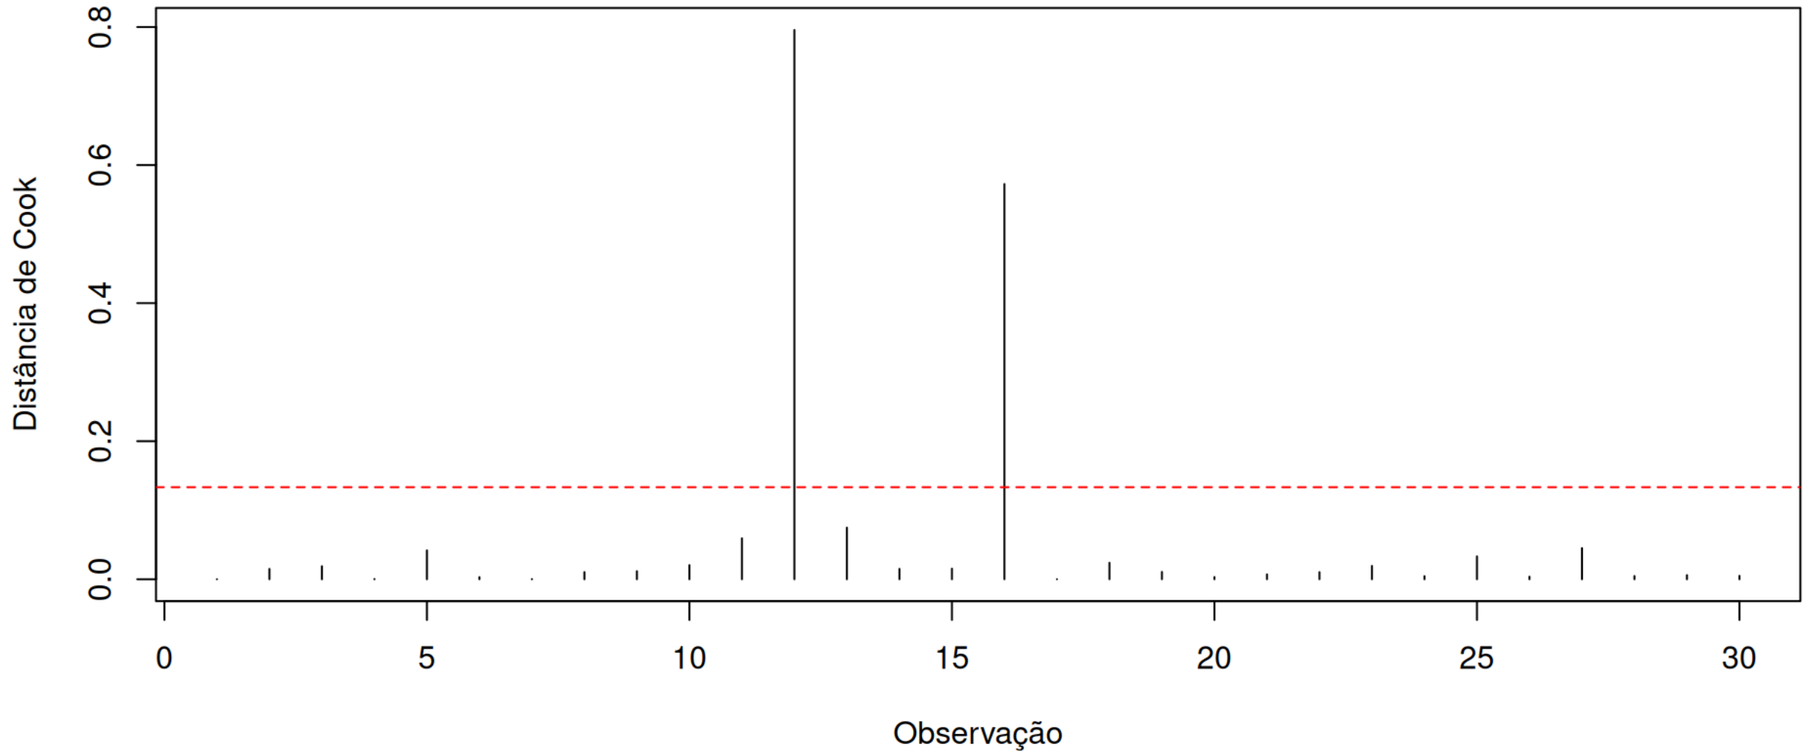
4. Análise de Diganóstico: Pontos de alavanca

```
# Gráfico da alavancagem
plot(h, type = "h", xlab = "Observação", ylab = "Alavancagem")
abline(h = 2*(length(mod_binNeg_log4$coefficients) - 1)/length(mod_binNeg_log4$fitted.values),
               col = "red", lty = 2) # 2p/n
```



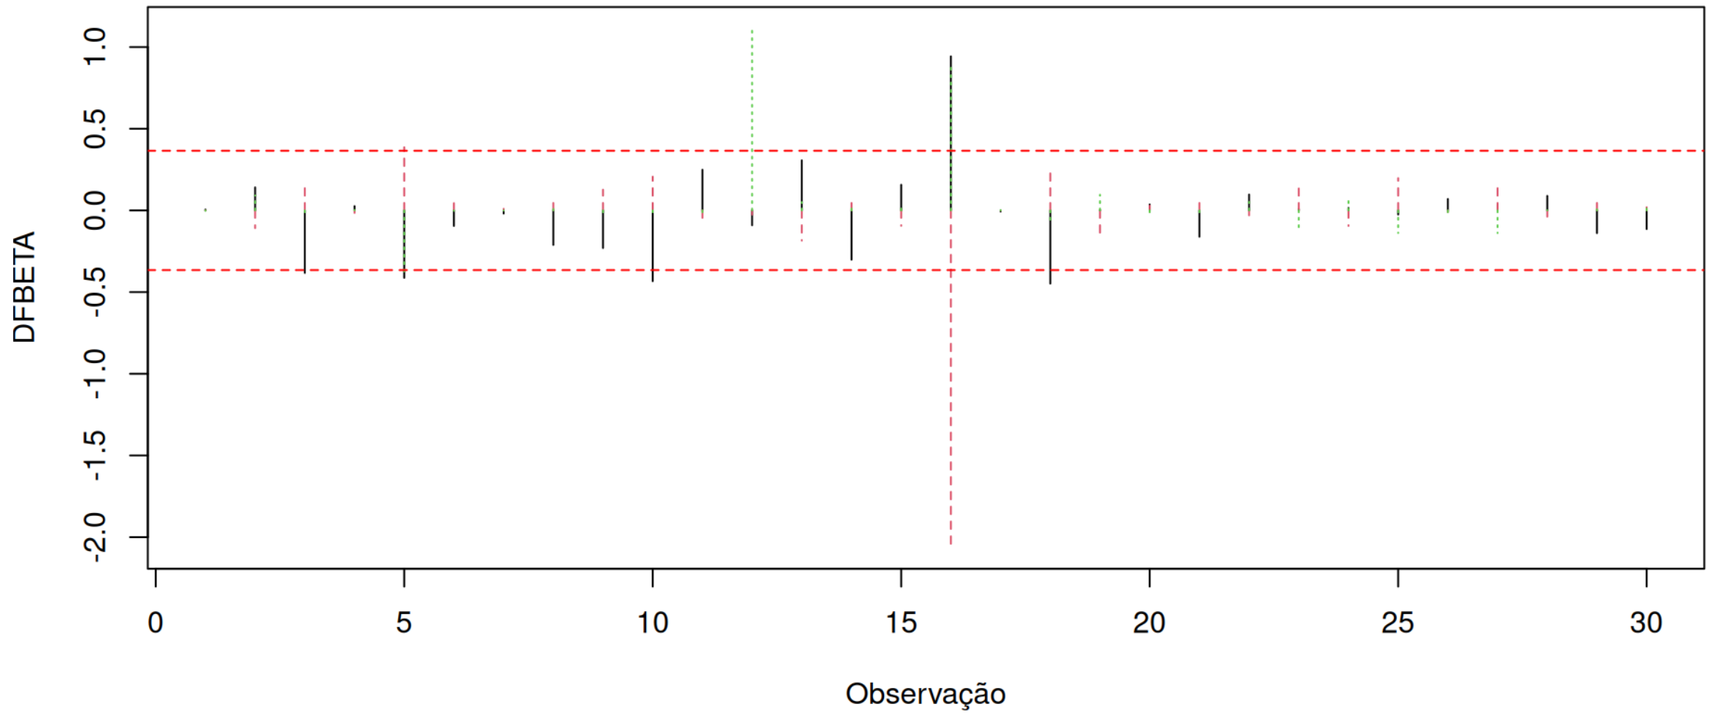
4. Análise de Diganóstico: Distância de Cook

```
# Gráfico da distância de Cook
plot(cook, type = "h", xlab = "Observação", ylab = "Distância de Cook")
abline(h = 4/length(mod_binNeg_log4$fitted.values), col = "red", lty = 2) # Linha de alerta: 4/n
```



4. Análise de Diganóstico: DFBETAs

```r
# DFBETAs
matplot(dfb, type = "h", xlab = "Observação", ylab = "DFBETA")
corte_dfb <- 2/sqrt(length(mod_binNeg_log4$fitted.values)) # 2/sqrt(n)
abline(h = c(-corte_dfb, corte_dfb), col = "red", lty = 2) # Linhas limites
```



A Influência da Obs. 16: Ilha Isabela

```
gala[16, c("Species", "Elevation", "Adjacent")]
```

```
        Species Elevation Adjacent
Isabela     347      1707   634.49
```

```
colMeans(gala[,c("Species", "Elevation", "Adjacent")])
```

```
  Species Elevation  Adjacent
 85.23333 368.03333 261.09833
```

```
# Predição para a observação 16 segundo o modelo
predict(mod_binNeg_log4, type = "response")[16]
```

```
 Isabela
2285.345
```

- **Características:**
  - A observação 16 (Isabela) possui altitude de $1.707\ \mathrm{m}$, sendo um ponto extremo no espaço do preditor `Elevation`.
  - O modelo superestima a contagem de espécies nessa ilha (≈ 2.285 espécies estimadas contra 347 contabilizadas).

Exercício

- Base de dados: `dataCar`, pacote `insuranceData` do R.

A base contém 67.856 apólices de seguro de automóveis contratadas em 2004 ou 2005, com informações sobre os veículos, os segurados, a exposição ao risco e a ocorrência de sinistros.

- Ajuste um modelo de regressão com a variável `numero_sinistros` como resposta e `valor_veiculo`, `idade_veiculo`, `sexo`, `regiao`, `faixa_etaria` e `offset(log(exposicao)` como variáveis regressoras.
- Escolha a distribuição e função de ligação mais adequada. Faça seleção de variáveis, Avalie a adequação do modelo. Faça a análise de resíduos e diagnóstico.

Exercício

```
library(insuranceData, dplyr, forcats)
data(dataCar)
dados <- dataCar |>
  rename(valor_veiculo = veh_value, exposicao = exposure, sinistro = clm,
    numero_sinistros = numclaims, custo_sinistros = claimcst0, carroceria = veh_body,
    idade_veiculo = veh_age, sexo = gender, regiao = area, faixa_etaria = agecat
  ) |>
  mutate(
    sinistro = factor(sinistro, levels = c(0, 1), labels = c("Não", "Sim")),
    idade_veiculo = factor(idade_veiculo, levels = c(1, 2, 3, 4),
      labels = c("Mais novo", "Categoria 2", "Categoria 3", "Mais antigo")),
    sexo = factor(sexo, levels = c("F", "M"), labels = c("Feminino", "Masculino")),
    regiao = factor(regiao, levels = c("A", "B", "C", "D", "E", "F"),
      labels = c("Região A", "Região B", "Região C", "Região D", "Região E", "Região F")),
    faixa_etaria = factor(faixa_etaria, levels = 1:6,
      labels = c("Mais jovem", "Faixa 2", "Faixa 3", "Faixa 4", "Faixa 5", "Mais velha")),
    carroceria = fct_recode(factor(carroceria), "Ônibus" = "BUS", "Conversível" = "CONVT",
      "Cupê" = "COUPE", "Hatchback" = "HBACK", "Teto rígido" = "HDTOP", "Minicarro" = "MCARA",
      "Micro-ônibus" = "MIBUS", "Furgão" = "PANVN", "Roadster" = "RDSTR", "Sedã" = "SEDAN",
      "Perua" = "STNWG", "Caminhão" = "TRUCK", "Utilitário" = "UTE"))
```

Fim